




Transformation des reviews en un système décisionnel



Rapport note/review.



text_length	mean_rating	impact_score	normalized_impact_score
1	4.292360892801006	0.3195103855412911	0.6306987934621574
2	4.174361378017342	0.2015108707576272	0.5149227537508231
3	4.1395348837209305	0.1666843764612156	0.48075249810138104
4	4.533216603151715	0.5603660958919998	0.8670160388117613
5	4.411049818996725	0.43819931173701	0.7471512539466268
6	4.40958605664488	0.436735549385165	0.7457150733954961
7	4.668754516983859	0.6959040097241442	1.0
8	4.40835196712395	0.4355014598642355	0.7445042379302451
9	4.479625670106287	0.5067751628465724	0.8144349243570954
10	4.40738717539289	0.4345366681331755	0.7435576258532958
11	4.394458975104136	0.4216084678444214	0.7308730327617817
12	4.282978110599078	0.3101276033393634	0.6214928118375316
13	4.2770170634084685	0.30416655614875365	0.6156440891751844
14	4.2570473280682535	0.2841968208085386	0.5960506452867723
15	4.241198270537368	0.2683477632776534	0.5805002329190003
16	4.216877389003234	0.24402688174351939	0.5566376318610815
17	4.244488299971807	0.2716377927120921	0.5837282680439868
18	4.214866842259291	0.24201633499957653	0.5546649700234886
19	4.167316080255889	0.19446557299617373	0.5080102111450027
20	4.194283730617912	0.22143322335819748	0.5344697077366555
21	4.1938811188811185	0.22103061162140358	0.5340746824476722

Corrélation d’une review longue à :

- Déception,
- Justification émotionnelle,
- Demande de remboursement probable

$$Risk_Score = \alpha \cdot \text{len}(text) + \varepsilon$$

Modèle de prédiction

```
▶ ✓ Dec 27, 2025 (<1s) 7

from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

preds = model.predict(X_test)

print("★ Accuracy :", accuracy_score(y_test, preds))
print("\n★ Classification Report :\n", classification_report(y_test, preds))
print("\n★ Confusion Matrix :\n", confusion_matrix(y_test, preds))
```

★ Accuracy : 0.9118132775514698

★ Classification Report :

	precision	recall	f1-score	support
0	0.87	0.69	0.77	1936
1	0.92	0.97	0.95	7147
accuracy			0.91	9083
macro avg	0.90	0.83	0.86	9083
weighted avg	0.91	0.91	0.91	9083

★ Confusion Matrix :

```
[[1327 609]
 [ 192 6955]]
```

💀 Mots liés aux reviews NÉGATIVES :

broke
disappointed
poor
cheap
returning
cheaply
poorly
disappointing
broken
waste
returned
terrible
fell
horrible
return

🔥 Mots liés aux reviews POSITIVES :

awesome
amazing
excellent
loved
exactly
beautiful
little
compliments
nice
perfectly
comfortable
loves
perfect
great
love



Les sujets avec leurs notes

topic		keywords	average_rating
0	47	love, opuj9j, ut, favorite, beautiful	5.000000
1	28	love, them, these, themmmmmmmmm, bows	5.000000
2	41	compliments, lots, many, complements, of	4.937500
3	17	nice, awesome, perfect, great, excellent	4.913333
4	33	what, exactly, looking, just, wanted	4.862069
5	20	love, it, loved, like, luv	4.854545
6	31	warm, weather, fuzzy, hot, cold	4.812500
7	15	gift, loved, she, loves, my	4.786127
8	38	happy, pleased, satisfied, happythat, pleasedu	4.736842
9	43	love, , , ,	4.733333
10	12	cute, beautiful, pretty, very, made	4.695187
11	39	amazing, girlies, crawling, conditionsbr, vide...	4.555556

12	46	like, lke, line, photo, just	4.545455
13	48	pin, pins, excellent, beat, assured	4.545455
14	4	fit, top, fits, great, perfect	4.504732
15	14	comfortable, soft, comfy, very, super	4.474860
16	21	fast, shipping, shipped, delivery, arrived	4.423077
17	9	quality, product, good, price, great	4.329897
18	29	described, exactly, what, as, expected	4.250000
19	34	works, does, worked, directions, what	4.230769
20	2	hat, mask, head, it, is	4.221636
21	27	old, month, she, fit, daughter	4.204545
22	19	la, es, muy, el, que	4.196970
23	5	bag, wallet, purse, cards, it	4.185430

Et avec les sujets principaux, et leurs notes moyenne, on a le ...



BERTopic



Résultats avec BERTopic

Sujet	Mots clés	Note Moyenne
Confort	<i>soft, breathable, perfect fit</i>	4.6
Livraison	<i>fast shipping, reliable</i>	4.4
Taille	<i>too small, inaccurate size chart</i>	2.9
Qualité	<i>cheap, ripped, broke</i>	2.7



Choix d'un modèle ML

Modèle choisi : TF-IDF + Régression Logistique

TF - IDF

$$TF-IDF(t, d) = TF(t, d) \cdot \log \frac{N}{df(t)}$$

Interprétation : Les mots fréquents mais discriminants → score fort.



Régression Logistique

$$\mathbb{P}(y = 1|x) = \sigma(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n),$$

avec $\sigma(z) = \frac{1}{1 + e^{-z}}$

Interprétation : Chaque mot ajoute ou retire de la probabilité à la classification.

ReviewGPT

ReviewGPT : Chatbot spécialisé d'Amazon, qui est entraîné sur les bonnes pratiques des nos clients.



```
def predict_rating(keywords):  
    filtered = reviews_df  
    for word in keywords:  
        filtered = filtered.filter(col("text").contains(word.lower()))  
  
    return round(filtered.agg(avg("rating")).collect()[0][0], 2)
```

```
keywords = ["comfortable", "stylish", "quality"]  
  
print("motclés:", keywords)  
print("Note prédite:", predict_rating(keywords))  
print("REVIEW générée:", generate_review_from_keywords(keywords))
```

User keywords: ['comfortable', 'stylish', 'quality']

Predicted rating: 4.8

Generated review: I have bought this watch twice my son says they are the best shoes he had ever had, super comfortable this sunglasses looks very nice and stylish.



Comparaison des outils

	Databricks (Data Intelligence Platform)	Dataiku (Plateforme pour l'IA au quotidien)
Philosophie	Code-First. Basé sur Apache Spark et le Lakehouse (Delta Lake).	Low-Code / No-Code. Interface visuelle basée sur des "recettes" et des workflows.
Public Cible	Data Engineers, Data Scientists, Experts SQL/Python.	Analystes Business, Data Scientists, Managers.
Interface	Notebooks collaboratifs (type Jupyter) et SQL Editor.	Flow visuel (Drag-and-drop) et Studio de codage intégré.
Performance	Exceptionnelle sur le Big Data (calcul distribué natif).	Dépend de l'infrastructure sous-jacente (peut utiliser Spark/Databricks).
Avantages	• Scalabilité quasi-illimitée • Standard Open Source (Delta Lake/MLflow). • Meilleur pour l'ingénierie lourde.	• Collaboration métier-technique fluide. • Gouvernance et MLOps très intuitifs. • Rapidité de prototypage (AutoML).
Inconvénients	• Courbe d'apprentissage élevée. • Interface moins accessible aux non-codeurs. • Coûts de calcul (DBU) parfois complexes à prévoir.	• Coût de licence annuel élevé. • Moins flexible pour le "custom" pur. • Peut devenir une "boîte noire" si mal géré.
Modèle de Coût	Consommation à l'usage (Pay-as-you-go).	Licence annuelle (souvent par utilisateur/groupe).

Répartitions des tâches

Enrique ALVES	Annaelle FAGE	Ruben Pina
- Mise en place de l'architecture Databricks et du Spark distribué. - Ingestion et nettoyage des 2,5 millions de reviews avec PySpark. - Développement du modèle supervisé (TF-IDF + Régression Logistique) avec <i>Annaelle</i>.	- Développement du modèle supervisé (TF-IDF + Régression Logistique) avec <i>Enrique</i>. - Mise en œuvre du Topic Modeling avec BERTopic (SBERT, UMAP, HDBSCAN). - Conception de l'algorithme de génération de ReviewGPT.	- Analyse de la corrélation entre longueur des textes et sentiment (Risk Score). - Comparaison stratégique des outils (Databricks vs Dataiku). - Traduction des insights en actions opérationnelles (alertes fournisseurs, fiches produits).
Tournage de la vidéo (nous tous) et montage vidéo (Annaelle)		
Construction du PowerPoint (notre tous) que nous faisons en même temps que l'avancement du projet.		



Merci de votre
attention M. BEZOS

