


DIFFERENTIAL PRIVACY FOR CLINICAL TRIAL DATA: PRELIMINARY EVALUATIONS

VU Duy & SLAVKOVIC Aleksandra




ALVES, FAGE & PINA

M2 Probabilités et Statistiques
des Nouvelles Données

Sommaire

01 **Cas 1**
Test statistique classique appliqué à une proportion unique


02 **Cas 2**
Analyse d'indépendance par test du chi-deux dans un tableau 2×2



Test statistique classique appliqué à une proportion unique

Succès ou échec du traitement.

- Variables : $(X_1, \dots, X_N) \sim \text{Ber}(p)$
- Hypothèses : $H_0 : p = p_0$ contre $H_a : p = p_0 + \delta$
- Maximum de vraisemblance(MLE): $\hat{p} = \frac{1}{N} \sum_{i=1}^N X_i$



TEST D'HYPOTHÈSE

- Deux types d'erreurs :
 - Type I (α) : on rejette alors que c'est vrai.
 - Type II (β) : on ne rejette pas alors que c'est faux.
- Confiance = $1 - \alpha$
- Puissance = $1 - \beta$

Confidentialité différentielle

- Deux bases de données sont voisines si elles changent pour une seule personne.
 - Un mécanisme est ϵ -privé s'il donne presque le même résultat sur ces deux bases.
 - ϵ indique combien d'information sur un individu peut fuir.

Bruit de Laplace

- Pour rendre l'estimation conforme à l' ϵ -DP, on ajoute un bruit de Laplace.
 - La sensibilité de la moyenne est $1/N$.
 - On ajoute donc un bruit Laplace :
$$L \sim \text{Laplace}\left(0, \frac{\Delta}{\epsilon}\right) = \text{Laplace}\left(0, \frac{1}{N\epsilon}\right).$$
 - La variance du bruit vaut $2b^2$ quand l'échelle est notée b .

MSE et MSE standardisée:

Mesurer la perte de précision

Comment est-elle calculée ?

MSE :

$$MSE(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

combine variance et biais ; plus elle est faible, plus l'estimation est précise.

MSE standardisée :

$$\frac{MSE(DP)}{Var(MLE)}$$

valeur sans unité qui indique combien de fois l'estimateur privé est moins précis que l'estimateur classique.

Comment l'interpréter ?

une MSE standardisée proche de 1
⇒ performance comparable au MLE
; valeurs élevées ⇒ fort coût en
précision dû au bruit de
confidentialité.

en divisant la MSE(DP) par Var(MLE),
on voit combien de fois l'estimateur
privé est moins précis que
l'estimateur sans bruit

Pourquoi c'est utile ici ?

La MSE standardisée permet de comparer directement l'estimateur différentiel privé (DP) à l'estimateur classique (MLE). Elle quantifie le « coût » de la confidentialité en termes de perte de précision.

Le rôle de p_0 (taux de référence)

p_0 = taux de succès « normal », attendu sans effet du traitement.

C'est la valeur de référence autour de laquelle les données doivent tourner si H_0 est vraie.

Le rôle de δ (effet minimal détectable)

δ = effet minimal détectable : le gain que l'on veut pouvoir repérer.

Plus δ est petit, plus l'effet est subtil → il faut davantage d'observations.

Pourquoi on doit augmenter la taille d'échantillon N' ?

Le bruit DP réduit fortement la précision et fait perdre de la puissance.


Pour retrouver les mêmes garanties (α, β) , il faut augmenter l'échantillon :

$N' = K N$, où K indique combien de données supplémentaires sont nécessaires.



Effet du niveau de confidentialité ϵ

Quand ϵ est petit, la confidentialité est forte, le bruit est élevé et la MSE du DP explose.
Quand ϵ augmente, le bruit diminue et la MSE du DP revient proche de celle du MLE.
→ Compromis clair : plus de confidentialité = moins de précision.



Tables I–II : quand ϵ est petit, la MSE DP est très élevée → les facteurs K sont grands.

TABLE 1 – Exact and normal-approximated sample size correction factor K with $\alpha = .05$, $\beta = .4$, $p_0 = .25$, $\delta = .1$. True sample size is $N = 103$ and the DP sample size is $N' = KN$.

ϵ	0.1	0.2	0.3	0.4	0.5
Exact K	3.65	2.12	1.64	1.42	1.29
Normal-Approximated K	3.58	2.10	1.63	1.41	1.29


TABLE 2 – Exact and normal-approximated sample size correction factor K when $\alpha = .05$, $\beta = .1$, $p_0 = .25$, $\delta = .1$. True sample size is $N = 221$ and the DP sample size is $N' = KN$.

ϵ	0.1	0.2	0.3	0.4	0.5
Exact K	2.62	1.64	1.35	1.22	1.15
Normal-Approximated K	2.64	1.65	1.35	1.22	1.15

Effet de la taille d'échantillon N

Quand on fixe $\varepsilon=0.1$, augmenter la taille d'échantillon N réduit fortement l'impact du bruit DP (qui décroît comme $1/(N\varepsilon)$).

Plus N est grand, plus l'estimateur DP devient précis, et sa MSE se rapproche de celle du MLE (≈ 1)



Pour petits N, le bruit DP domine et la MSE standardisée est très élevée.

Quand N augmente, la variance naturelle diminue et le bruit DP devient négligeable : la MSE du DP baisse fortement.
→ Augmenter N compense naturellement le bruit DP, même sans changer ε .

Analyse d'indépendance par test du χ^2 - deux dans un tableau 2×2



Tableaux de contingence

Tableau à double entrée.
Lignes : type de médicament.
Colonnes : effet observé (succès ou échec).
Le croisement permet d'analyser la relation entre le médicament et son effet et d'observer leur comportement combiné.

$$(X_1, X_2, X_3, X_4) \sim \text{Mult}(N, \pi_1, \pi_2, \pi_3, \pi_4).$$

test du χ^2

- Permet de tester si le type de médicament et son effet sont indépendants.
- Statistique : $\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}$
 O_i : fréquence observée dans la cellule
 E_i : fréquence attendue sous l'hypothèse d'indépendance
- Plus χ^2 est grand, plus il y a de preuves contre l'indépendance.

Effet du bruit

- Le bruit est appliqué indépendamment à chaque cellule, puis les proportions bruitées sont renormalisées.
- Cette étape affecte différemment les cellules selon leur probabilité :
- → les petites cellules subissent une erreur relative plus grande.

$$\text{Mult}(0.333, 0.167, 0.25, 0.25)$$



Correction de taille d'échantillon : le facteur K

L'ajout de bruit réduit l'efficacité statistique, notamment la puissance des tests. Les auteurs introduisent donc un facteur de correction :

$$K = \frac{N'}{N},$$

où N' est la taille d'échantillon nécessaire sous DP pour obtenir la même puissance qu'avec un échantillon de taille N sans bruit.


Dans le cas binomial :

- Lorsque ϵ est petit (ex. $\epsilon = 0.1$), le bruit est important : le facteur K monte jusqu'à environ 4 (voir Tables I et II).
- Lorsque ϵ augmente, le bruit s'atténue : K redescend rapidement vers 1.
- Les versions « exactes » (basées sur Normal-Laplace) et « approximées » (basées sur gaussienne) coïncident presque.

Cela formalise l'idée intuitive : un bruit plus fort peut être compensé en augmentant la taille d'échantillon.

Effet du paramètre ϵ


MSE selon ϵ pour chaque cellule du tableau. Les petites proportions (ex. $\pi = 0.167$) possèdent une variance plus élevée. Ainsi, lorsque le bruit Laplace est ajouté, leur MSE augmente plus fortement que celui des cellules ayant une probabilité plus élevée.



Toutes les courbes DP décroissent vers les lignes MLE lorsque ϵ augmente, ce qui confirme que le bruit devient négligeable.

Effet de N

MSE selon N pour un ϵ fixé (0.1). En augmentant N, on réduit la variance statistique naturelle, ce qui rend le bruit DP de plus en plus marginal.



Lorsque N augmente, la variance du MLE décroît comme

$$\frac{1}{N},$$

alors que la variance du bruit DP décroît seulement


$$\text{comme } \frac{1}{N^2 \epsilon^2}.$$

Résultat : à partir d'un certain seuil de N, le bruit DP devient totalement négligeable par rapport à la variabilité naturelle des données

Effet de N

- K décroît rapidement quand ϵ augmente (moins de bruit, moins de correction nécessaire).
- K décroît quand N augmente (le bruit devient moins important relativement).
- Pour $\epsilon = 0.2$ et $N = 200$, on retrouve $K \approx 4$, conformément aux simulations

Figure 5 — Sample Size Correction Factor K



Correction du facteur K – Figure 5
Le PDF fournit une formule approchée du facteur K :

$$K = \frac{\left(\sqrt{1 + 4(c - 1)} + 1\right)^2}{4},$$

où c est le ratio des MSE standardisés :

$$c \approx \frac{\text{MSE}_{DP}}{\text{MSE}_{MLE}}.$$

Comparaison de la puissance statistique pour le test d'indépendance χ^2

Les tableaux présenter ci-dessous comparent la puissance statistique $1 - \beta$ pour le test d'indépendance χ^2 , avec un niveau de confiance $1 - \alpha$.

TABLEAU 3 - La puissance statistique du test d'indépendance χ^2 avec $\alpha = 0,05$, la taille d'échantillon classique $N = 200$, la taille d'échantillon DP $N' = KN$, la taille de simulation $M = 10000$. Les estimations a priori des probabilités de cellules sont $(0,333; 0,167; 0,25; 0,25)$ lorsque les vraies valeurs sont $(2/9, 5/18, 13/36, 5/36)$.

ϵ	0,1	0,2	0,3	0,4	0,5
Sans bruit	0,9835	0,9811	0,9835	0,9824	0,9812
DP	1,0000	0,9999	0,9996	0,9984	0,9958

Pour le tableau 3, le bruit est ajouté aux échantillon sur la base des valeurs issues de la distribution $Mult(2/9, 5/18, 13/36, 5/36)$ qui sont proches des estimations a priori.

On prend $N = 200$ comme taille de l'échantillon d'origine et $N' = KN$ comme taille de l'échantillon corrigé avec le bruit de Laplace.


TABLEAU 4 - La puissance statistique du test d'indépendance χ^2 avec $\alpha = 0,05$, la taille d'échantillon classique $N = 200$, la taille d'échantillon DP $N' = KN$, la taille de simulation $M = 10000$. Les estimations a priori des probabilités de cellules sont $(0,333; 0,167; 0,25; 0,25)$ lorsque les vraies valeurs sont $(0,25; 0,25; 0,167; 0,333)$.

ϵ	0,1	0,2	0,3	0,4	0,5
Sans bruit	0,6727	0,6723	0,6746	0,6776	0,6675
DP	0,9999	0,9865	0,9263	0,8743	0,8242

En revanche, pour le tableau 4, les échantillons sont basés sur des valeurs réelles tirées de la distribution $Mult(0.25, 0.25, 0.167, 0.333)$, qui sont plus éloignées de nos estimation a priori.

Ainsi, les statistique du χ^2 est calculée sur la base des estimations DP.

Résultats




Pour certaines configurations, la puissance du test DP est plus élevée que celle du test classique.

Cela s'explique par le bruit qui peut augmenter la séparation entre H_0 et H_1 .

Dans d'autres configurations, en l'absence dans le tableau 2, la puissance DP diminue fortement lorsque ε est petit.

Recapitulatif

L'étude complète montre un message général clair :



- Le bruit Laplace dégrade la précision lorsque est petit,
- mais cette perte disparaît dès que N augmente suffisamment,
- Le facteur K permet de quantifier exactement l'inflation nécessaire de la taille d'échantillon,

- Les petites cellules (groupes minoritaires) sont les plus affectées,
- le test du χ^2 peut perdre ou gagner en puissance selon la configuration,
- Dans le pire cas, il faut jusqu'à $K = 4$ pour retrouver la puissance originale.

Recapitulatif

CHOIX SOCIÉTAL DU PARAMÈTRE ϵ

ϵ n'est pas seulement un paramètre mathématique. Il détermine l'équilibre entre confidentialité et utilité scientifique.

Un ϵ trop petit détruit la précision et la puissance ; un ϵ trop grand fragilise la protection des individus.

Ce choix doit être discuté au niveau politique et éthique.

COÛT OPERATIONNEL ET ETHIQUE

Atteindre la même puissance statistique sous DP peut nécessiter un échantillon jusqu'à quatre fois plus grand.

Dans un essai clinique, cela signifie : plus de participants, plus de coûts, plus de délais, et plus de personnes exposées à un traitement expérimental. La DP a donc un coût réel qu'il faut explicitement accepter et justifier.

Conclusion générale

La confidentialité différentielle fournit une garantie forte et transparente, mais elle modifie profondément la structure des estimateurs et des tests.

Une application responsable nécessite une collaboration entre statisticiens, cliniciens, experts éthiques et décideurs publics, car les compromis entre confidentialité, précision et équité touchent directement à la validité scientifique et à la justice sociale.

