

① Définition

Soit $\mathcal{X}$ un ensemble typiquement $\mathbb{R}^p$ ou un produit d'ensembles finies.

Définition: Une base de données, ou jeu de données, est un tableau x à n lignes et p colonnes où chaque ligne x_i est à valeurs dans $\mathcal{X}$.

Chaque ligne représente un individu.

les colonnes représentent $\left\{ \begin{array}{l} \text{des variables} \\ \text{des caractéristiques} \end{array} \right.$

Remarque: les valeurs x_{ij} peuvent être aléatoires, mais dans un premier temps, on va plutôt les considérer déterministes.

Définition: la distance de Hamming entre 2 bases de données est définie par:

$$d(x, x') = \text{card}\{i, x_i \neq x'_i\} \text{ où } x_i \neq x'_i \Leftrightarrow \exists j \in \{1, \dots, p\}, x_{ij} \neq x'_{ij}.$$

Deux bases de données sont dites voisines si $d(x, x') \leq 1$.

On considère des $\left\{ \begin{array}{l} \text{algorithmes sur ces bases de données: } f: \mathcal{X}^n \rightarrow \mathcal{Y} \text{ où } \mathcal{Y} \text{ ensemble (muni d'un tribu).} \\ \text{requêtes} \end{array} \right.$

On considèrera aussi le cas où ces algorithmes donnent en sortie une variable aléatoire:

$$[f: \mathcal{X}^n \times (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathcal{Y}, \mathcal{A}')]]$$

Définition: Un algorithme (aléatoire) f est α -différentiellement confidentiel si pour tous jeux de données voisins X, X' et pour tout ensemble (mesurable) A : $\mathbb{P}(f(X) \in A) \leq e^\alpha \mathbb{P}(f(X') \in A)$.

On dira que f est α -DP (Differentially private)

Si les données sont aléatoires, cela s'écrit en termes de probabilité conditionnelle $Q(\cdot | X)$ de $f(X)$ sachant X et $\forall u, u'$ voisins, $\forall A$ mesurable, $Q(A | X = u) \leq e^\alpha Q(A | X = u')$.

Idée: Si on change les données d'un seul individu, cela change très peu les résultats.

Ainsi on ne peut pas vraiment savoir si un individu précis est dans la base ou pas.

- indépendant de la puissance computationnelle de l'adversaire
- pas affecté par la présence d'info auxiliaire.

Notion qui porte sur l'algo lui-même (pas sur les données).

Reste à savoir comment faire de tels algos.

α -paramètre qui mesure le degré de confidentialité (parfois appelé ϵ).

$$e^\alpha \simeq 1 + \alpha \text{ car } \alpha \text{ petit}$$

①

Plus α petit, plus c'est confidentiel.

$$\text{Si } \alpha \rightarrow 0: P(f(X) \in A) = P(f(X') \in A)$$

Même loi de sorte quelle que soit $x, \forall x, f(x)$ à la même loi, très confidentiel, aucun utilité stats

Si α grand, plus de contrainte, on peut garder l'information statistique moins confidentiel.

En pratique, on considère $\alpha \simeq 0,1$ ou $\alpha \simeq 1$.

Extension

Définition: Un algorithme f est (α, δ) -différentiellement confidentiel si:

$$\forall x, x' \text{ voisins}, \forall A \text{ mesurable}, P(f(X) \in A) \leq e^\alpha P(f(X') \in A) + \delta.$$

Pour montrer qu'un algorithme est α -DP, il faut prendre x, x' voisins et comparer la loi de $f(x)$ et celle de $f(x')$:

- si $\mathcal{Y}$ discret, majorer $\frac{P(f(x)=r)}{P(f(x')=r)}$ par $r \in \mathcal{Y}$.
- si $\mathcal{Y}$ continue ($\mathbb{R}$): majorer des densités

Exemple: Randomisation en sciences sociales: Question délicate.

Algorithme: lancer pièce, $\left\{ \begin{array}{l} \text{si pile reponse honnête} \\ \text{si face, relancer: } \left\{ \begin{array}{l} \text{si face "oui"} \\ \text{si pile "non"} \end{array} \right. \end{array} \right.$

$n=1, p=1, \mathcal{X} = \{\text{"oui"}, \text{"non"}\}$ et $\mathcal{Y} = \{\text{"oui"}, \text{"non"}\}$.

$$f(X) = \begin{cases} X & \text{avec probabilité } \frac{1}{2} \text{ (pile)} \\ \text{oui} & \text{avec probabilité } \frac{1}{4} \text{ (face, face)} \\ \text{non} & \text{avec probabilité } \frac{1}{4} \text{ (face, pile)} \end{cases}$$

Cet algorithme est-il α -DP?

- Supposons que $x = \text{"oui"}: P(f(X) = \text{oui}) = \frac{3}{4}$ et $P(f(X) = \text{non}) = \frac{1}{4}$
- Supposons que $x = \text{"non"}: P(f(x) = \text{oui}) = \frac{1}{4}$ et $P(f(X) = \text{non}) = \frac{3}{4}$.

Si x et x' voisins, $\frac{P(f(x)=r)}{P(f(x')=r)} \leq ?$ par $r \in \{\text{oui}, \text{non}\}$.

- 1^{er} cas: $x = x', \frac{P(f(x)=r)}{P(f(x')=r)} = 1, \forall r$
- 2^{ème} cas: $x = \text{oui}, x' = \text{non}$
 $\text{Si } r = \text{oui}, \frac{P(f(\text{oui}) = \text{oui})}{P(f(\text{non}) = \text{oui})} = \frac{3/4}{1/4} = 3$
 $\text{Si } r = \text{non}, \frac{P(f(\text{oui}) = \text{non})}{P(f(\text{non}) = \text{non})} = \frac{1/4}{3/4} = \frac{1}{3}$
- 3^{ème} cas: $x = \text{non}, x' = \text{oui} \Rightarrow \text{idem}$

Finalement, $\frac{P(f(x)=r)}{P(f(x')=r)} \in \{1, \frac{1}{3}, 3\}$, donc ≤ 3 .

Donc f est α -DP pour $\alpha = \ln(3) \approx 0,48$

⑨

Exemple: $n=1, x \in \{0, 1\}$.

Soit $q > \frac{1}{2}$, on considère $f(x) = \begin{cases} x & \text{avec probabilité } q \\ 1-x & \text{avec probabilité } 1-q \end{cases}$

Montre que f est α -DP si $q = \frac{e^\alpha}{1+e^\alpha}$.

II Propriétés

x déterministe

Propriété: Soit f un algorithme α -DP.

Pour $i \in \{1, \dots, n\}$ une ligne quelconque, considérons un test $H_0: "x_i = \theta"$ et $H_1: "x_i = \theta' "$.

Alors tout test de niveau γ à partir des données $f(x)$ à une puissance inférieure à γe^α .

Ainsi, un tel test est très mauvaise puissance très proche du niveau, typiquement 0,05.

Il est quasiment impossible de tester si un individu i précis a telle ou telles valeurs dans la base.

Démonstration: Soit x, x' voisines tel que $x_i = \theta$ et $x'_i = \theta'$.

B événement "le test rejette"

Notons: P_0 la probabilité sous H_0 et P_1 la probabilité sous H_1 .

Le niveau du test est $\gamma = P_0(B)$.


La puissance du test $P_1(B)$.

Par définition de la confidentialité différentielle: $P_1(B) \leq e^\alpha P_0(B)$ car B construit à partir de $f(x)$

ou $f(x')$ du type $f(x) \in A$ ou $f(x') \in A$

Ainsi puissance $\leq e^\alpha \gamma$.

Propriété: Post-processing: Si f est α -DP alors $g \circ f$ est α -DP quelle que soit g mesurable.



16/09/25

Démonstration: Soient X, X' bases de données voisines et soit A ensemble mesurable.

On veut montrer que: $P(g \circ f(X) \in A) \leq e^\alpha P(g \circ f(X') \in A)$.

On sait que $\forall B, P(f(X) \in B) \leq e^\alpha P(f(X') \in B)$ car f α -DP.

Or $g \circ f(X) \in A \Leftrightarrow g(f(X)) \in A$

$\Leftrightarrow f(X) \in g^{-1}(A)$

Il suffit de prendre $B = g^{-1}(A)$.

Donc on a $P(g \circ f(X) \in A) = P(f(X) \in g^{-1}(A))$

$= P(f(X) \in B)$

$\leq e^\alpha P(f(X') \in B)$

⑩

$$\leq e^{\alpha} \cdot P(f(X') \in g^{-1}(A)) \leq e^{\alpha} P(g \circ f(X') \in A).$$

Propriété: Algorithme produit: Soit $f_i: \mathcal{X} \rightarrow \mathcal{Y}$ un algorithme α_i -DP, pour $i=1, \dots, I$.

On suppose que ces algorithmes sont indépendants.

Alors $f: \mathcal{X} \rightarrow \mathcal{Y}_1 \times \dots \times \mathcal{Y}_I$ défini par: $f(x) = (f_1(x), \dots, f_I(x))$ est $(\sum_{i=1}^I \alpha_i)$ -DP.

Démonstration: Soit X, X' voisins.

$$\begin{aligned} \text{Soit } A = A_1 \times \dots \times A_I, P(f(X) \in A) &= P(f_1(X) \in A_1, \dots, f_I(X) \in A_I) \\ &= \prod_{i=1}^I P(f_i(X) \in A_i) \text{ indépendance} \\ &\leq \prod_{i=1}^I e^{\alpha_i} P(f_i(X') \in A_i). \end{aligned}$$

$$\text{Or } \prod_{i=1}^I e^{\alpha_i} = e^{\sum_{i=1}^I \alpha_i}.$$

Propriété: Convexité: Soit f_1 et f_2 deux algorithmes α -DP.

Soit g l'algorithme qui applique f_1 avec probabilité p et f_2 avec probabilité $1-p$.

Alors g est α -DP.

Propriété: Soit $T = f(X)$ où f est α -DP.

Soit Z indépendante de X conditionnellement à T .

Alors $X \rightarrow Z$ définit un algorithme α -DP.

C'est le cas si φ est une densité construite à partir de T et que Z est un échantillon de variables aléatoires tirées de φ .

II Mécanisme de Laplace

Définition: Une variable aléatoire Y suit une loi de Laplace de paramètre $b > 0$

si elle admet pour densité: $f_b(x) = \frac{1}{2b} e^{-|x|/b}$.

On la note: $Y \sim \text{Lap}(b)$.

On a loi centrée: $\mathbb{E}[Y] = 0$ et variance: $\text{Var}(Y) = 2b^2$.



Définition: Soit f une fonction à valeurs dans $\mathcal{Y} = \mathbb{R}^k$.

La sensibilité de f est la quantité: $\Delta(f) = \sup_{d(X, X') \leq 1} \|f(X) - f(X')\|_1$ où $\|z\|_1 = \sum_{i=1}^k |z_i|$.

Par tout algorithme (fonction) f à valeurs dans $\mathcal{Y} = \mathbb{R}^k$, le mécanisme de Laplace est le suivant:

$$M(X) = f(X) + Y \text{ où } Y = (Y_1, \dots, Y_k) \text{ et } Y_d \stackrel{\text{iid}}{\sim} \text{Lap}(b).$$

Théorème: En choisissant $b = \frac{\Delta(f)}{\alpha}$, ce mécanisme est α -DP.

Démonstration: Soit X, X' voisins.

$$\text{Notons } Z = M(X) = f(X) + Y \text{ et } Z' = M(X') = f(X') + Y.$$

14

Z et Z' variables aléatoires continues.

$$\forall A, P(Z \in A) = \int_A f_Z(t) dt.$$

Montrons que $\forall z, f_Z(z) \leq e^\alpha f_{Z'}(z)$.

Exercice: Trouver la densité de $Z, k=1$.

Par la fonction muette: Soit φ mesurable positive:

$$\begin{aligned} E[\varphi(Z)] &= E[\varphi(f(X)+Y)] \\ &= \int \varphi(f(x)+t) f_Y(t) dt = \int \varphi(f(u)) f_Y(u-f(x)) du \end{aligned}$$

④: Changement de variable: $u = f(x) + t \Leftrightarrow t = u - f(x)$
 $\Leftrightarrow dt = du$

$$k=1: \text{la densité de } Z \text{ est donc } u \mapsto f_Y(u-f(X)) = \frac{1}{2b} \exp(-\frac{|u-f(X)|}{b})$$

$$k \geq 1: Z \text{ a pour densité: } z = (z_1, \dots, z_k) \mapsto \prod_{i=1}^k \frac{1}{2b} \exp(-\frac{1}{b} |z_i - f(X)_i|)$$

$$\begin{aligned} \text{Par l'exercice ci-dessus, on a: } \frac{f_Z(z)}{f_{Z'}(z)} &= \frac{\prod_{i=1}^k \frac{1}{2b} \exp(-\frac{1}{b} |z_i - f(X)_i|)}{\prod_{i=1}^k \frac{1}{2b} \exp(-\frac{1}{b} |z_i - f(X')_i|)} \\ &= \exp(\frac{1}{b} \sum_{i=1}^k |z_i - f(X')_i| - |z_i - f(X)_i|). \end{aligned}$$

Or, par inégalité triangulaire, $|z - f(X)| - |z - f(X')| \leq |f(X) - f(X')|$

$$\begin{aligned} \text{Donc, } \frac{f_Z(z)}{f_{Z'}(z)} &\leq \exp(\frac{1}{b} \sum_{i=1}^k |f(X)_i - f(X')_i|) \\ &\leq \exp(\frac{1}{b} \|f(X) - f(X')\|_1) \leq \exp(\frac{1}{b} \Delta(f)). \end{aligned}$$

$$\text{Et } \frac{1}{b} \Delta(f) = \alpha \Leftrightarrow b = \frac{\Delta(f)}{\alpha}.$$

Exemple: Comptage: "combien d'individus satisfont la propriété P".

$f(X) = \text{card}\{i, X_i \text{ vérifie } P\}$ à valeurs dans $\mathbb{N} \subset \mathbb{R}$.

Sensibilité de f ? $\Delta(f) = 1$.

Si X, X' voisins, 1 seul individu différent, $f(X) - f(X') = 0, 1$ ou -1 .

Exemple: Moyenne: $X_i \in \mathbb{R}, f(X) = \frac{1}{n} \sum_{i=1}^n X_i$.

Quelle est sa sensibilité?

$$\begin{aligned} \text{On suppose que } \forall i, X_i \in [a, b], |f(X) - f(X')| &= \frac{1}{n} |X_i - X'_i| \\ &\leq \frac{b-a}{n}. \end{aligned}$$

Exemple: Histogramme: On partitionne l'espace des données en $\bigcup_{j=1}^k B_j$

On a: $f_j(X) = \text{card}\{i; X_i \in B_j\}$

$$= \sum_{i=1}^n \mathbb{1}_{\{X_i \in B_j\}}$$

Exemple de tailles: $B_1 =]0, 1.50 \text{ m}], B_2 =]1.50, 1.60[, \dots$

Sensibilité? $f = (f_1, \dots, f_k)$.

$$\text{On a } \|f(X) - f(X')\|_1 = \sum_{i=1}^k |f_i(X) - f_i(X')|$$

(12)

X et X' ne diffèrent qu'à la ligne j (individu numéroté j)

$\Rightarrow$ seulement deux B_i concernées.

$$|f(X) - f(X')| \leq 0 + \dots + 0 + 1 + 1 + 0 + \dots + 0 \leq 2$$

$$\Rightarrow \text{Donc } \Delta(f) = 2.$$

Par confidentialiser, on ajoute à chaque $f_i(X)$ une variable aléatoire Y_i de loi $\text{Lap}(\frac{\alpha}{2})$.

Théorème: Soit f de sensibilité Δ et M le mécanisme précédent.

Alors avec probabilité $\geq 1 - \delta$, $\|M(X) - f(X)\|_\infty \leq \ln(\frac{k}{\delta}) \cdot \frac{\Delta}{\alpha}$ où $\|z\|_\infty = \max_{1 \leq i \leq k} |z_i|$.

Remarque: Plus α petit, plus $\|M(X) - f(X)\|_\infty$ grand.

Exemple: Histogramme des prénoms: $k = 5000$ prénoms

$\alpha = 1$ avec probabilité 95%?

$$\text{erreur de } \ln(\frac{5000}{0.05}) \times \frac{2}{1} \simeq 23$$

Démonstration: Soit $y > 0$.

$$\text{On a } M(X) - f(X) = Y$$

$$= (Y_1, \dots, Y_k) \text{ avec } Y_i \sim \text{Lap}(b) \text{ indépendants.}$$

$$\text{On a donc } P(\|M(X) - f(X)\|_\infty > y) = P(\|Y\|_\infty > y)$$

$$= P(\max_{1 \leq i \leq k} |Y_i| > y)$$

$$= P(\exists j \in \{1, \dots, k\}, |Y_j| > y)$$

$$= P(\bigcup_{j=1}^k \{|Y_j| > y\})$$

$$\leq \sum_{j=1}^k P(|Y_j| > y) \stackrel{Y_j \text{ même loi que } Y_1}{\leq} k P(|Y_1| > y)$$

$$\text{Et } P(|Y_1| > y) \stackrel{\text{Symétrie loi Laplace}}{=} 2 P(Y_1 > y)$$

$$= 2 \cdot \int_y^\infty f_{Y_1}(t) dt$$

$$= 2 \cdot \int_y^\infty \frac{1}{2b} \exp(-\frac{t}{b}) dt$$

$$= [-\exp(-\frac{t}{b})]_y^\infty = e^{-y/b}$$

$$\text{Donc } P(\|M(X) - f(X)\|_\infty > y) \leq k e^{-y/b}.$$

$$\text{De plus, } k e^{-y/b} \leq \delta \Leftrightarrow e^{-y/b} \leq \frac{\delta}{k}$$

$$\Leftrightarrow e^{y/b} \geq \frac{k}{\delta}$$

$$\Leftrightarrow \frac{y}{b} \geq \ln(\frac{k}{\delta}) \Leftrightarrow y \geq b \ln(\frac{k}{\delta}).$$

$$\text{Or } b = \frac{\Delta}{\alpha}, \text{ donc } y \geq \frac{\Delta}{\alpha} \ln(\frac{k}{\delta}).$$

III Mécanisme exponentiel

Définition: On appelle fonction d'utilité toute fonction $u: X \rightarrow \mathbb{R}$.

(13)

Définition: La sensibilité de u est : $\Delta(u) = \sup_{y \in \mathcal{Y}} \sup_{d(x, x') \leq 1} |u(x, y) - u(x', y)|$.

Ce genre de fonctions u mesure si la sortie y par une entrée x est "utile", préférée par l'utilisateur.

On cherchera souvent u tel que la sortie recherchée soit $f(x) \in \arg\max_{y \in \mathcal{Y}} u(x, y)$

le mécanisme exponentiel est le suivant : $M(X)$ est une variable aléatoire tirée selon la loi suivante :

- * cas $\mathcal{Y}$ discret: $P(M(X) = y) = C_x \cdot \exp(\frac{u(x, y)}{2\Delta(u)})$ où $\frac{1}{C_x} = \sum_{y \in \mathcal{Y}} \exp(\frac{u(x, y)}{2\Delta(u)})$.
- * cas $\mathcal{Y}$ continu: $M(X)$ admet pour densité : $C_x \cdot \exp(\frac{u(x, y)}{2\Delta(u)})$ où $\frac{1}{C_x} = \int_{y \in \mathcal{Y}} \exp(\frac{u(x, y)}{2\Delta(u)}) dy$.

Remarque: le mécanisme de Laplace renvoie toujours une sortie numérique

→ pas toujours de sens

Ici la sortie d'algorithme reste dans l'espace $\mathcal{Y}$ désiré.

Cette sortie est une sortie d'approximation de $\arg\max_{y \in \mathcal{Y}} u(x, y)$.

Théorème: Ce mécanisme est bien α -DP.

Exemple: Une seule colonne, $p = 1$, $X_i \in \{A, B\}$.

On veut savoir s'il y a plus de A que de B.

$\forall y \in \{A, B\}, u(x, y) = \text{card}\{i, x_i = y\}$.

$N_A = u(x, A)$ mesure le nombre d'individus qui valent A.

On a $\Delta(u) = 1$

$N_B = u(x, B) = \text{card}\{i, X_i = B\}$.

$M(X)$ est une variable aléatoire qui vaut :

- * A avec probabilité $p_A = \frac{\exp(\frac{1}{2} N_A)}{\exp(\frac{1}{2} N_A) + \exp(\frac{1}{2} N_B)}$
- * B avec probabilité $p_B = \frac{\exp(\frac{1}{2} N_B)}{\exp(\frac{1}{2} N_A) + \exp(\frac{1}{2} N_B)}$

Exemple: Maximum de vraisemblance: Si X aléatoire de loi $\mathbb{P}_\theta^\alpha$, $V(X, \theta) = p_\theta^\alpha(X)$ vraisemblance

On choisit $u(X, \theta) = V(X, \theta)$ ou $\ln(V(X, \theta))$, $\mathcal{Y} = \Theta$.

$M(X)$ donne une version confidentialisée du max de vraisemblance on sait calculer $\Delta(u)$.

Exemple: Médiane: On peut prendre $u(x, y) = -|\frac{n}{2} - \text{card}\{i, X_i \leq y\}|$ ou $u(x, y) = -\sum_{i=1}^n |x_i - y|$

$$\hookrightarrow \Delta(u) = 1$$

$$\hookrightarrow \Delta(u) = \text{diam}(\mathcal{X})$$

Théorème: Cas $\mathcal{Y}$ fini

$$m := \max_{y \in \mathcal{Y}} u(x, y).$$

$$\mathcal{Y}_m := \arg\max(u(x, y)) = \{y \in \mathcal{Y}, u(x, y) = m\}.$$

$$\text{Avec probabilité } \geq 1 - \delta, \text{ on a } u(x, M(x)) > m - \frac{2\Delta(u)}{\alpha} \ln\left(\frac{\text{card}(\mathcal{Y})}{\text{card}(\mathcal{Y}_m)\delta}\right)$$