

③ Estimation confidentialisée de la distribution: densité et fonction de répartition

On cherche à trouver un mécanisme confidentiel qui transforme $X = (X_1, \dots, X_n)$, indépendants et identiquement distribués de densité f en un autre échantillon confidentialisé $Z = (Z_1, \dots, Z_k)$.

On suppose $x = [0, 1]^p$ (support de f)

1) Mécanisme de Laplace sur les histogrammes

On va partir de l'estimateur par l'histogramme de f .

On a $x = B_1 \cup \dots \cup B_m$ avec B_j hypercube de côté $h = m^{-1/p}$ et de volume $h^p = \frac{1}{m}$.

Notons, pour $1 \leq j \leq m$, $p_j = P(X_1 \in B_j)$, $\hat{p}_j = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_{1,i} \in B_j}$ et $C_j = n \hat{p}_j$.

Estimateur: $\hat{f}_m(x) = \frac{1}{h^p} \sum_{j=1}^m \hat{p}_j \mathbb{1}_{B_j}(x)$.

Bon: $E[\hat{f}_m(x)] = \frac{1}{h^p} \sum_{j=1}^m E[\hat{p}_j] \mathbb{1}_{B_j}(x)$
 $= \frac{1}{h^p} \sum_{j=1}^m p_j \mathbb{1}_{B_j}(x) := f_m(x)$

Bon: f_m est la meilleure approximation de f par une fonction constante par morceaux sur les B_j .

On peut montrer:

Lemme: Supposons f est lipschitzienne: $\forall x, \forall y, |f(x) - f(y)| \leq L \|x - y\|_2$.

Alors: $\int_{[0,1]^p} |f_m(x) - f(x)|^2 dx = O(m^{-2/p})$.

Lemme: On a $E[\int |f_m(x) - f_m(x)|^2 dx] \leq \frac{m}{n}$.

Démonstration: On a: $E[|\hat{p}_j - p_j|^2] = \text{Var}(\hat{p}_j)$
 $= \frac{p_j(1-p_j)}{n} \leq \frac{p_j}{n}$.

Proposition: Si f est lipschitzienne, alors: $E[\int |f_m(x) - f_m(x)|^2 dx] = O(m^{-2/p} + \frac{m}{n})$.

Le risque est minimisé en choisissant $m = cn^{p/2+p}$, qui donne: $E[\int |f_m(x) - f(x)|^2 dx] = O(n^{-2/2+p})$.

Confidentialité: On a: $D_j := C_j + Y_j$, où $Y_j \sim \text{lap}(\frac{2}{\alpha})$, $1 \leq j \leq m$.

$$= \sum_{i=1}^n \mathbb{1}_{X_{1,i} \in B_j} + Y_j$$

On va ensuite rendre ces quantités positives et de somme 1:

$$\hat{q}_j = \frac{D_j^+}{\sum_{k=1}^m D_k^+} \text{ où } a^+ = \max(a, 0) : \text{partie positive}$$

Nouvel estimateur: $\tilde{f}(x) = \frac{1}{h^p} \sum_{j=1}^m \hat{q}_j \mathbb{1}_{B_j}(x)$.

On tire $Z_1, \dots, Z_k$ selon $\tilde{f}$.

Théorème: les mécanismes $(X_1, \dots, X_n) \mapsto \tilde{f}$ et $(X_1, \dots, X_n) \mapsto (Z_1, \dots, Z_n)$ sont α -différentialement confidentiels.

Démonstration: Déjà vu que l'histogramme α -DP + post-processing.

Théorème: On suppose f lipschitzienne.

On choisit $m = cn^{-p/2+p}$.

Alors: $\mathbb{E}[|\hat{f}(x) - f(x)|^2 dx] = O(n^{-2/2+p})$.

Démonstration: On peut montrer que: $\mathbb{E}[|\tilde{f} - f|^2] = O(m^{-2/2+p} + \frac{m}{n} + (\frac{m \ln(m)}{n})^2)$

| ①: dû à la confidentialité

Remarque: On peut généraliser cette approche aux estimateurs par projection: $\hat{f} = \sum_{j=1}^m \hat{\beta}_j \psi_j$ avec $\hat{\beta}_j = \frac{1}{n} \sum_{i=1}^n \psi_j(X_i)$

et ψ_j une base orthonormée, par exemple: base de Fourier.

On prend: $\tilde{\beta}_j = \hat{\beta}_j + \gamma_j$ avec $\gamma_j \sim \text{Lap}(b)$ où $b = \frac{2 \|\sum_{j=1}^m \psi_j\|_\infty}{n^\alpha}$.

Vitesse d'estimation non-paramétrique $n^{-2/2+p+1}$ où γ régularité de f en lien avec ψ_j (ici $p=1$).

Si confidentialité locale (voir + loin), vitesse minimax par estimation de densité est: $(n^\alpha)^{-2/2+p+2}$.

2) Mécanisme exponentielle sur les fonctions de répartition

On note: $\hat{F}_x(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i \leq t}$ et $\hat{F}_z(t) = \frac{1}{k} \sum_{i=1}^k \mathbb{1}_{Z_i \leq t}$.

On a donc: $\mu(X, Z) = -\|\hat{F}_x - \hat{F}_z\|_\infty$.

On tire $Z = (Z_1, \dots, Z_k)$ selon la densité $C \exp(\frac{\alpha \mu(X, \cdot)}{2\Delta})$, où $\frac{1}{C} = \int_{y \in \mathcal{Z}^k} \exp(\frac{\alpha \mu(z, y)}{2\Delta}) dy$

Propriété: Avec $\Delta = \frac{1}{n}$, c'est α -DP

Théorème: Si f bornée et $k = \lceil (\frac{\alpha}{\ln(\|f\|_\infty)})^{2/3} n^{2/3} \rceil$, alors $\|F - \hat{F}_z\|_\infty = O(n^{-1/3})$.

Perte de vitesse car sans confidentialité, F s'estime à vitesse $O(n^{-1/2})$.

08/12/25

② Estimation confidentialisée de paramètres

1) Une méthode par histogrammes par les M-estimateurs

On a $X_1, \dots, X_n$ indépendants et identiquement distribués de densité f .

On cherche à estimer un certain paramètre θ^* .

On suppose $\mathcal{X} = [0, 1]^P$ (support de f).

Dans beaucoup de cas, on peut trouver une fonction de contraste γ , $\gamma: \mathcal{X} \times \Theta \rightarrow \mathbb{R}$ qui vérifie:

$$\theta^* = \arg\min_{\theta \in \Theta} \mathbb{E}[\gamma(X_1, \theta)].$$

Un estimateur naturel est alors: $\hat{\theta}_n = \arg\min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \gamma(X_i, \theta)$.

Exemple: Maximum de vraisemblance

On a $g(x, \theta) = -\ln(f_\theta(x))$ où f_θ densité des X_i sous P_θ .

Alors: $\hat{\theta}_n = \arg \max_{\theta} \frac{1}{n} \sum_{i=1}^n \ln(f_\theta(X_i))$, et $E[g(X_1, \theta)] - E[g(X_1, \theta^*)] = \int \ln\left(\frac{f_\theta}{f_{\theta^*}}\right) f_{\theta^*} = D_{KL}(P_\theta^*, P_\theta) \geq 0$ on peut montrer que

↳ $\forall \theta, E[g(X_1, \theta)] \geq E[g(X_1, \theta^*)]$, minimum en θ^* .

Exemple: $Y = A\theta^* + \varepsilon$, avec $g((y, a), \theta) = (y - a^\top \theta)^2$

↳ estimateur des moindres carrés

Exemple: $g(x, \theta) = |x - \theta|$

↳ Pour estimer la médiane.

On reprend l'histogramme confidentialisé précédent:

$$\hat{f} = \frac{1}{h^p} \sum_{j=1}^m \hat{q}_j \mathbb{1}_{B_j}(x), \text{ où } \hat{q}_j = \frac{D_j}{\sum_{k=1}^m D_k} \text{ avec } D_j = \sum_{i=1}^n \mathbb{1}_{X_i \in B_j} + Y_j \text{ et } Y_j \sim \text{Lap}\left(\frac{2}{\lambda}\right).$$

$$\begin{aligned} \text{On pose } \tilde{\theta}_n &= \arg \min_{\theta} \int g(x, \theta) \hat{f}(x) dx \\ &= \arg \min_{\theta} \sum_{j=1}^m \hat{q}_j \int_{B_j} g(x, \theta) dx \end{aligned}$$

| $\odot$: peut être remplacé par $g(c_j, \theta) h^p$ où c_j centre de B_j .

Théorème: le mécanisme $X \rightarrow \tilde{\theta}_n$ est α -DP.

Théorème: Lei (2011): Sous des hypothèses de régularité et de convexité, et si $h = \left(\frac{\sqrt{\ln(n)}}{n}\right)^{2/p+2}$, alors avec grande probabilité: $|\tilde{\theta}_n - \theta^*| = O(n^{-1/2} + \left(\frac{\sqrt{\ln(n)}}{n}\right)^{2/p+2})$.

$$\text{Si } p=1, \left(\frac{\sqrt{\ln(n)}}{n}\right)^{2/3} = o(n^{-1/2})$$

Si $p > 2$, perte de vitesse.


Exemple: les hypothèses du théorème sont vérifiées dans le cas de la régression logistique: $(X_i, Y_i) \in [0, 1] \times \{0, 1\}$ sachant X_i et $Y_i \sim \mathcal{B}\left(\frac{e^{\theta x_i}}{1 + e^{\theta x_i}}\right)$.

On a donc $g((x, y), \theta) = -\theta xy + \ln(1 + e^{\theta x})$.

2) Mécanisme d'aggrégation pour les estimateurs classiques

Méthode "subsample - and - aggregate", on partitionne l'échantillon $X_1, \dots, X_n$ en k blocs de telle sorte que

$$\{X_1, \dots, X_n\} = \{u_1, \dots, u_k\}$$



Théorème: Soit $H: D^k \rightarrow E$ un mécanisme α -DP.

Alors quelles que soient $g_1, \dots, g_k$ le mécanisme $X \rightarrow H(g_1(u_1), \dots, g_k(u_k))$ est α -DP.

Démonstration: Soit X et X' voisins.

Ils ne diffèrent que pour un individu i_0 .

Cet individu n'appartient qu'à un seul bloc, disons j_0 , donc $v = (g_1(u_1), \dots, g_k(u_k))$ et $v' = (g_1(u'_1), \dots, g_k(u'_k))$ sont voisins (ne diffèrent que par v_{j_0}).

Donc $\forall A, P(M(v) \in A) \leq e^\alpha P(M(v') \in A)$.

On cherche à estimer $\theta \in \mathbb{R}$.

On suppose $\text{diam}(\mathbb{H}) = \sup_{\theta, \theta' \in \mathbb{H}} \|\theta - \theta'\| < \infty$, on connaît une méthode d'estimation $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$.

On suppose $\mathbb{H} \subset \mathbb{R}$ (dimension 1)

On divise X en k blocs, on suppose n divisible par k , $n = tk$, avec :

$$\begin{cases} \mu_1 = (X_1, \dots, X_k) \\ \mu_2 = (X_{k+1}, \dots, X_{2k}) \\ \vdots \\ \mu_k = (X_{(k-1)k+1}, \dots, X_{tk}) \end{cases}$$

On a donc $\tilde{\theta} = \frac{1}{k} \sum_{i=1}^k \hat{\theta}(X_{(i-1)k+1}, \dots, X_{ik}) + Y$ où $Y \sim \text{Lap}(\frac{\text{diam}(\mathbb{H})}{k^\alpha})$.

Théorème: Ce procédé est α -DP.

Démonstration: Théorème précédent + mécanisme Laplace avec fonction moyenne

Proposition: Notons $b_k(\theta)$ le biais et $v_k(\theta)$ la variance de $\hat{\theta}$ dans le cas de n observations.

Alors : $\mathbb{E}[|\tilde{\theta} - \theta|^2] = b_k^2(\theta) + \frac{1}{k} v_k(\theta) + 2 \cdot \frac{\text{diam}(\mathbb{H})^2}{k^2 \alpha^2}$ où $t = \frac{n}{k}$.

Il faut $k \gg \alpha$ et t assez grand.

Théorème: Supposons $nv_n(\theta) \xrightarrow{n \rightarrow \infty} \sigma_0^2$ et $b_n(\theta) = o(n^{-\beta})$ avec $\beta > 1$.

On choisit $k = k_n$ tel que : $\alpha^{-1} n^{1/2} \ll k \ll n^{1-1/2\beta}$.

Alors : $\mathbb{E}[|\tilde{\theta} - \theta|^2] = \frac{\sigma_0^2}{n} (1 - o(1))$ et $\sqrt{n}(\tilde{\theta} - \theta) \xrightarrow{n \rightarrow \infty} \mathcal{N}(0, \sigma_0^2)$.

3) Minimisation du risque empirique et mécanisme exponentiel

On s'intéresse à la minimisation de $\mathcal{L}(X, \theta) = \frac{1}{n} \sum_{i=1}^n \ell(X_i, \theta)$ par $\theta \in \mathbb{H} (\subset \mathbb{R}^p)$ ensemble convexe et borné, et par la fonction de perte

On suppose $\theta \mapsto \ell(X, \theta)$ convexe lipschitzienne de constante L .

Exemple: Médiane, k -mean, régression linéaire

On tire $\tilde{\theta}$ selon la loi $C \exp\left(\frac{-\alpha}{4L \text{diam}(\mathbb{H})} \mathcal{L}(X, \theta)\right)$ où C est une constante de normalisation.

Théorème: Ce procédé est α -DP.

Théorème: Soit θ^* le vrai minimiseur de $\mathcal{L}(X, \cdot)$.

On a donc : $\mathbb{E}[\mathcal{L}(X, \tilde{\theta}) - \mathcal{L}(X, \theta^*) | X = x] = O\left(\frac{pL \text{diam}(\mathbb{H})}{\alpha}\right)$

19

Remarque: Dans le cas de la régression linéaire, nombreuses méthodes analysées par Wang (2018): $Y = H\theta + \varepsilon$.

Par exemple, la méthode de perturbations des statistiques exhaustives: $\hat{\theta} = (H^T H)^{-1} H^T Y$, remplacé en confidentialisant $H^T H$ et $H^T Y$.

4) Risque empirique régularisé

On s'intéresse à la minimisation de $\mathcal{J}(X, \theta) = \frac{1}{n} \sum_{i=1}^n \ell(X, \theta) + \lambda r(\theta)$.

Méthode 1: Perturbation de sortie: On a $\tilde{\theta} = \arg \min \mathcal{J}(X, \theta) + \gamma$ où γ tiré selon la densité $y \mapsto \exp(-\|y\|_2/b)$.

On obtient sous hypothèses: $\mathcal{J}(X, \tilde{\theta}) - \mathcal{J}(X, \theta^*) = O(\frac{\rho^2 \ln^4(\rho)}{\lambda r^2 d^2})$.

Méthode 2: Perturbation d'objectif: On a $\tilde{\theta} = \arg \min \mathcal{J}(X, \theta) + \frac{\gamma}{n} Y^T \theta$ où γ tiré selon la densité $C \cdot \exp(-\|y\|_2/b)$.

Sous l'hypothèses sur ℓ, r , on obtient la même vitesse.

Mais les simulations numériques sont meilleures pour la méthode 2.

15/12/25

10 Étude minimax par la confidentialisé locale

Jusque là, on a supposé que la statisticienne a le droit d'utiliser toutes les données pour faire ses algorithmes confidentiels.

↳ Problème.

On va plutôt confidentialiser chaque données X_i .

Définition: Un algorithme (aléatoire) $f = (f_1, \dots, f_n)$ est α -localement différentiellement confidentiel si:

$$\forall 1 \leq i \leq n, \text{ pour tous } X_i, X'_i, \forall A_i \text{ mesurable, } \mathbb{P}(f_i(X_i) \in A_i) \leq e^\alpha \mathbb{P}(f_i(X'_i) \in A_i).$$


on dira que f est α -LDP.

$$\text{Avant } \forall i, \mathbb{P}(f(X_1, \dots, X_i, \dots, X_n) \in A) \leq e^\alpha \mathbb{P}(f(X_1, \dots, X_i, \dots, X_n) \in A).$$


l'algorithme f_i n'utilise les données que d'un seul utilisateur.

Exemple: Randomisation en sciences sociales rentre en fait dans ce cadre:

DP "globale":



DP "locale":



la LDP a été en particulier déployée par:

- Google (2016): Algo RAPPOR testé sur Chrome

- Apple (2017): algorithme Private Count Mean Sketch : emojis préférés.

Cadre minimax

On suppose qu'on veut estimer un paramètre θ .

Risque quadratique minimax usuel: $\inf_{\hat{\theta}} \sup_{P \in \mathcal{P}} \mathbb{E}_P [\|\hat{\theta}(X_1, \dots, X_n) - \theta\|^2]$.

Maintenant, on va noter $\mathcal{Q}_\alpha$ l'ensemble des probabilités conditionnelles vérifiant la condition α -LDP:

$$\forall i, \forall x, \forall x', \forall A_i, \mathbb{P}(Z_i \in A_i | X_i = x) \leq e^\alpha \mathbb{P}(Z_i \in A_i | X_i = x').$$

le risque minimax α -confidentiel est $\mathcal{M}_n(\alpha, \mathcal{P}) = \inf_{\hat{\theta}} \sup_{P \in \mathcal{Q}_\alpha} \mathbb{E}_{X \sim P, Z | X \sim P} [\|\hat{\theta}(Z_1, \dots, Z_n) - \theta\|^2]$.

Estimation de la moyenne en dimension 1:

On a $\mathcal{P} = \{P \text{ lois tel que } \mathbb{E}_P[|X|^2] \leq 1\}$ (lois à variance bornée).

On estime $\mathbb{E}[X]$:

- sans confidentialité risque minimax $\frac{1}{n}$
- avec confidentialité: $\mathcal{M}_n(\alpha, \mathcal{P}) \asymp \min(1, \frac{1}{\sqrt{n\alpha^2}})$ ou $\mu_{n,\alpha} \asymp \nu_{n,\alpha} \Leftrightarrow \exists c > 0, \exists C > 0, c\mu_{n,\alpha} \leq \nu_{n,\alpha} \leq C\mu_{n,\alpha}$.


Vitesse dégradée

Exemple: Estimateur qui atteint cette vitesse $\frac{1}{\sqrt{n\alpha^2}}$ $\rightarrow$ mécanisme de Laplace tronqué:

On définit: $\forall T > 0$, la fonction de troncation:

$$[\cdot]_T : \mathbb{R} \rightarrow [-T, T]$$

$$x \mapsto [x]_T = \begin{cases} -T & \text{si } x < -T \\ x & \text{si } -T \leq x \leq T \\ T & \text{si } x > T. \end{cases}$$



On pose $b = \frac{2T}{\alpha}$ et $Z_i = [X_i]_T + Y_i$ avec $Y \sim \text{Lap}(b)$ pour $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n Z_i$.

Pour avoir la bonne vitesse, il faut prendre $T = (n\alpha^2)^{1/4}$.

Estimation de la moyenne en dimension p:

On a $X = (X^{(1)}, \dots, X^{(p)})$, $p \leq n$ et $\mathcal{P} = \{P \text{ lois tel que presque sûrement } \sum_{k=1}^p |X^{(k)}|^2 \leq 1\}$

Vitesse en non confidentiel: $\frac{1}{n}$

Vitesse en α -LDP: $\mathcal{M}_n(\alpha, \mathcal{P}) = \min(1, \frac{p}{n\alpha^2})$ (minima)

On peut montrer le mécanisme de Laplace est sous-optimal ($1, \frac{p^2}{n\alpha^2}$).

Algorithme optimal ici:

- On choisit $\tilde{X} = \begin{cases} X & \text{avec proba: } 1 - \frac{\|X\|_2}{2} \\ -X & \text{avec proba: } \frac{1}{2} - \frac{\|X\|_2}{2} \end{cases}$
- On tire $Y \sim \mathcal{B}(\frac{e^\alpha}{1+e^\alpha})$

(2.4)

Si $Y=1$: On choisit Z uniforme sur $S_1 = \{z \in \mathbb{R}^p, \|z\|_2 = R, \langle z, \bar{X} \rangle > 0\}$ avec $R = \frac{e^{\alpha} + 1}{e^{\alpha} - 1} \cdot \frac{\sqrt{p}}{2} \cdot p \frac{\Gamma(p/2 + 1)}{\Gamma(p/2 + 1)}$.

Si $Y=0$: On choisit Z uniforme sur $S_0 = \{z \in \mathbb{R}^p, \langle z, \bar{X} \rangle \leq 0, \|z\|_2 = R\}$

On a: $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n Z_i$.

Grande dimension et parcimonie

Soit $p \geq n$, par simplifier, on considère des vecteurs 1-sparse (une seule coordonnée non-nulle).

On a $\mathcal{P} = \{P \text{ lois tel que presque sûrement: } |X^{(k)}| \leq r \text{ et } \|\mathbb{E}_P[X]\|_0 \leq 1\}$.

Vitesse en non-confidentiel: $\frac{r^2 \ln(p)}{n}$

Vitesse en α -LDP: $\mathcal{H}_n(\alpha, \mathcal{P}) \asymp \min(r^2, r^2 \frac{p \ln(2p)}{n \alpha^2})$

Non-paramétrique, estimation de densité.

Vitesse non-confidentielle: $n^{-2p/2p+1}$

Vitesse α -LDP: $(n \alpha^2)^{-2p/2p+2}$