

L'EQUITÉ DANS LA MACHINE (FAIRML)

Du réalisme métrologique au jugement exercé



Basé sur l'article de : Bilel Benbouzid (2022)
ALVES, FAGE, PINA & SARRI

La transformation politique de la statistique

Le constat :

Le Machine Learning (ML) ne peut plus ignorer les enjeux sociaux.

Le conflit :

- Statisticien classique : Recherche le "réalisme métrologique" (mesure neutre, sans trace politique) ;
- Data Scientist en FairML : Contraint d'adopter une posture "constructiviste" (la machine agit sur le réel)

Thèse :

L'algorithme n'est plus un simple outil de calcul, c'est un acteur politique.



La rencontre entre Informatique et Philosophie

Origine : Le domaine vient des recherches sur la Privacy (vie privée) .

Les figures pionnières :

Helen Nissenbaum (Philosophe) : Le biais comme problème de valeurs



Cynthia Dwork (Informaticienne) : Differential Privacy et mathématisation de l'équité



Latanya Sweeney (Informaticienne) : Dénonciation du racisme structurel (pub en ligne)



Lieu clé : Conférence ACM FAccT (Fairness, Accountability, Transparency).

Du biais méthodologique au biais politique

Approche Classique:

- Biais = Erreur systématique / Écart à la vérité terrain (Ground Truth).
- Objectif : Éliminer le biais pour être objectif.



Problème:

- La "vérité terrain" est elle-même biaisée par la société
- Biais = Norme sociale ou injustice structurelle .
- Le biais devient un enjeu politique

Exemple AMAZON:

- Algorithme de tri de CV
- Données issues de recrutements passés
- Reproduction d'inégalités de genre

Boucles de rétroaction, FairML

Influence du biais :

- Boucles de rétroaction (feedback loop)
- Construction algorithmique de la réalité

Les Algorithmes une solution:

- Les biais ne peuvent pas être totalement éliminés
- Mais ils peuvent être rendus visibles
- Algorithmes = nouveaux outils de transparence
- FairML : détecter pour prévenir la discrimination



Les 3 approches de l'équité

Equité de groupe

L'approche de groupe vise à garantir un traitement similaire entre groupes sociaux en comparant leurs taux d'erreur ou de succès.

Exemple :

un algorithme de recrutement devrait retenir autant de femmes que d'hommes à compétences égales.

Limite :

cette égalité statistique peut masquer des injustices individuelles et ne pas refléter la complexité des situations réelles

L'équité individuelle

L'équité individuelle vise à garantir que deux personnes similaires reçoivent des décisions similaires.

Exemple :

deux candidats au crédit avec un parcours équivalent devraient obtenir la même prédiction

Limite :

il est difficile de définir ce que signifie réellement "être similaire", car cela dépend de choix et critères souvent subjectifs

L'équité causale

L'équité causale cherche à savoir si une caractéristique sensible a causé une décision injuste en modélisant les relations de cause à effet

Exemple :

vérifier si un refus de prêt vient réellement du revenu ou indirectement de l'origine sociale

Limite :

ces modèles sont complexes, reposent sur des hypothèses fortes et leur validité est difficile à démontrer.

Comment choisir entre une métrique qui privilégie l'égalité des chances et une autre qui optimise l'efficacité du modèle ?

Cadre

On considère :

- une variable cible binaire $Y \in \{0, 1\}$;
- un attribut de groupe $A \in \{1, 2\}$;
- un score prédictif $S \in [0, 1]$ interprété comme une probabilité.

Les trois propriétés

1. **Calibration intra-groupe.** Pour chaque groupe t et chaque valeur de score s ,

$$\Pr(Y = 1 \mid S = s, A = t) = s.$$

2. **Balance pour la classe négative.**

$$\mathbb{E}[S \mid Y = 0, A = 1] = \mathbb{E}[S \mid Y = 0, A = 2].$$

3. **Balance pour la classe positive.**

$$\mathbb{E}[S \mid Y = 1, A = 1] = \mathbb{E}[S \mid Y = 1, A = 2].$$

théorème (Kleinberg, Mullainathan et al., 2016)

Si un score S satisfait simultanément les trois propriétés ci-dessus, alors nécessairement :

1. soit le modèle est *parfait*, c'est-à-dire qu'il ne fait aucune erreur, auquel cas $S \in \{0, 1\}$ et $S = Y$ pour tout individu ;
2. soit les *taux de base* des deux groupes sont égaux :

$$\Pr(Y = 1 \mid A = 1) = \Pr(Y = 1 \mid A = 2).$$

En dehors de ces deux cas, aucune fonction de score ne peut satisfaire simultanément les trois conditions.



trois grandes familles d'équité de groupe

Indépendance (Parité démographique)

Le modèle doit donner la même proportion de prédictions positives dans chaque groupe, indépendamment de leurs caractéristiques

Exemple :

Si 30 % des candidats sont retenus, alors 30 % des femmes et 30 % des hommes doivent l'être aussi.

Limite :

risque de discrimination positive

$$\Pr(\hat{Y} = 1 \mid A = 1) = \Pr(\hat{Y} = 1 \mid A = 0)$$

Séparation (Equality of Opportunity)

Les personnes réellement positives doivent avoir la même probabilité d'être correctement classées, quel que soit leur groupe.

Exemple :

Deux bons candidats à un prêt ($Y=1$) doivent avoir la même chance d'obtenir un crédit, qu'ils soient d'un groupe favorisé ou non.

Limite :

Demande d'accéder aux valeurs réelles Y , et peut diminuer la performance globale du modèle.

$$\Pr(\hat{Y} = 1 \mid Y = 1, A = 0) = \Pr(\hat{Y} = 1 \mid Y = 1, A = 1)$$

Suffisance (Calibration)

Pour un même score prédictif, la probabilité réelle de succès doit être la même dans chaque groupe.

Exemple :

Si le modèle attribue un score de 0.7, alors 70 % des personnes de chaque groupe doivent effectivement réussir

Limite :

Bonne mesure de performance, mais insuffisante pour corriger des discriminations structurelles entre groupes

$$\Pr(Y = 1 \mid S = s, A = 0) = \Pr(Y = 1 \mid S = s, A = 1)$$

Pourquoi Hardt défend l'égalité des opportunités?

La parité démographique est trop contraignante.
Elle impose une égalité des prédictions positives entre groupes sans tenir compte du vrai label.

→ Cela force parfois le modèle à faire plus d'erreurs.

$$\Pr(\hat{Y} = 1 \mid A = 0) = \Pr(\hat{Y} = 1 \mid A = 1)$$

L'égalité des opportunités se concentre sur les "réellement positifs"

On ajuste les seuils par groupe pour :

- maximiser les vrais positifs,
- maintenir l'égalité entre groupes,
- sans sacrifier la précision globale.

$$\Pr(\hat{Y} = 1 \mid Y = 1, A = 0) = \Pr(\hat{Y} = 1 \mid Y = 1, A = 1)$$

D'après lui, l'égalité des opportunités maximise mieux l'utilité du modèle que la parité démographique : Sa posture est politique

- La calibration n'est pas une intervention de justice sociale : elle relève simplement de la précision attendue d'un modèle, pas d'un choix moral.
- L'égalité des opportunités engage réellement le modélisateur et l'utilisateur dans la compréhension et le réglage du modèle.
- La parité statistique peut aller contre l'équité : elle impose de traiter différemment les groupes pour compenser des écarts, au risque d'une forme de discrimination positive non méritocratique.



Limites de l'équité de groupe : émergence de l'équité individuelle

fairness gerrymandering

en cherchant à réduire les discriminations entre grands groupes (ex. hommes/femmes), on peut créer de nouvelles discriminations au niveau de sous-groupes plus fins (ex. femmes âgées d'une classe sociale précise).

Comme l'écrivent Kearns et Roth, un modèle peut « unfairly treat disabled gay Hispanic women over age fifty-five making less than \$50,000 annually » tout en respectant formellement l'équité groupe par groupe

au lieu de comparer des groupes, on impose que des individus “similaires” soient traités de manière similaire, même si cette approche est souvent difficile à spécifier et à interpréter

Pourquoi l'équité de groupe peut discriminer des sous-groupes

Équité imposée sur un seul attribut A :

$$\phi(\hat{Y}, Y \mid A = 0) = \phi(\hat{Y}, Y \mid A = 1)$$

Mais pour un sous-groupe défini par plusieurs attributs $(A_1, A_2, \dots, A_k)$:


$$\phi(\hat{Y}, Y \mid A_1 = a_1, \dots, A_k = a_k) \neq \phi(\hat{Y}, Y \mid \text{reste})$$

Ainsi, même si toutes les égalités marginales sont respectées :


$$\phi(\hat{Y}, Y \mid A_i = 0) = \phi(\hat{Y}, Y \mid A_i = 1) \quad \text{pour tout } i,$$




Inférence causale




(a)




(b)



(c)



(d)



(e)



In Level 2, we postulate that a latent variable: a student's **knowledge** (K), affects GPA, LSAT, and FYA scores. The causal graph corresponding to this model is shown in Figure 2, (**Level 2**). This is a short-hand for the distributions:

$$\begin{aligned} \text{GPA} &\sim \mathcal{N}(b_G + w_G^K K + w_G^R R + w_G^S S, \sigma_G), \\ \text{LSAT} &\sim \text{Poisson}(\exp(b_L + w_L^K K + w_L^R R + w_L^S S)), \end{aligned}$$

$$\begin{aligned} \text{FYA} &\sim \mathcal{N}(w_F^K K + w_F^R R + w_F^S S, 1), \\ K &\sim \mathcal{N}(0, 1) \end{aligned}$$

We perform inference on this model using an observed training set to estimate the posterior distribution of K . We use the probabilistic programming language Stan [34] to learn K . We call the predictor constructed using K , **Fair** K .





Table 1: Prediction results using logistic regression. Note that we must sacrifice a small amount of accuracy to ensuring counterfactually fair prediction (Fair K , Fair Add), versus the models that use unfair features: GPA, LSAT, race, sex (Full, Unaware).

	Full	Unaware	Fair K	Fair Add
RMSE	0.873	0.894	0.929	0.918

in Figure 2, (**Level 3**), and is expressed by:

$$\begin{aligned} \text{GPA} &= b_G + w_G^R R + w_G^S S + \epsilon_G, \quad \epsilon_G \sim p(\epsilon_G) \\ \text{LSAT} &= b_L + w_L^R R + w_L^S S + \epsilon_L, \quad \epsilon_L \sim p(\epsilon_L) \\ \text{FYA} &= b_F + w_F^R R + w_F^S S + \epsilon_F, \quad \epsilon_F \sim p(\epsilon_F) \end{aligned}$$

We estimate the error terms ϵ_G, ϵ_L by first fitting two models that each use race and sex to individually predict GPA and LSAT. We then compute the residuals of each model (e.g., $\epsilon_G = \text{GPA} - \hat{Y}_{\text{GPA}}(R, S)$). We use these residual estimates of ϵ_G, ϵ_L to predict FYA. We call this *Fair Add*.

Accuracy. We compare the RMSE achieved by logistic regression for each of the models on the test set in Table 1. The **Full** model achieves the lowest RMSE as it uses race and sex to more accurately reconstruct FYA. Note that in this case, this model is not fair even if the data was generated by one of the models shown in Figure 2 as it corresponds to Scenario 3. The (also unfair) **Unaware** model still uses the unfair variables GPA and LSAT, but because it does not use race and sex it cannot match the RMSE of the **Full** model. As our models satisfy counterfactual fairness, they trade off some accuracy. Our first model **Fair K** uses weaker assumptions and thus the RMSE is highest. Using the Level 3 assumptions, as in **Fair Add** we produce a counterfactually fair model that trades slightly stronger assumptions for lower RMSE.



Vers l'objectivité du “Jugement Exercé”

Bilan :

Le FairML s'éloigne du réalisme naïf.

Nouvelle Objectivité :

- Non plus la "neutralité" (impossible).
- Mais la "partialité raisonnable" ou le "jugement exercé" .

Message final :

Pour être scientifique, le Data Scientist doit expliciter ses choix politiques et assumer un point de vue situé .



MERCI

