

Chapitre 3: Dépassement de seuil

X variable aléatoire.

On fixe u (seuil), on s'intéresse à la modélisation de la loi de $X-u$ sachant que $X > u$.

① Mean Excess Function (dépassement moyen)

On a $e(u) = \mathbb{E}[X-u | X > u]$.

Propriété: On a $e(u) = \frac{\int_u^\infty \bar{F}(t) dt}{\bar{F}(u)}$ où $\bar{F}(t) = 1 - F(t)$ avec F fonction de répartition de X .

Démonstration: On a: $\mathbb{E}[X-u | X > u] = \frac{\mathbb{E}[(X-u) \mathbb{1}_{X > u}]}{\mathbb{P}(X > u)}$.

Par définition: $\bar{F}(u) = \mathbb{P}(X > u)$


On a alors: $\mathbb{E}[(X-u) \mathbb{1}_{X > u}] = \int (x-u) \mathbb{1}_{x > u} dP^X(x)$

$$= \int \left(\int_u^x dt \right) \mathbb{1}_{x > u} dP^X(x)$$

$$= \int_u^\infty \left(\int_t^\infty dP^X(x) \right) dt$$

$$= \int_u^\infty \mathbb{P}(X > t) dt = \int_u^\infty \bar{F}(t) dt$$

On a montré que $e(u) = \frac{\int_u^\infty \bar{F}(t) dt}{\bar{F}(u)}$



Estimateur de $e(u)$: $\mathbb{E}[X-u | X > u] = \frac{\mathbb{E}[(X-u) \mathbb{1}_{X > u}]}{\mathbb{E}[\mathbb{1}_{X > u}]}$.

(X_i) indépendants et identiquement distribués de même loi que X

On peut estimer $e(u)$ par: $e_n(u) = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - u) \mathbb{1}_{X_i > u}}{\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i > u}} = \frac{\sum_{i=1}^n (X_i - u) \mathbb{1}_{X_i > u}}{\sum_{i=1}^n \mathbb{1}_{X_i > u}} \xrightarrow[n \rightarrow \infty]{\text{Lévy}} e(u)$.

Mean excess plot: graphe $u \mapsto e_n(u)$ par $u = X_{(k,n)}$, $k = 1, \dots, n$

$(X_{(k,n)})$ statistique d'ordre de l'échantillon $(X_i)_{i=1, \dots, n}$.

↳ On trace les points $(X_{(n-k,n)}, e_n(X_{(n-k,n)}))_{k=1, \dots, n}$, avec $e_n(X_{(n-k,n)}) = \frac{1}{k} \sum_{j=1}^k [X_{(n-k+j,n)} - X_{(n-k,n)}]$.

Si $u = X_{(n-k,n)}$ il y a k variables supérieures à u .

Exemples: Allure de $u \mapsto e(u) = \frac{\int_u^\infty \bar{F}(t) dt}{\bar{F}(u)}$ avec $\bar{F}(t) = 1 - F(t)$.

a) loi exponentielle de paramètre λ

b) loi de Pareto

c) loi uniforme sur $[0, 1]$.

a) $\bar{F}(t) = e^{-\lambda t}$

On a alors: $e(u) = \frac{\int_u^\infty e^{-\lambda t} dt}{e^{-\lambda u}}$, donc taille $\xi = 0$.

$$= \frac{-\frac{1}{\lambda} [e^{-\lambda t}]_u^\infty}{e^{-\lambda u}} = \frac{1}{\lambda}$$


b) On a $\bar{F}(t) = \frac{1}{t^\alpha}$ avec $t \geq 1$ et $\alpha > 1$

Donc : $e(u) = \frac{\int_u^\infty \frac{1}{t^a} dt}{\frac{1}{u^a}}$, donc $0 < \xi = \frac{1}{2} < 1$.

$$= \frac{[-\frac{1}{(a-1)t^{a-1}}]_u^\infty}{\frac{1}{u^a}} = \frac{u}{(a-1)}$$

c) $\bar{F}(x) = \begin{cases} 1-x & \text{si } x \in [0,1] \\ 0 & \text{si } x > 1 \end{cases}$

On a alors : $e(u) = \frac{\int_u^1 (1-t) dt}{\frac{1-u}{1-u}} = \frac{[-(1-t)^2/2]_u^1}{1-u} = \frac{1}{2}(1-u)$, donc $u \in]0,1[$ et $\xi < 0$.



II Lois de Pareto généralisées (GPD : Generalized Pareto Distribution)

Définition: Une variable Z a une loi GPD si la fonction de répartition de Z est :

$$G_\xi(x) = \begin{cases} 1 - (1 + \xi x)^{-1/\xi} & \text{si } \xi \neq 0 : \begin{cases} \text{si } \xi > 0 & \text{alors } x \geq 0 \\ \text{si } \xi < 0 & \text{alors } 0 \leq x \leq -1/\xi \end{cases} \\ 1 - e^{-x} & \text{si } \xi = 0 \end{cases}$$

Pour $\xi > 0$, $G_\xi(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - (1 - \xi x)^{-1/\xi} & \text{si } x \geq 0 \end{cases}$

Pour $\xi < 0$, $G_\xi(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - (1 + \xi x)^{-1/\xi} & \text{si } 0 \leq x \leq -\frac{1}{\xi} \\ 1 & \text{si } x > -\frac{1}{\xi} \end{cases}$

Pour $\xi = 0$, $G_0(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 - e^{-x} & \text{si } x \geq 0 \end{cases}$ et $G_0(x) = \lim_{\xi \rightarrow 0} G_\xi(x)$.

On définit $G_{\xi,a,b}$ par : $G_{\xi,a,b}(x) = G_\xi(\frac{x-b}{a})$, avec :

- ξ : shape parameter
- a : scale parameter
- b : location parameter

Et $G_{\xi,a,b}$ fonction de répartition de $Z = aY + b$ où Y a pour fonction de répartition G_ξ .

Et $G_{\xi,1,0} = G_\xi$ et $G_{\xi,a} = G_{\xi,a,0}$.

III Caractérisation des domaines d'attraction

X variable aléatoire de fonction de répartition F .

u seuil fixé, avec $F_u(x) = \mathbb{P}(X-u > x | X > u)$ où F_u est la fonction de répartition du seuil u .

Théorème: Pickands: $F \in DA(H_\xi)$ si et seulement si $\lim_{u \rightarrow x_F} \sup_{u < x < x_F - u} |F_u(x) - G_{\xi,a(u)}(x)| = 0$ pour a fonction positive.

Interprétation: Si u (seuil) est grand, $F_u(x) \stackrel{(1)}{\approx} G_{\xi,a(u)}(x) \stackrel{(2)}{=}$ pour $X \in DA(H_\xi)$

①: Distribution de $X-u$ sachant $X > u$

②: GPD de paramètre ξ et $a(u)$ (scaling) et $b=0$.

Théorème: Si X suit une loi GPD $G_{\xi,a}$ avec $\xi < 1$, alors pour $u < x_F$, $e(u) = \frac{a + \xi u}{1 - \xi}$

28 Pour une loi GPD, $G_{\xi, a}$, le graphe $u \mapsto e(u)$ droite de pente $\frac{\xi}{1-\xi}$:
$$\begin{cases} \text{positive si } \xi > 0 \text{ (avec } \xi < 1) \\ \text{négative si } \xi < 0 \\ 0 \quad \text{si } \xi = 0 \end{cases}$$

Démonstration: On a $\bar{F}(t) = 1 - G_{\xi, a}(t) = \begin{cases} (1 + \xi \cdot \frac{t}{a})^{-1/\xi} & \text{si } \xi \neq 0 \\ e^{-t/a} & \text{si } \xi = 0 \end{cases}$

De plus, $e(u) = \frac{\int_u^\infty \bar{F}(t) dt}{\bar{F}(u)}$

$$\begin{aligned} &= \frac{\int_u^\infty (1 + \xi \cdot \frac{t}{a})^{-1/\xi} dt}{(1 + \xi \cdot \frac{u}{a})^{-1/\xi}} \\ &= \frac{[1/(-1/\xi + 1) \cdot (1 + \xi \cdot \frac{t}{a})^{-1/\xi + 1} \cdot \frac{a}{\xi}]_u^\infty}{(1 + \xi \cdot \frac{u}{a})^{-1/\xi}} \\ &= \frac{1}{1/\xi - 1} \cdot (1 + \xi \cdot \frac{u}{a}) \cdot \frac{a}{\xi} \\ &= \frac{a(1 + \xi \cdot \frac{u}{a})}{1 - \xi} = \frac{a + \xi u}{1 - \xi} \text{ pour } \xi > 0 \text{ et } \xi < 1 \text{ (pour que l'intégrale converge)}. \end{aligned}$$

Théorème: Si X est GPD, $u \mapsto e(u)$ droite

Théorème: Pour u grand, la loi de $X - u | X > u \simeq \text{GPD}$ (lorsque $u \mapsto x_F$)

En pratique, si $X \in \text{DA}(H_\xi)$, à partir d'un échantillon (X_i) indépendante et identiquement distribuées de même loi que X .

$X_i - u | X_i > u$ échantillon d'une loi GPD (chaîne de modèle paramétrique): 3 paramètres à estimer: ξ, a, b .

On estime ces paramètres par maximum de vraisemblance: $f_{\xi, a, b}(x) = G'_{\xi, a, b}(x)$.

le problème est de savoir à partir de quel niveau u_0 l'approximation par une loi GPD est pertinente

le second théorème "permet de choisir" le seuil u .

↳ On trace le mean excess plot, on choisit le seuil à partir duquel $u \mapsto e_n(u)$ droite

↳ Etape 1: Mean excess plot: On choisit u_0 (attention, si u_0 trop grand, on n'a plus beaucoup d'observations et l'estimation par maximum de vraisemblance est mauvaise).

↳ pas toujours clair

Etape 2: On ne retient que les observations dépassant u_0 : $Y_i = X_i - u_0$ (pour $X_i > u_0$)

On ajuste une loi GPD $G_{\xi, a, b}$ sur ces observations.

Exercice avec R: Construire un mean excess plot pour : $\begin{cases} \text{loi uniforme sur } [0, 1] \in \text{DA}(H_\xi), \xi < 0 \\ \text{loi exponentielle} \in \text{DA}(H_0). \end{cases}$

$$\begin{aligned} (X_{(n-k, n)}, e_n(X_{(n-k, n)}))_{k=1, \dots, n-1} &\text{ avec } e(X_{(n-k, n)}) = \frac{1}{k} \sum_{j=1}^k (X_{(n-k+j, n)} - X_{(n-k, n)}) \\ &= \frac{1}{n-i} \sum_{j=1}^k (X_{(i+j, n)} - X_{(i, n)}) = e(X_{(i, n)}) \end{aligned}$$

$$\text{graphe}(X_{(n-k, n)}, e_n(X_{(n-k, n)}))_{k=1, \dots, n-1} = \text{graphe}(X_{(i, n)}, e(X_{(i, n)}))_{i=1, \dots, n-1}$$