Université Gustave Eiffel - Cours M2 - Valeurs extrêmes

Emmanuelle Clément

1. Statistique d'ordre - Estimation de quantiles
2. Convergence des maxima - Domaines d'attraction
3. Dépassements de seuil
4. Estimateurs de Hill et Pickands - Estimation des quantiles extrêmes

Bibliographie

- J. Beirlant et Al. (2004). *Statistics of extremes.*
- S. Coles (2001). *An introduction to statistical modeling of extreme values.*
- J.F. Delmas, B. Jourdain (2006). *Modèles aléatoires.*
- P. Embrechts, C. Kluppelberg, T. Mikosch (1997). *Modelling extremal events for insurance and finance.*

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1.1 Fonction de répartition - Quantiles

Pour X variable aléatoire réelle, on note F sa fonction de répartition

$$F(x) = \mathbb{P}(X \leq x),$$

et $q(p)$ le quantile d'ordre p, $p \in (0,1)$

$$q(p) = inf\{x \in \mathbb{R}; F(x) \geq p\} := F^{-1}(p)$$

F^{-1} est l'inverse généralisé de F.

Exemple : calculer le quantile d'ordre p d'une loi exponentielle de paramètre λ, comment peut-on l'estimer.

Propriétés

1. $F(x) \geq p \Leftrightarrow x \geq F^{-1}(p)$.
2. Si F continue alors $\forall p \in (0,1)$, $F(F^{-1}(p)) = p$.
3. Si U v.a de loi uniforme sur $[0,1]$, $F^{-1}(U)$ a même loi que X.
4. Si F continue, $F(X)$ a même loi que U.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1.2. Statistique d'ordre

Dans cette section $(X_i)_{i\geq 1}$ est une suite de variables aléatoires i.i.d., de même loi que X de fonction de répartition F.
Avant de présenter la méthode non paramétrique classique d'estimation des quantiles, nous rappelons quelques résultats sur la statistique d'ordre de l'échantillon $(X_i)_{1\leq i\leq n}$. On appelle statistique d'ordre, l'échantillon ordonné

en croissant

$$X_{(1,n)} \leq \ldots \leq X_{(i,n)} \leq \ldots \leq X_{(n,n)}$$

avec

$$X_{(1,n)} = \min_{1\leq i\leq n} X_i, \qquad X_{(n,n)} = \max_{1\leq i\leq n} X_i.$$

Remarque : si F est continue, on a p.s.

$$X_{(1,n)} < \ldots < X_{(i,n)} < \ldots < X_{(n,n)}.$$

<u>Proposition</u>
Si X admet pour densité f (par rapport à la mesure de Lebesgue) alors $(X_{(1,n)}, \ldots, X_{(n,n)})$ a pour densité

$$g(x_1, \ldots, x_n) = n! 1_{\{x_1 < \ldots < x_n\}} \prod_{i=1}^{n} f(x_i).$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Proposition. On a pour $1 \leq k \leq n$

$$\mathbb{P}(X_{(k,n)} \leq x) = \sum_{j=k}^{n} \frac{n!}{(n-j)!j!} F(x)^j (1 - F(x))^{n-j}.$$

Dém. Donner la loi de $S_n(x) = \sum_{i=1}^{n} 1_{\{X_i \leq x\}}$ et vérifier que

$$\{S_n(x) \geq k\} = \{X_{(k,n)} \leq x\}.$$

1.3 Estimation des quantiles

Pour $p \in (0,1)$, l'estimateur non paramétrique du quantile $q(p)$ est donné par

$$\hat{q}_n(p) = X_{(i,n)} \quad \text{si } \frac{i-1}{n} < p \leq \frac{i}{n}$$

Remarque : pour $\frac{i-1}{n} < p < \frac{i}{n}$, $\hat{q}_n(p) = X_{([np]+1,n)}$ où $[np]$ est la partie entière de np.

Problème d'estimation des quantiles extrêmes (par exemple VaR sur dépassement de seuil où on a peu de données) :

- si $p < 1/n$, $\hat{q}_n(p) = X_{(1,n)} = \min X_i$,
- si $p > 1 - 1/n$, $\hat{q}_n(p) = X_{(n,n)} = \max X_i$.

Convergence et normalité asymptotique.

1. On suppose F continue et on suppose que l'équation $F(x) = p$ admet pour unique solution $q(p)$ pour $p \in (0,1)$, alors on a la convergence presque sûre
$$\hat{q}_n(p) \to q(p) \quad \text{p.s.}$$
2. On suppose que X admet une densité f, continue et strictement positive en $q(p)$ pour $p \in (0,1)$, alors on a la convergence en loi
$$\sqrt{n}(\hat{q}_n(p) - q(p)) \Longrightarrow \mathcal{N}\left(0, \frac{p(1-p)}{f(q(p))^2}\right).$$

Remarque : plus généralement, on a la convergence de $X_{(k(n),n)}$ pour $k(n)$ entier compris entre 1 et n tel que $k(n)/n \to p$ pour 1. et $k(n) = np + o(\sqrt{n})$ pour 2.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

2.3 Probability plot - QQ-plot

Outil pratique pour déterminer l'adéquation d'un jeu de données à une famille de lois. On note $x_{(1,n)} \leq \ldots \leq x_{(n,n)}$ la statistique d'ordre observée et pour $1 \leq i \leq n$

$$p_{i,n} = \begin{cases} \frac{i}{n} \text{ (problème pour } i = n) \\ \frac{i-0.5}{n} \text{ (valeur utilisée par R)} \\ \frac{i}{n+1} \end{cases}$$

- Probability plot
  On trace le graphe
  $$(F(x_{(i,n)}), p_{i,n})$$
  où F est la fonction de répartition de la loi pour laquelle on veut tester l'ajustement. Si F est bien la fonction de répartition de X (et F continue) on a $F(q(p)) = p$ et le graphe précédent est une droite.
- QQ-plot
  On trace le graphe quantile théorique contre quantile empirique
  $$(F^{-1}(p_{i,n}), x_{(i,n)})$$
  On obtient une droite si F est bien la fonction de répartition de X (1ere bissectrice).

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Exemple : si nos observations proviennent d'une loi exponentielle de paramètre λ, le graphe

$$\left(-\frac{\log(1-p_{i,n})}{\lambda}, x_{(i,n)}\right)$$

est sur la 1ere bissectrice.

Si on ne connaît pas λ, on peut le remplacer par un estimateur dans l'expression précédente

$$\hat{\lambda} = \frac{1}{\frac{1}{n}\sum_{i=1}^{n} X_i},$$

ou tracer

$$(-\log(1-p_{i,n}), x_{(i,n)}).$$

Dans ce dernier cas, si la loi exponentielle est appropriée, les points seront alignés (mais pas forcément sur la première bissectrice) et le graphique peut donner une approximation de λ.

Reprendre l'exemple avec une loi de Pareto ($F(x) = 1 - \frac{1}{x^\alpha}$, $x > 1$, $\alpha > 0$).

2. Convergence des maxima

$(X_i)_{i\geq 1}$ suite de variables i.i.d. de même loi que X admettant pour fonction de répartition F. On note M_n le maximum sur un bloc de taille n

$$M_n = \max_{1\leq i\leq n} X_i.$$

On vérifie facilement

$$\mathbb{P}(M_n \leq x) = F(x)^n \to \begin{cases} 0 \text{ si } F(x) < 1 \\ 1 \text{ si } F(x) = 1. \end{cases}$$

- Par quelle loi peut-on approcher M_n ?
- Pour $S_n = \sum_{i=1}^n X_i$, on sait que sous des conditions sur la loi de X

$$\sqrt{n}\left(\frac{S_n}{n} - \mathbb{E}(X)\right) \Longrightarrow \mathcal{N}(0, V(X)).$$

- Peut-on trouver des suites (a_n) et (b_n) telles que $\frac{M_n - b_n}{a_n}$ converge en loi vers une limite non dégénérée ?

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

2.1 Exemples

1. Loi uniforme

   X suit une loi uniforme sur $[0, a]$, $a > 0$.
   Montrer que $n(\frac{M_n}{a} - 1)$ converge en loi et préciser la fonction de répartition de la loi limite.
   (loi de Weibull)

   important

   examen

2. Loi exponentielle

   X suit une loi exponentielle de paramètre $\lambda > 0$.
   Montrer que $\lambda M_n - \log(n)$ converge en loi et préciser la fonction de répartition de la loi limite.
   (loi de Gumbel)

3. Loi de Pareto

   X suit une loi de Pareto de paramètre $\alpha > 0$, de densité $f(x) = \frac{\alpha}{x^{\alpha+1}} 1_{x \geq 1}$
   Montrer que $\frac{M_n}{n^{1/\alpha}}$ converge en loi et préciser la fonction de répartition de la loi limite.
   (loi de Fréchet)

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

2.2 Lois limites des maxima renormalisés - GEV distribution

On peut montrer que la loi limite de la suite des maxima renormalisés appartient nécessairement à une des trois familles de lois vues dans les exemples précédents.

Théorème(Fisher-Tippett).
Soit $(X_i)_{i\geq 1}$ une suite de variables i.i.d. On suppose qu'il existe des suites (a_n) avec $a_n > 0$ et (b_n) telles que $\frac{M_n - b_n}{a_n}$ converge en loi vers une variable Y de fonction de répartition H. Alors H (ou $\tilde{H}(x) = H(\frac{x-b}{a})$) appartient à une des trois familles caractérisées par les fonctions de répartition suivantes :

- Weibull
$$\Psi_\alpha(x) = \begin{cases} e^{-(-x)^\alpha}, & x \leq 0, \quad \alpha > 0, \\ 1, & x > 0. \end{cases}$$
- Gumbel
$$\Lambda(x) = e^{-e^{-x}}, \quad x \in \mathbb{R}.$$
- Fréchet
$$\Phi_\alpha(x) = \begin{cases} 0, & x \leq 0, \\ e^{-(x^{-\alpha})}, & x > 0, \quad \alpha > 0. \end{cases}$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Les trois lois précédentes ont une fonction de répartition de la forme (distribution GEV Generalized Extreme Value)

$$H_\xi(x) = e^{-(1+\xi x)^{-1/\xi}}, \quad \xi \in \mathbb{R}, \quad 1 + \xi x > 0.$$

- Weibull $\xi = -1/\alpha < 0$

$$\Psi_\alpha(x) = H_{-1/\alpha}(\alpha(x+1))$$

  support de la loi $\{x < 0\}$, maxima bornés supérieurement.
  Ex : loi uniforme, loi beta (températures, lois non adaptées pour la modélisation en finance et assurance).

- Gumbel $\xi = 0$

$$\Lambda(x) = H_0(x)$$

  support de la loi $\mathbb{R}$, décroissance relativement rapide de la survie, light tail .
  Ex : loi normale, loi log-normale, loi exponentielle, loi gamma (précipitations, débits de cours d'eau, maxima annuels de hauteur d'eau).

- Fréchet $\xi = 1/\alpha > 0$

$$\Phi_\alpha(x) = H_{1/\alpha}(\alpha(x-1))$$

  support de la loi $\{x > 0\}$, décroissance lente de la survie, heavy tail.
  Ex : loi de Pareto, loi de Cauchy, loi de student (précipitations, pics de pollution, rendements d'actifs).

Le signe de ξ permet d'identifier la famille de loi.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Le graphique suivant donne l'allure des densités pour ces trois lois (réalisé avec le R package evd).

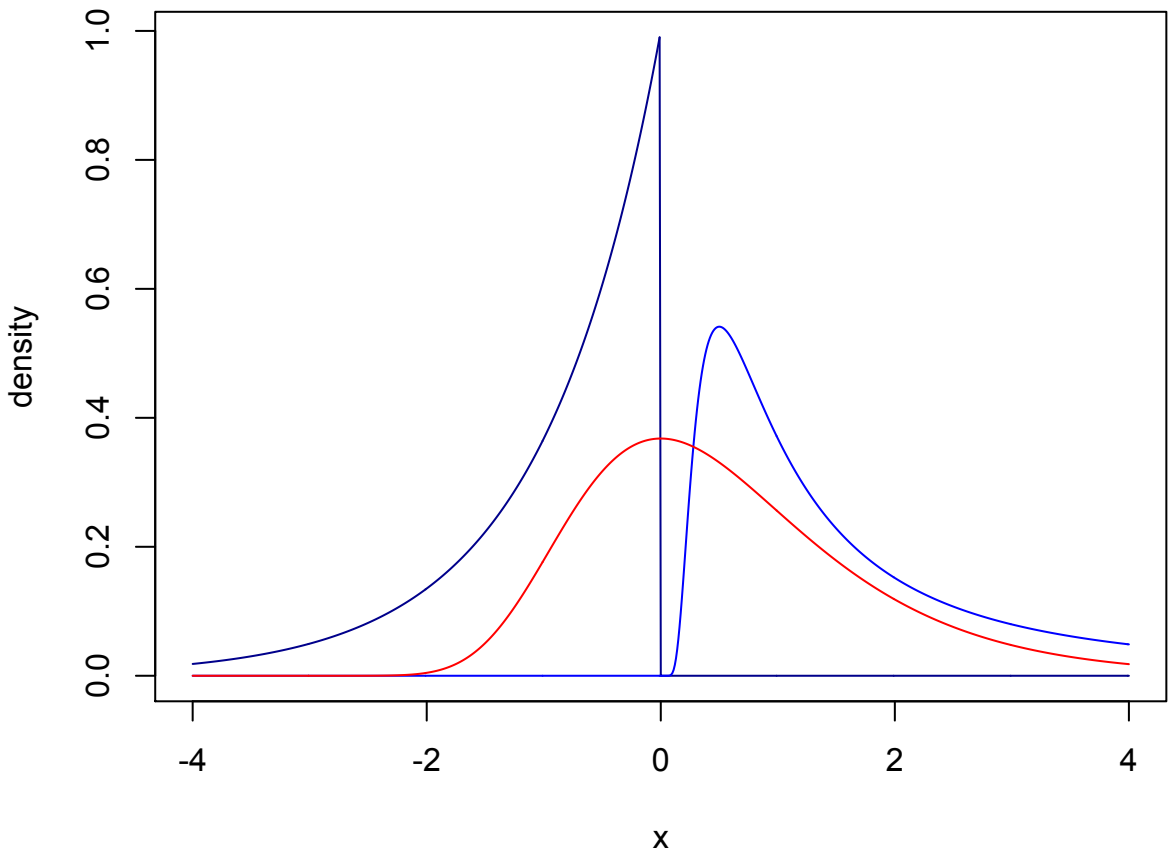

Figure – Densités GEV : Weibull ($\xi = -1$, darkblue), Gumbel (red), Fréchet ($\xi = 1$, blue)

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

2.3 Caractérisation du domaine d'attraction

Pour X variable aléatoire de fonction de répartition F, on cherche des conditions sur F pour que F appartienne au domaine d'attraction de H_ξ, c'est à dire pour qu'il existe (a_n) et (b_n) telles que $(M_n - b_n)/a_n$ converge en loi vers une variable Y de fonction de répartition H_ξ. Nous ne donnons ici qu'une caractérisation, il y a d'autres caractérisations (s'exprimant directement à partir de F) des domaines d'attraction pour les lois de Fréchet, Weibull et Gumbel.

On pose $U(t) = F^{-1}(1 - \frac{1}{t}), \quad t > 0$ (quantile d'ordre $1 - 1/t$).

Théorème.
F appartient au domaine d'attraction de H_ξ ssi $\forall x, y > 0$ avec $y \neq 1$

$$\lim_{s\to\infty} \frac{U(sx) - U(s)}{U(sy) - U(s)} = \begin{cases} \frac{x^\xi - 1}{y^\xi - 1} & \text{si} \quad \xi \neq 0, \\ \frac{\log(x)}{\log(y)} & \text{si} \quad \xi = 0. \end{cases}$$

Exercice. Calculer U et la limite précédente pour

1. une loi exponentielle,
2. une loi uniforme sur $[0, a]$,
3. une loi de Cauchy.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

3. Dépassement de seuil et GPD

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

<u>Définition</u>
Une distribution GPD est caractérisée par la fonction de répartition

$$G_\xi(x) = \begin{cases} 1-(1+\xi x)^{-1/\xi} & \text{si} \quad \xi \neq 0, \quad 0 < x < x^*, \\ 1-e^{-x} & \text{si} \quad \xi = 0, \quad x > 0, \end{cases}$$

où $x^* = +\infty$ si $\xi > 0$ et $x^* = -1/\xi$ si $\xi < 0$.

Si X suit une loi G_ξ alors βX suit la loi $G_{\xi,\beta}$ avec

$$G_{\xi,\beta}(x) = G_\xi\left(\frac{x}{\beta}\right)$$

Si on s'intéresse au dépassement de seuil (POT peak other threshold), le théorème suivant montre que pour un niveau de seuil u élevé, si F (la fonction de répartition de X) appartient au domaine d'attraction de H_ξ, alors la distribution de $X-u|X>u$ est proche d'une distribution $G_{\xi,a(u)}$.

On pose $x_F = \inf\{x; F(x) = 1\} = F^{-1}(1)$.

<u>Théorème</u>.
F appartient au domaine d'attraction de H_ξ ssi il existe une fonction a strictement positive telle que pour $x > 0$

$$\lim_{u \nearrow x_F} \mathbb{P}\left(\frac{X-u}{a(u)} > x | X > u\right) = \begin{cases} (1+\xi x)^{-1/\xi} & \text{si} \quad \xi \neq 0, \\ e^{-x} & \text{si} \quad \xi = 0, \end{cases}$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Le résultat suivant fournit un outil graphique important pour identifier ξ et $a(u)$.

On note $e(u)$ la moyenne du dépassement de seuil (mean excess function)

$$e(u) = \mathbb{E}(X - u | X > u)$$

Proposition

Si X suit une loi GPD $G_{\xi,a}$ avec $\xi < 1$ alors pour $u < x_F$, on a

$$e(u) = \frac{a + \xi u}{1 - \xi}.$$

Pour établir cela, on utilise que

$$e(u) = \frac{\int_u^\infty \mathbb{P}(X > x) dx}{\mathbb{P}(X > u)}.$$

Mean excess plot. En pratique pour identifier a et ξ, l'idée est de tracer le graphe $(u, e(u))$ et de voir à partir de quel seuil ce graphe est linéaire. On estime la fonction $e(u)$ par

$$e_n(u) = \frac{\sum_{i=1}^n (X_i - u) 1_{X_i > u}}{\sum_{i=1}^n 1_{X_i > u}}$$

et on trace le graphe

$$(X_{(n-k,n)}, e(X_{(n-k,n)})), \quad 1 \leq k \leq n - 1.$$

avec

$$e(X_{(n-k,n)}) = \frac{1}{k} \sum_{j=1}^{k} (X_{(n-j+1,n)} - X_{(n-k,n)}).$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

4. Estimation de ξ

Pour estimer le paramètre ξ apparaissant dans les lois GEV ou GPD on peut utiliser la méthode du maximum de vraisemblance à partir des données suivantes :

1. Maxima par blocs

   Données $Y_i = \max_{(i-1)n+1 \leq j \leq in} X_j$ pour $1 \leq i \leq m$. On suppose que les variables $(Y_i)_{1 \leq i \leq m}$ sont i.i.d. de loi $H_\xi(\frac{\cdot - b}{a})$, a paramètre d'échelle (scale parameter) et b paramètre de localisation (location parameter). On estime ξ, a et b par maximum de vraisemblance.

2. Dépassements de seuil (POT)

   On ne retient que les données qui dépassent le seuil u : $Y_i = X_i - u$ si $X_i > u$. On sait que pour u assez grand la loi de Y_i peut être approchée par une loi GPD et on estime ensuite ξ par maximum de vraisemblance. On peut choisir le seuil u à partir du graphe "mean excess plot".

Nous présentons dans les sections suivantes deux autres méthodes pour estimer le paramètre ξ.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

4.1 Estimateur de Pickands

Soient $(X_i)_{1\leq i\leq n}$ des variables i.i.d. de loi F. L'estimateur de Pickands est défini à partir de la statistique d'ordre par

$$\hat{\xi}^P_{(k(n),n)} = \frac{1}{\log(2)} \log\left(\frac{X_{(n-k(n)+1,n)} - X_{(n-2k(n)+1,n)}}{X_{(n-2k(n)+1,n)} - X_{(n-4k(n)+1,n)}}\right),$$

où $k(n)$ un entier tel que $1 \leq k(n) \leq n/4$.
On peut établir les résultats de convergence suivants lorsque F appartient au domaine d'attraction de H_ξ, $\xi \in \mathbb{R}$.

- Si $\lim_n k(n) = +\infty$ et $\lim_n k(n)/n = 0$ alors $\hat{\xi}^P_{(k(n),n)}$ converge en probabilité vers ξ lorsque n tend vers l'infini.
- Si de plus $\lim_n k(n)/\log(\log(n)) = \infty$, alors la convergence a lieu presque sûrement.
- Sous des hypothèses supplémentaires sur $k(n)$ et F, on a la convergence en loi

$$\sqrt{k(n)}(\hat{\xi}^P_{(k(n),n)} - \xi) \Longrightarrow \mathcal{N}\left(0, \frac{\xi^2(2^{2\xi+1}+1)}{[2(2^\xi-1)\log(2)]^2}\right).$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Idée de la construction de l'estimateur

Soit $U(t) = F^{-1}(1 - 1/t)$, le quantile d'ordre $1 - 1/t$ de F, avec $t > 0$. Nous avons établi pour $x, y > 0$ et $y \neq 1$

$$\lim_{s\to\infty} \frac{U(sx) - U(s)}{U(sy) - U(s)} = \begin{cases} \frac{x^\xi - 1}{y^\xi - 1}, & \text{si} \quad \xi \neq 0, \\ \frac{\log(x)}{\log(y)}, & \text{si} \quad \xi = 0. \end{cases}$$

En choisissant $x = 2$, $y = 1/2$ et $s = t/2$, on obtient

$$\lim_{t\to\infty} \frac{U(t) - U(t/2)}{U(t/2) - U(t/4)} = 2^\xi, \quad \forall \xi \in \mathbb{R},$$

et plus généralement si c_1 et c_2 sont deux fonctions telles que $c_1(t) \to 1/2$ et $c_2(t) \to 1/4$ lorsque $t \to \infty$ on a

$$\lim_{t\to\infty} \frac{U(t) - U(tc_1(t))}{U(tc_1(t)) - U(tc_2(t))} = 2^\xi, \quad \forall \xi \in \mathbb{R}.$$

L'idée de la construction de l'estimateur de Pickands est alors de trouver c_1 et c_2 en fonction des observations (X_i).

Soit $(V_i)_{1\leq i\leq n}$ un échantillon de loi de Pareto de paramètre 1 notée F_V, $F_V(x) = 1 - 1/x$, pour $x \geq 1$, et $k(n)$ entier tel que $1 \leq k(n) \leq n/4$, $\lim_n k(n) = +\infty$ et $\lim_n k(n)/n = 0$.
On admet les convergences suivantes :

$$\lim_{n\to\infty} V_{(n-k(n)+1,n)} = \infty, \quad \lim_{n\to\infty} \frac{V_{(n-2k(n)+1,n)}}{V_{(n-k(n)+1,n)}} = \frac{1}{2}, \quad \lim_{n\to\infty} \frac{V_{(n-4k(n)+1,n)}}{V_{(n-k(n)+1,n)}} = \frac{1}{4}.$$

On en déduit

$$\lim_{n\to\infty} \frac{U(V_{(n-k(n)+1,n)}) - U(V_{(n-2k(n)+1,n)})}{U(V_{(n-2k(n)+1,n)}) - U(V_{(n-4k(n)+1,n)})} = 2^{\xi}.$$

Mais par définition de U et F_V, on a $U(V) = F^{-1}(F_V(V))$ et donc

$$(U(V_{(1,n)}), \ldots, U(V_{(n,n)})) = (F^{-1}(F_V(V_{(1,n)})), \ldots, F^{-1}(F_V(V_{(n,n)}))).$$

Mais on sait que si X a pour loi F, $F(X)$ suit une loi uniforme sur $[0,1]$, $\mathcal{U}$, et que $F^{-1}(\mathcal{U})$ a même loi que X. Ceci permet de conclure que le vecteur $(U(V_{(1,n)}), \ldots, U(V_{(n,n)}))$ a même loi que $(X_{(1,n)}, \ldots, X_{(n,n)})$, on en déduit l'égalité en loi

$$\frac{U(V_{(n-k(n)+1,n)}) - U(V_{(n-2k(n)+1,n)})}{U(V_{(n-2k(n)+1,n)}) - U(V_{(n-4k(n)+1,n)})} = 2^{\hat{\xi}^P_{(k(n),n)}} \quad \text{(égalité en loi)}.$$

On peut donc conclure que $\hat{\xi}^P_{(k(n),n)}$ converge en loi vers ξ.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Exercice : mise en oeuvre avec R.

Pour $n = 40000$, simuler n variables aléatoires de loi (a) exponentielle de paramètre 1, (b) uniforme sur $[0, 1]$, (c) Cauchy. Nous avons montré que la loi (a) appartient au domaine d'attraction de H_0, la loi (b) au domaine d'attraction de H_{-1} et la loi (c) au domaine d'attraction de H_1. L'estimateur $\hat{\xi}^P_{(k(n),n)}$ est proche de ξ pour n grand, et $k(n)$ grand ($\lim_n k(n) = \infty$) mais $k(n)$ beaucoup plus petit que n ($\lim_n k(n)/n = 0$). Pour observer la convergence de l'estimateur, tracer la courbe $k \mapsto \hat{\xi}^P_{(k,n)}$ (Pickands plot) pour k variant de 1 à 1000, ceci pour les lois (a), (b) et (c). Pour la loi (c), faites ensuite varier k de 1 à 10000, vous devez observer que lorsque k est trop grand, l'estimateur de ξ (en l'occurence 1 pour (c)), s'éloigne de la valeur 1.

4.2 Estimateur de Hill

On peut aussi estimer ξ avec l'estimateur de Hill. La version de l'estimateur présentée ici ne concerne que le cas $\xi > 0$. L'estimateur est défini par

$$\hat{\xi}^H_{(k(n),n)} = \frac{1}{k(n)} \sum_{i=n-k(n)+1}^{n} (\log(X_{(i,n)} - \log(X_{(n-k(n)+1,n)}), \quad 1 \leq k(n) \leq n$$

On peut établir les résultats de convergence suivants lorsque F appartient au domaine d'attraction de H_ξ, $\xi > 0$.

- Si $\lim_n k(n) = +\infty$ et $\lim_n k(n)/n = 0$ alors $\hat{\xi}^H_{(k(n),n)}$ converge en probabilité vers ξ lorsque n tend vers l'infini.
- Si de plus $\lim_n k(n)/\log(\log(n)) = \infty$, alors la convergence a lieu presque sûrement.
- Sous des hypothèses supplémentaires sur $k(n)$ et F, on a la convergence en loi
$$\sqrt{k(n)}(\hat{\xi}^H_{(k(n),n)} - \xi) \Longrightarrow \mathcal{N}\left(0, \xi^2\right).$$

En pratique pour les deux estimateurs, Pickands et Hill, il est conseillé de tracer la courbe $k \mapsto \hat{\xi}_{(k,n)}$ (Pickands plot ou Hill plot) pour avoir une idée du choix de k (valeurs où la courbe est horizontale).

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Idée de la construction de l'estimateur

Comme $\xi > 0$, F appartient au domaine d'attraction d'une loi de Fréchet (avec $\alpha = 1/\xi$). On peut montrer dans ce cas que (en notant $\overline{F} = 1 - F$)

$$\lim_{t\to\infty} \frac{\overline{F}(tx)}{\overline{F}(t)} = \frac{1}{x^\alpha}.$$

On peut donc écrire $\overline{F}(x) = \frac{1}{x^\alpha} L(x)$ où L est à variation lente et le Théorème de Karamata donne

$$\int_x^\infty \frac{L(t)}{t^{\eta+1}} dt \sim_\infty \frac{1}{\eta x^\eta} L(x), \quad \forall \eta > 0.$$

Pour X variable aléatoire de loi F, calculons $\mathbb{E}(\log(X) - \log(t)|X > t)$, en supposant pour simplifier que F admet pour densité f. On a

$$\begin{aligned} \mathbb{E}(\log(X) - \log(t)|X > t) &= \tfrac{1}{\overline{F}(t)} \mathbb{E}((\log(X) - \log(t))1_{\{X>t\}}) \\ &= \tfrac{1}{\overline{F}(t)} \int_t^\infty \tfrac{\overline{F}(u)}{u} du. \end{aligned}$$

On en déduit

$$\mathbb{E}(\log(X) - \log(t)|X > t) = \frac{\int_t^\infty \frac{L(u)}{u^{\alpha+1}} du}{\frac{L(t)}{t^\alpha}} \sim_\infty \frac{1}{\alpha}.$$

On peut approcher $\mathbb{E}(\log(X) - \log(t)|X > t)$ par la loi des grands nombres :

$$\lim_{n\to\infty} \frac{\frac{1}{n}\sum_{i=1}^n (\log(X_i) - \log(t))1_{\{X_i>t\}}}{\frac{1}{n}\sum_{i=1}^n 1_{\{X_i>t\}}} = \mathbb{E}(\log(X) - \log(t)|X > t).$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

On remplace ensuite t par $X_{(n-k(n)+1,n)}$. D'après la section précédente $X_{(n-k(n)+1,n)}$ a même loi que $U(V_{(n-k(n)+1,n)})$ et $\lim_n V_{(n-k(n)+1,n)} = \infty$. On en déduit que $\lim_n X_{(n-k(n)+1,n)} = \infty$.
On obtient

$$\begin{aligned}
\hat{\xi}^H_{(k(n),n)} &= \frac{\frac{1}{n}\sum_{i=1}^n (\log(X_i) - \log(X_{(n-k(n)+1,n)})1_{\{X_i > X_{(n-k(n)+1,n)}\}}}{\frac{1}{n}\sum_{i=1}^n 1_{\{X_i > X_{(n-k(n)+1,n)}\}}} \\
&= \frac{\frac{1}{n}\sum_{i=n-k(n)+1}^n (\log(X_{(i,n)}) - \log(X_{(n-k(n)+1,n)}))}{\frac{k(n)-1}{n}} \\
&= \frac{1}{(k(n)-1)}\sum_{i=n-k(n)+1}^n (\log(X_{(i,n)}) - \log(X_{(n-k(n)+1,n)})).
\end{aligned}$$

On conclut alors

$$\lim_{n\to\infty} \hat{\xi}^H_{(k(n),n)} = \frac{1}{\alpha} = \xi.$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

Exercice : mise en oeuvre avec R.

(a) Pour $n = 40000$, simuler n variables aléatoires de loi de Cauchy ($\xi = 1$) et tracer la courbe $k \mapsto \hat{\xi}^H_{(k,n)}$ pour k variant de 1 à 1000, puis pour $k = 1$ à 10000.
(b) Même chose avec une loi de pareto de paramètre 1 ($F(x) = 1 - 1/(1 + x)$ pour $x \geq 0$) pour $n = 4000$ et k variant de 1 à 1000. On peut simuler un échantillon i.i.d. de taille n d'une loi de Pareto avec le package evd.

4.3 Applications aux quantiles extrêmes

Pour X variable aléatoire de loi F, on note

$$z_q = F^{-1}(1-q), \quad \text{quantile d'ordre } 1-q, \quad q \in (0,1)$$

Nous avons vu que l'on peut estimer ce quantile à partir de l'échantillon $(X_i)_{1 \leq i \leq n}$ par

$$\hat{z}_q = X_{(n-i+1,n)}, \quad (i-1)/n < q \leq i/n$$

si $1/n < q < 1 - 1/n$.
Nous allons voir dans cette section comment estimer z_q pour q de l'ordre de $1/n$, c'est à dire en supposant que

$$\lim_n nq_n = c > 0.$$

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

La construction d'un estimateur de z_{q_n} repose sur les idées suivantes. Pour X de fonction de répartition F appartenant au domaine d'attraction de H_ξ, on sait qu'il existe des suites (a_n) et (b_n) telles que $(M_n - b_n)/a_n$ converge en loi vers H_ξ, on a donc l'approximation pour n grand

$$\mathbb{P}((M_n - b_n)/a_n \leq x) = F(xa_n + b_n)^n \simeq H_\xi(x).$$

Cette approximation reste valable en remplaçant n par n/k pour k fixé, soit

$$F(xa_{n/k} + b_{n/k})^{n/k} \simeq H_\xi(x).$$

Par définition de z_{q_n}, on a $1 - q_n = F(z_{q_n})$, d'où

$$\begin{aligned} q_n &= 1 - F(z_{q_n}) \\ &\simeq 1 - H_\xi\left(\frac{z_{q_n} - b_{n/k}}{a_{n/k}}\right)^{k/n} \\ &= 1 - e^{-\frac{k}{n}[1+\xi(\frac{z_{q_n} - b_{n/k}}{a_{n/k}})]^{-1/\xi}} \qquad \text{par définition de } H_\xi \\ &\simeq \frac{k}{n}[1 + \xi(\frac{z_{q_n} - b_{n/k}}{a_{n/k}})]^{-1/\xi}, \end{aligned}$$

et donc

$$z_{q_n} \simeq a_{n/k}\left(\frac{(\frac{k}{nq_n})^\xi - 1}{\xi}\right) + b_{n/k}.$$

L'estimation complète de z_{q_n} est ensuite obtenue par l'estimation des suites (a_n), (b_n) et par l'estimation de ξ.

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

1. Statistique d'ordre - Estimation de quantiles
1.1 F.d.R.-Quantiles
1.2 Statistique d'ordre
1.3 Quantiles
1.4 QQ-plot
2. Convergence des maxima
2.1 Exemples
2.2 Lois GEV
2.3 Domaines d'attraction
3 Dépassement de seuil
4. Estimation de ξ
4.1 Pickands
4.2 Hill
4.3 Applications

- Estimation à partir de l'estimateur de Hill.

  Pour $\xi > 0$, on estime ξ par $\hat{\xi}^H$ et les suites $(a_{n/k})$, $(b_{n/k})$ par

$$a_{n/k} = \hat{\xi}^H X_{(n-k+1,n)}, \quad b_{n/k} = X_{(n-k+1,n)}.$$

  On obtient

$$\hat{z}_{q_n} = \left(\frac{k}{nq_n}\right)^{\hat{\xi}^H} X_{(n-k+1,n)},$$

  avec $k = k(n) \to \infty$ et $\lim_n k(n)/n = 0$.

- Estimation à partir de l'estimateur de Pickands.

  Un estimateur de z_{q_n} est donné par

$$\hat{z}_{q_n} = \left(\frac{(\frac{k}{nq_n})^{\hat{\xi}^P} - 1}{1 - 2^{-\hat{\xi}^P}}\right)(X_{(n-k+1,n)} - X_{(n-2k+1,n)}) + X_{(n-k+1,n)}, \quad \text{si} \quad \xi \neq 0,$$

$$\hat{z}_{q_n} = \left(\frac{\log(k/(nq_n))}{\log(2)}\right)(X_{(n-k+1,n)} - X_{(n-2k+1,n)}) + X_{(n-k+1,n)}, \quad \text{si} \quad \xi = 0,$$

  avec $k = k(n) \to \infty$ et $\lim_n k(n)/n = 0$.