

Projet 1 : Estimation de densité avec un estimateur à noyau

FAGE Annaelle & PINA Ruben

Introduction

L'objectif de ce projet est d'illustrer les méthodes d'estimation de densité à partir d'un échantillon de données. Dans ce projet, nous nous intéressons plus particulièrement aux estimateurs à noyau. Nous commencerons par étudier leur comportement sur des données simulées, afin de mieux comprendre leur fonctionnement dans un cadre connu. Dans un second temps, nous appliquerons cette méthode à un jeu de données réelles pour en évaluer les performances dans un contexte concret.

I. Données simulées

Dans cette partie, nous considérons un vecteur aléatoire $X = (X_i)_{i=1,\dots,100}$, dont la loi est connue, et nous cherchons à estimer sa densité de probabilité f . Nous allons estimer sa densité à partir de deux noyaux différents.

1. Génération des données simulées

On génère deux échantillons de taille $n = 50$:

$$X_1, \dots, X_{50} \sim \mathcal{N}(-1.5, 2) \quad \text{et} \quad Y_1, \dots, Y_{50} \sim \mathcal{U}[0, 1].$$

Les deux vecteurs sont ensuite concaténés pour former l'échantillon global :

$$Z = (X_1, \dots, X_{50}, Y_1, \dots, Y_{50}).$$

Cet échantillon correspond à un mélange de deux distributions très différentes : une gaussienne centrée en -1.5 et une uniforme sur $[0, 1]$. Cela permet de tester la capacité des estimateurs à capturer des structures de densité complexes.




FIGURE 1 – Histogramme de l'échantillon concaténé.

Nous représentons ici les données sous forme d'histogramme, ce qui nous permet d'obtenir une première estimation de la densité. On observe clairement un histogramme composé de deux composantes : une gaussienne centrée en -1.5 et une loi uniforme sur l'intervalle $[0, 1]$.

2. Estimateur à noyau

L'estimateur à noyau est défini par :

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right),$$

où K est une fonction noyau (par exemple : gaussien, rectangulaire) et $h > 0$ la fenêtre.

Deux noyaux ont été testés :

- Noyau **gaussien** : $K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}$,
- Noyau **rectangulaire** : $K(u) = \frac{1}{2} \mathbf{1}_{\{|u| \leq 1\}}(u)$.

Dans un premier temps, nous avons fixé une fenêtre h de manière arbitraire, dans le but d'obtenir une représentation graphique suffisamment claire pour observer les principales caractéristiques des données.




FIGURE 2 – Estimateurs à noyau pour deux noyaux).

3. Sélection optimale de la fenêtre

Le choix de la fenêtre h est crucial.

Un h trop petit entraîne un sur-apprentissage : la densité estimée devient trop irrégulière et suit le bruit des données.

Un h trop grand entraîne un sous-apprentissage : la densité estimée est trop lissée et ne capture plus la structure réelle des données.

Nous l'avons sélectionnée par **validation croisée** : pour chaque valeur candidate de h , on maximise

la log-vraisemblance moyenne sur des sous-échantillons de validation. Le meilleur h est celui qui maximise ce critère.




FIGURE 3 – Estimateurs des noyaux optimal

Les estimateurs à noyau offrent une représentation plus fluide et réaliste de la densité. Nous remarquons que l'estimateur à noyaux gaussien est le plus fidèle aux données simulées. Celui-ci capture correctement les deux composantes du mélange : le pic gaussien autour de -1.5 et la densité quasi uniforme entre 0 et 1.

II. Données réel

1. Choix et présentations des données

Dans cette deuxième partie, nous avons choisi de regarder la base de données **California Housing** disponible dans la bibliothèque **scikit-learn**. Cette base regroupe des informations sur le logement en Californie au début des années 1990. Chaque observation correspond à un *district* (zone géographique regroupant plusieurs ménages) et contient différentes variables socio-économiques.

La variable que l'on a choisi d'étudier est **MedInc**, qui reflète le niveau de richesse moyen des ménages dans chaque région de Californie. Les valeurs typiques de **MedInc** varient entre environ 0.5 et 15, ce qui correspond à des revenus médians compris entre 5 000 et 150 000 dollars.

Ce jeu de donnée et plus particulièrement la variable **MedInc** est adapté pour l'estimation à noyau pour plusieurs raison : c'est une variable quantitative continue et la taille de l'échantillon est suffisante. De plus, la distribution du revenu médian n'est pas connue à l'avance et ne suit pas nécessairement une loi simple.

L'objectif est d'estimer la densité de probabilité de la variable **MedInc**, c'est-à-dire la distribution du revenu médian des ménages dans chaque région de la Californie et donc de visualiser des possibles inégalités économiques.

2. Résultats obtenus et interprétations




FIGURE 4 – Estimateurs des noyaux optimal

Le tracé des densités montre une distribution asymétrique et étalée vers la droite. Cela signifie que la majorité des districts californiens présentent un revenu médian modéré (autour de 3 à 4 dizaines de milliers de dollars), tandis que certaines zones présentent des revenus nettement plus élevés, créant une *queue* à droite.

L'estimation de densité à noyau met en évidence :

- . Une concentration principale autour d'un revenu médian de 3 à 4 (soit environ 30 000 – 40 000 \$),
- . Une minorité de zones à revenus supérieurs à 10 ($\approx 100\,000$ \$),
- . Une forte asymétrie positive typique des variables économiques.

Le noyau gaussien, capture mieux la structure réelle de la distribution que le noyau rectangulaire. De plus, la forme asymétrique observée confirme que la loi normale ne serait pas un modèle adéquat pour cette variable d'où l'intérêt de cette méthode. Ainsi, le noyau gaussien avec la bande passante optimale apparaît comme le meilleur estimateur pour cette variable.

3. Conclusion

Dans le cas de la variable **MedInc**, la distribution estimée révèle une forte hétérogénéité des revenus, caractéristiques classiques des données socio-économiques californiennes. Cette asymétrie traduit la présence d'une majorité de districts présentant des revenus médians modestes, concentrés autour de 30 000 – 40 000 \$, tandis qu'un nombre plus restreint de zones, affichent des revenus nettement plus élevés.

Ce comportement est typique des distributions de revenus, souvent marquées par une concentration de la richesse dans une fraction limitée de la population. L'estimateur à noyau met ainsi en évidence une réalité économique importante : la coexistence de zones à faible revenu et de pôles de haute prospérité au sein d'un même État.