

Projet 2 : Estimation par projection sur la base de Fourier

FAGE Annaelle & PINA Ruben

Objectif du projet

L'objectif de ce projet est d'illustrer la mise en œuvre d'une méthode de régression non paramétrique à l'aide d'une base de Fourier. L'idée générale est d'estimer une fonction inconnue f à partir d'un échantillon de données simulées (X_i, Y_i) , sans supposer de forme fonctionnelle particulière pour f .

Pour ce faire, on utilise une approche par projection : on approxime f comme une combinaison linéaire de fonctions de base de Fourier, dont le nombre de termes est contrôlé par un paramètre N . Le but est de trouver une valeur optimale de N qui équilibre la complexité du modèle et la qualité de l'ajustement.

I. Théorie

I.1. Simulation des données

On génère un échantillon de taille $n = 100$ où les variables explicatives X_i sont uniformément réparties sur l'intervalle $[0, 1]$. Les observations sont simulées selon le modèle :

$$Y_i = f(X_i) + \sigma \xi_i$$

avec un bruit gaussien $\xi_i \sim \mathcal{N}(0, 1)$ et un écart-type $\sigma = 0.2$. La fonction réelle $f(x)$ choisie est volontairement complexe, non linéaire et oscillante afin de tester la capacité de l'estimateur à s'adapter à des structures variées.

La figure suivante illustre les données simulées ainsi que la véritable fonction utilisée pour la génération des observations :




FIGURE 1 – Nuage de points des données simulées et vraie fonction de régression

I.2. Méthode de régression par base orthonormale de Fourier

L'idée principale de l'approche est de représenter la fonction $f(x)$ comme une combinaison linéaire des premières fonctions d'une base orthonormée de Fourier définie sur $[0, 1]$:

$$\phi_n(x) = \begin{cases} 1 & \text{si } n = 0 \\ \sqrt{2} \cos(2\pi kx) & \text{si } n = 2k - 1 \\ \sqrt{2} \sin(2\pi kx) & \text{si } n = 2k \end{cases}$$

L'estimateur de f s'écrit alors :

$$\hat{f}_N(x) = \sum_{j=0}^{N-1} \hat{a}_j \phi_j(x)$$

où les coefficients $\hat{a}_j$ sont estimés empiriquement à partir des données :

$$\hat{a}_j = \frac{1}{n} \sum_{i=1}^n Y_i \phi_j(X_i)$$

La figure ci-dessous présente les cinq premières fonctions de la base de Fourier utilisées dans cette approximation.




FIGURE 2 – Les cinq premières fonctions de la base de Fourier sur $[0,1]$

I.3. Étude du paramètre N

Le paramètre N correspond au nombre de fonctions de base utilisées dans l'estimation. Le choix de N est crucial. Plus N est grand, plus le modèle est flexible, mais un choix trop grand risque d'entraîner du sur-apprentissage (sur-estimation du bruit). À l'inverse, un N trop faible conduit à une sous-estimation de la complexité réelle de la fonction.

Pour visualiser cet effet, on a tracé les estimateurs obtenus pour plusieurs valeurs de N :

- $N = 5, 10, 15$ (modèles simples),
- $N = 20, 30$ (modèles intermédiaires),
- $N = 50, 70$ (modèles très flexibles).

Les figures suivantes illustrent l'évolution de la qualité de l'ajustement selon N .




FIGURE 3 – Estimateurs pour différentes valeurs de $N = 5, 10, 15$




FIGURE 4 – Estimateurs pour différentes valeurs de $N = 20, 30$ et $N = 50, 70$.

On observe que pour les petites valeurs de N , l'estimation est trop lissée et ne capture pas les variations de la fonction réelle. À mesure que N augmente, l'ajustement s'améliore, mais pour les valeurs trop élevées, le modèle devient instable et reproduit le bruit.

I.4. Sélection du modèle par validation croisée

Afin de déterminer la valeur optimale du paramètre N , une procédure de validation croisée a été mise en place. Le principe consiste à diviser l'échantillon de données en plusieurs sous-ensembles, ici en 5 parties de taille égale.

Pour chaque valeur de N testée :

- on entraîne le modèle sur 4 des 5 sous-ensembles (échantillon d'apprentissage),
- on évalue ensuite l'erreur de prédiction sur la partie restante (échantillon de test).

Cette opération est répétée de manière à ce que chaque sous-ensemble soit utilisé une fois comme jeu de test. On calcule alors la moyenne des erreurs obtenues sur les 5 itérations. Le modèle dont le paramètre N minimise cette erreur moyenne est choisi comme modèle optimal.

La figure suivante illustre l'estimation finale correspondant à ce choix de paramètre.




FIGURE 5 – Estimateur optimal choisi par validation croisée

Pour aller plus loin, nous avons décidé d'évaluer la stabilité de cette procédure, l'expérience de validation croisée a été répétée sur 200 essais indépendants. Pour chaque essai, un nouveau découpage aléatoire des données a été effectué, et la valeur optimale de N correspondante a été enregistrée. La distribution de ces valeurs est représentée sous la forme d'un histogramme ci-dessous :




FIGURE 6 – Histogramme des valeurs de N_{optimal}

Cet histogramme permet de visualiser la variabilité du paramètre sélectionné. On observe que la majorité des essais se concentrent autour d'une même plage de valeurs, ce qui confirme la robustesse de la méthode de validation croisée. Ainsi, la valeur moyenne de N_{optimal} correspond à un compromis stable entre biais et variance du modèle.

II. Application sur données réelles

II.1. Description des données

Nous avons appliqué la même méthode au jeu de données *mcycle*, qui enregistre l'accélération de la tête d'un mannequin lors d'une simulation d'accident de moto. La variable explicative X est le temps en millisecondes, et la variable à prédire Y est l'accélération en g . Avant l'estimation, la variable "temps" a été normalisée sur l'intervalle $[0, 1]$. La figure ci-dessous montre le nuage de points.




FIGURE 7 – Nuage de point des des données réelles "*mcycle*".

II.2. Résultats et interprétation

De manière similaire au cas des données simulé, nous avons tracé l'estimateurs pour différentes valeurs de N :

- Pour $N \in \{5, 10, 20\}$,
- Pour $N \in \{40, 70\}$.




FIGURE 8 – Ajustement sur les données réelles pour différentes valeurs de N .

La validation croisée a sélectionné une valeur optimale de $N_{opt} = 6$. Cet estimateur, représenté sur par les figures suivantes, semble capturer la tendance principale des données de manière satisfaisante, en filtrant les oscillations à haute fréquence qui sont probablement dues au bruit de mesure.




FIGURE 9 – Évolution du score de validation croisée en fonction de N .




FIGURE 10 – Estimateur optimal obtenu par validation croisée avec $N_{optimal}$ sur les données "mcycle".

Grâce à cette analyse, on peut lire directement la décélération maximale réelle subie par la tête et ainsi comprendre la dynamique complète du choc, y compris l'effet de rebond qu'on voit facilement sur la courbe.

Cette analyse permet de contrôler la sécurité, la valeur de pic ($\simeq 150$ g) peut être ensuite comparée aux seuils de tolérance connus pour les lésions cérébrales afin de déterminer si le casque testé est efficace et protège l'utilisateur.

Pour finir, les oscillations qui s'atténuent ensuite traduisent un amortissement progressif du mouvement jusqu'à stabilisation.

III. Conclusion

Ce projet a permis de mettre en œuvre avec succès une méthode d'estimation non-paramétrique par projection sur la base de Fourier. L'étude sur données simulées a confirmé l'importance du paramètre de lissage N et a montré l'efficacité de la validation croisée pour trouver un bon compromis entre biais et variance.

L'application sur les données réelles *mcycle* a démontré la pertinence de cette approche dans un cas pratique. L'estimateur final avec $N = 6$ offre un lissage cohérent du signal d'accélération.

Cette méthode est donc un outil puissant pour extraire la tendance principale d'un signal bruité sans imposer de forme paramétrique rigide à la fonction sous-jacente.