

Projet 3 : Sparcité, estimation et sélection de variables

FAGE Annaelle & PINA Ruben

Objectif du projet

L'objectif de ce projet est d'étudier différentes méthodes d'estimation adaptées aux signaux *sparse* en présence de bruit, ainsi qu'une approche de détection de ruptures structurales.

La première partie compare trois estimateurs non linéaires classiques : seuillage dur, seuillage doux et Non-Negative Garrote.

La seconde partie utilise un mécanisme de seuillage sur les différences successives pour détecter les ruptures d'un signal à pièces constantes.

Enfin, la troisième partie applique cette méthode à la série temporelle historique du débit du Nil.

I. Les différents méthodes de seuillage

On observe un vecteur $y = (y_1, \dots, y_n)$ vérifiant le modèle de suite gaussienne, avec :

$$y_j = a\eta_j + \xi_j; \quad j = 1, \dots, d,$$

où $a \in \mathbb{R}$ et $\eta_j \in 0, 1$ qui sont des paramètres inconnus tels que

$$\sum_{j=1}^d \eta_j = [d^{1-\beta}], \quad \text{pour un } \beta \in (0, 1) \text{ fixé,}$$

où les variables aléatoires ξ_j sont i.i.d. de loi $\mathcal{N}(0, 1)$.

Notons $\theta^* = a \cdot (\eta_1, \dots, \eta_d)^\top$. On cherche à estimer θ^* à partir des observations y .

Pour contrôler le bruit, plusieurs estimateurs non linéaires sont utilisés. Ils reposent tous sur un seuil universel :

$$\tau = \sqrt{2 \log d}$$

Chaque méthode applique une transformation différente à chaque composante y_j .

Définition des estimateurs étudiés




Figure 1: Comparaison des trois fonctions de seuillage.

- **Seuillage dur (Hard Thresholding)** L'estimateur applique une coupure franche : un coefficient observé y_i est conservé s'il dépasse un seuil τ en valeur absolue, sinon il est mis à zéro. Formellement :

$$\hat{\theta}_j^H = y_j \mathbf{1}_{|y_j| > \tau}.$$

Cet estimateur est non biaisé dès que $|y_i| > \tau$, mais présente une discontinuité brutale autour du seuil.

- **Seuillage doux (Soft Thresholding)** Le seuillage doux contracte systématiquement les coefficients en réduisant leur amplitude de τ :

$$\hat{\theta}_j^S = y_j \cdot \left(1 - \frac{\tau}{|y_j|}\right)_+$$

Cet estimateur est continu mais introduit un biais sur toutes les valeurs, même les grandes. Il est très utilisé en débruitage, notamment en analyse par ondelettes.

- **Non-Negative Garrote** Le Garrote effectue une contraction multiplicative progressive :

$$\hat{\theta}_i^G = y_i \left(1 - \frac{\tau^2}{y_i^2}\right)_+$$

Il réduit les valeurs intermédiaires tout en préservant presque intactes les grandes amplitudes. Il est continu, ce qui le rend plus stable que le Hard tout en étant moins biaisé que le Soft.

Comparaison du risque quadratique et Risque de sélection

Le risque quadratique

$$R(\hat{\theta}, a) = \|\hat{\theta} - \theta^*\|_2^2$$

est évalué en fonction de l'amplitude a du signal et sur plusieurs simulations. Le signal contient $k = d^{1-\beta}$ coefficients non nuls.




Figure 2: Risque quadratique moyen avec intervalles d'incertitude.

On peut s'apercevoir que :

- Pour les faibles amplitudes, le Soft possède généralement le plus faible risque grâce à sa contraction importante.
- L'estimateur par seuillage fort se comporte très mal lorsque a est petit car il supprime beaucoup de coefficients vrais. Mais il devient plus efficace sur de grande amplitude.
- Et l'estimateur "non-negative garrote" suit la même tendance que l'estimateur par seuillage faible. Il est un compromis entre les deux, car il préserve mieux les grandes valeurs tout en limitant le biais

On évalue ensuite le risque de sélection de variables :

$$R^{MS}(\hat{\theta}, a) = \sum_{j=1}^M |\eta_j - \hat{\eta}_j|.$$

Commentaires : Le risque de support diminue lorsque a augmente : les coefficients actifs deviennent plus visibles. Pour les faibles amplitudes, l'erreur de sélection est élevée : les signaux sont difficiles à distinguer du bruit.

Impact de la parcimonie

Enfin, on fait varier le paramètre β pour analyser l'influence de la densité du signal.




Figure 3: Performance en fonction de la parcimonie.

Lorsque β est faible (peu sparse), les grands nombres de coefficients non nuls dégradent les performances des estimateurs. À mesure que β augmente (plus sparse), les méthodes de seuillage deviennent plus efficaces, notamment le Hard et le Garrote. Le Soft reste plus robuste dans les situations denses grâce à son biais régulier.

II. Détection de ruptures sur signal synthétique

Modèle

On considère un signal à pièces constantes de dimension d , défini par un vecteur inconnu $\theta^* = (\theta_1^*, \dots, \theta_d^*)^\top$, présentant plusieurs ruptures. Le signal est corrompu par un bruit gaussien centré de variance

$$\varepsilon = \frac{1}{\sqrt{d}}.$$

Les ruptures théoriques sont situées aux positions 10, 30 et 40, ce qui génère plusieurs plateaux successifs.

Méthode de détection

En pratique, le vecteur θ^* n'est pas observable. On travaille donc avec son estimateur $\hat{\theta}$ obtenu à partir des observations bruitées du signal.

On calcule alors le vecteur des différences successives :

$$\Delta_j = \hat{\theta}_{j+1} - \hat{\theta}_j, \quad j = 1, \dots, d-1.$$

Un point de rupture est détecté à la position j si :

$$|\Delta_j| > \delta_{\text{seuil}} = 2\sqrt{\frac{\log(d)}{d}}.$$

Cette méthode repose sur le fait qu'un saut brutal dans la valeur du signal engendre une différence élevée entre deux positions consécutives, contrairement aux fluctuations dues uniquement au bruit.

Résultats et analyse




Figure 4: Signal synthétique et ruptures détectées par la méthode des différences seuillées.

La figure montre des pics clairement visibles au niveau des positions correspondant aux ruptures théoriques. Les seuils appliqués permettent de filtrer les variations dues au bruit tout en conservant les véritables discontinuités du signal.

Les ruptures sont ainsi localisées avec précision, ce qui valide l'efficacité de la méthode dans un cadre de bruit modéré.

Étude Monte Carlo et stabilité de la méthode

Afin d'évaluer la robustesse de la méthode, une simulation de type Monte Carlo a été réalisée sur 1000 répétitions indépendantes. À chaque itération, un nouveau bruit est généré, puis la procédure de détection est appliquée.

Pour chaque position j , on calcule la fréquence de détection d'une rupture, ce qui permet d'obtenir une probabilité empirique de détection.




Figure 5: Probabilité de détection d'une rupture en chaque position.

Les résultats mettent en évidence :

- une probabilité de détection proche de 1 aux positions des ruptures réelles,
- une probabilité quasi nulle aux autres positions,
- une très bonne stabilité de la méthode face au bruit aléatoire.

Cette expérience confirme la fiabilité de la méthode de détection par seuillage des différences successives, particulièrement adaptée aux signaux à pièces constantes.

III. Données réelles : le débit du Nil

Description des données

La série étudiée correspond au débit annuel du Nil sur la période 1871–1970. Il s'agit d'une série temporelle comportant des variations d'amplitude importantes au cours du temps.

Ce jeu de données présente des variations marquées de niveau, susceptibles de correspondre à des changements de régime.

L'analyse de cette série permet ainsi d'évaluer les performances de la méthode proposée dans un contexte réel, sans information préalable sur la position exacte des éventuelles ruptures.

Méthode de détection

Contrairement au cas synthétique, le signal vrai θ^* est inconnu dans le cadre des données réelles. On ne peut donc pas calculer directement les différences sur θ^* .

À la place, on utilise l'estimateur $\hat{\theta}$ obtenu à l'aide des méthodes de seuillage étudiées dans la Partie I.

On calcule alors les différences successives sur le signal estimé :

$$\Delta_j = \hat{\theta}_{j+1} - \hat{\theta}_j, \quad j = 1, \dots, d-1$$

On applique ensuite le seuil validé :

$$\delta_{\text{seuil}} = 2\sqrt{\frac{\log(d)}{d}}$$

Un point de rupture est détecté à la position j si :

$$|\Delta_j| > \delta_{\text{seuil}}$$

Cette approche permet de détecter les ruptures directement à partir d'une version estimée et débruitée du signal.

Résultats et analyse




Figure 6: Série du débit du Nil et rupture détectée à l'aide des différences successives et du seuil δ_{seuil} .




Figure 7: Probabilité de détection d'une rupture pour chaque année par simulation Monte Carlo.

On observe plusieurs ruptures majeures dans la série, dont deux principales : la première autour de 1877–1878, et la seconde autour de 1898–1899. Le signal moyen avant et après ces dates présente des régimes distincts, confirmant des changements structurels.

La rupture de 1877–1878 peut être liée à un épisode de sécheresse majeur associé à un fort phénomène El Niño, entraînant une baisse exceptionnelle des crues du Nil. Celle de 1898–1899 coïncide avec le début des travaux d'aménagement du fleuve, notamment la construction du barrage d'Assouan, modifiant durablement le régime naturel et le cycle des crues.

Conclusion

Cette détection, basée sur le seuillage des différences successives sur le signal estimé, illustre la capacité de la méthode à identifier des ruptures réelles en série temporelle, en lien avec des faits historiques.