

Projet 4 : Régression en grande dimension et sparsité

FAGE Annaelle & PINA Ruben

Dans ce projet, on étudie l'impact de la régularisation en régression linéaire dans différents contextes : modèles sparse, modèles denses, prédicteurs corrélés et données réelles (California Housing). Nous comparons les performances de quatre méthodes de régression pénalisée : LASSO, Square-Root LASSO, Ridge et Elastic Net, en termes de sélection de variables et d'erreur de prédiction.

I. Introduction

On considère un modèle de régression linéaire

$$Y = X\beta + \eta,$$

où $X \in \mathbb{R}^{n \times p}$ est la matrice des prédicteurs, β le vecteur de vrais coefficients de dimension $p = 1500$ et η un bruit gaussien centré.

Nous comparons quatre modèles pénalisés :

— **LASSO** (pénalisation ℓ_1) :

$$\hat{\beta}^L = \arg \min_{\beta} L_{\lambda}(\beta) \quad \text{où} \quad L_{\lambda}(\beta) = \frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i,\cdot} \beta)^2 + \lambda \|\beta\|_1.$$

— **Square-Root LASSO** (pénalisation ℓ_1) :

$$\hat{\beta}^{SRL} = \arg \min_{\beta} S_{\lambda}(\beta) = \left(\frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i,\cdot} \beta)^2 \right)^{1/2} + \lambda \|\beta\|_1.$$

— **Ridge** (pénalisation ℓ_2) :

$$\hat{\beta}^R = \arg \min_{\beta} R_{\mu}(\beta) \quad \text{où} \quad R_{\mu}(\beta) = \frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i,\cdot} \beta)^2 + \frac{\mu}{2} \|\beta\|_2^2.$$

— **Elastic-Net** (mélange ℓ_1/ℓ_2) :

$$\hat{\beta}^{EN} = \arg \min_{\beta} F_{\lambda}(\beta) \quad \text{où} \quad F_{\lambda}(\beta) = \frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i,\cdot} \beta)^2 + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right).$$

Le paramètre de régularisation $\lambda > 0$ contrôle la force de la régularisation appliquée aux coefficients et $\alpha \in [0, 1]$ le compromis entre LASSO et Ridge pour l'Elastic Net.

Les hyperparamètres (λ, α) sont choisis par validation croisée sur un échantillon d'apprentissage, puis la performance est évaluée via l'erreur quadratique moyenne (MSE) sur un échantillon test.

II. Simulation avec des données simulées

II. a. 1er modèle : modèle sparse (peu de variables actives)

Nous simulons un modèle de grande dimension avec :

$$n = 1000, \quad p = 5000, \quad s = 15.$$

La matrice X est générée avec $X_{i,j} \sim \mathcal{N}(0, 1)$, et le vecteur de coefficients vrais est

$$\beta_1 = \dots = \beta_{15} = 1.$$

Le bruit η est gaussien standard et la variable réponse est donnée par

$$Y = X\beta + \eta.$$

Les données sont séparées en un jeu d'entraînement (environ 660) et un jeu de test (environ 340).

Chemin de régularisation du LASSO

Le chemin LASSO est obtenu en calculant les solutions pour une grille de valeurs de λ . Le graphique ci-dessous montre l'évolution des coefficients en fonction de $\log_{10}(\lambda)$.




FIGURE 1 – Chemin de régularisation du LASSO (modèle sparse, $s = 15$).

Pour des valeurs de λ élevées, tous les coefficients sont proches de zéro. Quand λ diminue, seuls quelques coefficients deviennent non nuls, ce qui illustre la capacité du LASSO à produire des solutions parcimonieuses adaptées à un modèle réellement clairsemé.

Choix des hyperparamètres et performances

Les hyperparamètres sont choisis par validation croisée (5 blocs) :

- LASSO : α (au sens de `scikit-learn` dans *Python*) optimisé par `ElasticNetCV` avec `l1_ratio = 1`,
- Square-Root LASSO : même idée que le LASSO,
- Ridge : λ optimisé par `RidgeCV` sur une grille logarithmique,
- Elastic Net : recherche conjointe de λ et de $\alpha \in \{0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9\}$.

Sur le jeu de test, nous comparons les MSE des quatre modèles. Dans ce cadre très sparse ($s \ll p$), le LASSO, le Square-Root LASSO et l'Elastic Net obtiennent une MSE plus faible que Ridge, ce qui est cohérent avec le fait qu'ils réalisent une sélection de variables explicite.

Ainsi, on retrouve que le meilleur λ / MSE pour chaque estimateur est :

	LASSO	Square-Root LASSO	Ridge	Elastic Net
λ	0.0994	0.1347	100.0000	0.1104 (avec $\alpha = 0.9$)
MSE	1.2627	1.2693	12.6523	1.3042

Donc, le meilleur estimateur pour ce modèle est : **LASSO**.

II. b. 2ème modèle : modèle dense (nombreuses variables actives)

Nous modifions ensuite le niveau de sparsité en prenant

$$s = 1500$$

tout en conservant $n = 1000$ et $p = 5000$. Les s premiers coefficients de β sont fixés à 1 ($\beta_1 = \dots = \beta_{1500} = 1$).

Le chemin de régularisation du LASSO montre qu'un grand nombre de coefficients deviennent non nuls lorsque λ diminue.




FIGURE 2 – Chemin LASSO pour un modèle dense ($s = 1500$).

Dans ce cadre, le LASSO peut être trop agressif en mettant à zéro un grand nombre de coefficients réellement non nuls. La comparaison des MSE sur le test montre que :

- Ridge devient plus compétitif, car la pénalisation ℓ_2 réduit les coefficients sans les annuler,
- l'Elastic Net offre un compromis entre parcimonie et stabilité, alors que le Square-Root LASSO donnent les meilleurs compromis.

Ainsi, on retrouve que le meilleur lambda / MSE pour chaque estimateur est :

	LASSO	Square-Root LASSO	Ridge	Elastic Net
λ	6.3374	0.1850	0.0100	0.0634 (avec $\alpha = 0.1$)
MSE	1437.6160	1439.4912	1221.4573	1206.2423

Donc, le meilleur estimateur pour ce modèle est : **Elastic Net**.

II. c. 3ème modèle : Prédicteurs corrélés

Nous considérons ensuite un cas de dimension modérée avec variables corrélées :

$$n = 100, \quad p = 50.$$

Les prédicteurs suivent une loi gaussienne multivariée $\mathcal{N}(0, a)$ avec comme matrice de covariance :

$$a = \text{cov}(X_{k,i}, X_{k,j}) = 0.7^{|i-j|}.$$

Le vecteur de coefficients vrais est défini par

$$\beta_1 = \beta_2 = 10, \quad \beta_3 = \beta_4 = 5, \quad \beta_5, \dots, \beta_{14} = 1, \quad \beta_j = 0 \text{ sinon.}$$

Le chemin LASSO montre que, en présence de fortes corrélations, le LASSO a tendance à sélectionner une seule variable dans un groupe de variables corrélées, ce qui peut rendre la sélection instable.




FIGURE 3 – Chemin LASSO avec prédicteurs corrélés.

La comparaison des MSE sur le jeu de test indique que l'Elastic Net, qui combine pénalisations ℓ_1 et ℓ_2 , peut améliorer la stabilité de la sélection par rapport au LASSO pur, tout en restant plus parcimonieux que Ridge. Néanmoins, le Square-Root LASSO reste plus parcimonieux qu'Elastic-Net tout en conservant une bonne précision.

Ainsi, on retrouve que le meilleur lambda / MSE pour chaque estimateur est :

	LASSO	Square-Root LASSO	Ridge	Elastic Net
λ	0.1195	0.1500	0.7543	0.1077 (avec $\alpha = 0.90$)
MSE	0.9620	0.9470	2.2412	0.9689

Donc, le meilleur estimateur pour ce modèle est : **Square-Root LASSO**.

III. Simulation avec des données réelles (*California Housing*)

III. a. Description et prétraitement

Nous utilisons le jeu de données *California Housing* (jeu de données qu'on a déjà utilisé lors du projet 1), qui décrit le prix médian des maisons en Californie. Les variables explicatives incluent notamment :

- revenu médian des ménages (**MedInc**),
- âge médian des maisons,
- nombre moyen de pièces et de chambres,
- population et occupation moyenne,
- latitude et longitude.

La variable cible est le prix médian des maisons.

Pour rendre la régularisation plus visible, nous sous-échantillonons à $n = 1000$ observations. Nous enrichissons ensuite les prédicteurs via des polynômes de degré 2 (carrés et interactions), ce qui fait passer le nombre de variables de 8 à 44. Toutes les variables sont finalement standardisées.

III. b. LASSO et sélection de variables

Le chemin de régularisation du LASSO permet de visualiser l'ordre d'entrée des variables et de leurs interactions lorsque λ décroît.




FIGURE 4 – Chemin LASSO sur le jeu de données California Housing.

Certaines variables, telles que le revenu médian ou la latitude/longitude, deviennent non nulles pour des valeurs de λ relativement élevées, ce qui indique un rôle important dans la prédiction du prix. Ainsi, on retrouve que le meilleur lambda pour chaque estimateur est :

	LASSO	Square-Root LASSO	Ridge	Elastic Net
λ	0.0015	0.1000	8.6851	0.0099 (avec $\alpha = 0.1$)

III. c. Comparaison LASSO / Square-Root LASSO / Ridge / Elastic Net

Information

Pour pouvoir faire une bonne comparaison avec les quatre modèles, nous allons utiliser le R^2 , appelé *coefficient de détermination*, qui est la métrique la plus courante pour évaluer la performance d'une régression en pourcentage.

Ainsi, plus le R^2 est proche de 1, plus le modèle prédit parfaitement toutes les valeurs, ce qui signifie que l'erreur est nulle. Mais attention, ceci est suspect sur des données réelles car il est souvent signe de sur-apprentissage.

Nous n'avons pas utilisé cette méthode dans le cas des données simulées car nous obtenions souvent des R^2 très élevés (proches de 0.9 ou 1.0).

Les quatre modèles sont ajustés par validation croisée (5 blocs). Sur le jeu de test, nous comparons la MSE, le R^2 et le nombre de variables actives (coefficients non nuls). Nous présentons un tableau récapitulatif pour chaque modèle, on a donc :

Modèle	MSE (test)	R^2	Nombre de variables actives
LASSO	0.434	0.711	24/44
Square-Root LASSO	0.625	0.583	6/44
Ridge	0.417	0.722	44/44
Elastic Net	0.415	0.724	39/44

En pratique, Ridge utilise toutes les variables, tandis que LASSO et Elastic Net réalisent une sélection automatique. De plus, Square-Root LASSO fournit une alternative interprétable avec une sélection plus stricte. Dans nos résultats, l'Elastic Net offre un compromis intéressant entre performance de prédiction (MSE plus faible) et parcimonie (nombre limité de variables actives).

Ainsi, le meilleur modèle pour notre jeu de données est : **Elastic-Net**.

III. d. Interprétation des coefficients et qualité de la prédiction

En ordonnant les coefficients d'Elastic Net par importance (valeur absolue), on identifie les prédicteurs les plus influents. On observe notamment que :

- le revenu médian (**MedInc**) a un effet positif important sur le prix des maisons,
- la localisation géographique (latitude/longitude et leurs interactions) joue un rôle majeur,
- certaines interactions polynomiales peuvent affiner le modèle.

Le graphe ci-dessous représente les prix prédits en fonction des prix réels, avec la diagonale $y = x$ comme référence. La dispersion des points autour de cette diagonale illustre la qualité de la prédiction.




FIGURE 5 – Prix prédits vs prix réels (Elastic Net).

IV. Conclusion

Sur les données simulées, nous avons montré que :

- pour un modèle très sparse, le LASSO, Square-Root LASSO et l'Elastic Net surpassent Ridge en termes de MSE,
- lorsque le signal devient plus dense, la pénalisation ℓ_2 (Ridge) ou un Elastic Net avec forte composante Ridge devient plus adapté,
- en présence de corrélations fortes entre prédicteurs, l'Elastic Net améliore la stabilité de la sélection par rapport au LASSO ; mais le Square-Root LASSO le dépasse en terme de MSE.

Sur les données réelles *California Housing*, la régularisation est essentielle pour contrôler la complexité induite par les termes polynomiaux. L'Elastic Net fournit un bon compromis entre performance de prédiction et interprétabilité, en identifiant un nombre restreint de variables et d'interactions ayant un impact significatif sur le prix des maisons.