

③

Chapitre 1: Modèle de densité

On a: $(\mathbb{R}, \mathcal{B}, (P_f, f \in \mathcal{F}))$

On observe un n-échantillon $X_1 \dots X_n$ de loi P_f (c'est-à-dire $X_i \stackrel{iid}{\sim} P_\theta$)

On veut estimer f .

Définition: Estimateur: Un estimateur $\hat{f}_n$ de f_n est une fonction mesurable des observations

$$\hookrightarrow \hat{f}_n(\cdot, X_1, \dots, X_n) = \hat{f}(\cdot).$$

Notation: $\mathbb{E}_f$: espérance sous P_f .

Var_f : variance sous P_f .

Qualité d'un estimateur: Pour $\hat{f}_n$.

Soit $x \in \mathbb{R}, h > 0$:

- **biais:** $\beta(\hat{f}_n(x)) = \mathbb{E}_f[\hat{f}_n(x)] - f(x)$
- **variance:** $\text{Var}_f(\hat{f}_n(x)) = \mathbb{E}_f[(\hat{f}_n(x) - \mathbb{E}_f[\hat{f}_n(x)])^2]$
 $= \mathbb{E}_f[\hat{f}_n^2(x)] - (\mathbb{E}_f[\hat{f}_n(x)])^2$
- **MSE (Mean Square Error):** $\text{MSE}(\hat{f}_n(x)) = \mathbb{E}_f[(f(x) - \hat{f}_n(x))^2]$.
- **MISE (Mean Integrated Square Error):** $\text{MISE}(\hat{f}_n) = \mathbb{E}_f[\int (f(x) - \hat{f}_n(x))^2 dx]$
 $= \mathbb{E}_f[\|f - \hat{f}_n\|_2^2]$
- **Risque:** $R(\hat{f}_n(x)) = \mathbb{E}_f[\omega(d(\hat{f}_n(x), f(x)))]$ où $\begin{cases} d \text{ est une distance} \\ \omega: \mathbb{R}_+ \rightarrow \mathbb{R}_+ \text{ tel que } \omega(0) = 0. \\ \hookrightarrow \omega(u) = u^2. \end{cases}$

Proposition: Décomposition Biais - Variance: $\text{MSE}(\hat{f}_n(x)) = \beta^2(\hat{f}_n(x)) + \text{Var}_f(\hat{f}_n(x))$.

Preuve: On a: $\text{MSE}(\hat{f}_n(x)) = \mathbb{E}_f[(f(x) - \mathbb{E}_f[\hat{f}_n(x)] + (\mathbb{E}_f[\hat{f}_n(x)] - \hat{f}_n(x)))^2]$
 $= \mathbb{E}_f[(f(x) - \mathbb{E}_f[\hat{f}_n(x)])^2] + \mathbb{E}_f[(\mathbb{E}_f[\hat{f}_n(x)] - \hat{f}_n(x))^2]$
 $+ 2 \mathbb{E}_f[(f(x) - \mathbb{E}_f[\hat{f}_n(x)])(\mathbb{E}_f[\hat{f}_n(x)] - \hat{f}_n(x))]$
 $= \mathbb{E}_f[\beta^2(\hat{f}_n(x))] + \text{Var}_f(\hat{f}_n(x)) + \cancel{2(f(x) - \mathbb{E}_f[\hat{f}_n(x)])(\mathbb{E}_f[\hat{f}_n(x)] - \hat{f}_n(x))}.$

① Estimateur à noyau

Fonction de répartition: $F(x) = \mathbb{P}(X \leq x)$

$$= \mathbb{E}[\mathbb{1}_{X \leq x}]$$

Fonction de répartition empirique: $\hat{F}_n(x) = \mathbb{E}[\mathbb{1}_{X \leq x}]$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{x_i \leq x}$$

- LFGN: $\hat{F}_n(x) \xrightarrow{ps} F(x), \forall x \in \mathbb{R}.$

④

$$\bullet \mathbb{P}(\sup_x |\hat{F}_n(x) - F(x)| > \varepsilon) \leq 2e^{-2\varepsilon^2 n}$$


Remarque: $f(x) = F'(x)$

$$= \lim_{h \rightarrow 0} \frac{F(x+h) - F(x)}{h} = \lim_{h \rightarrow 0} \frac{F(x+h) - F(x-h)}{2h}$$

Rosenblatt (1956): Pour $h > 0$ petit, on a: $f(x) \simeq \frac{F(x+h) - F(x-h)}{2h}$.

On considère: $\hat{f}_h(x) = \frac{\hat{F}_h(x+h) - \hat{F}_h(x-h)}{2h}$

$$\begin{aligned} &= \frac{1}{2h} \cdot \frac{1}{n} \left(\sum_{i=1}^n \mathbb{1}_{x_i \leq x+h} - \mathbb{1}_{x_i \leq x-h} \right) \\ &= \frac{1}{2nh} \cdot \sum_{i=1}^n \mathbb{1}_{x-h \leq x_i \leq x+h} \\ &= \frac{1}{2nh} \sum_{i=1}^n \mathbb{1}_{-1 \leq \frac{x_i - x}{h} \leq 1} \\ &= \frac{1}{nh} \sum_{i=1}^n K_0\left(\frac{x_i - x}{h}\right) \text{ car } K_0 \text{ admet une densité} \\ &= \frac{1}{nh} \sum_{i=1}^n K_0(u) \text{ où } K_0(u) = \frac{1}{2} \mathbb{1}_{|u| \leq 1} \end{aligned}$$



Définition: Estimateur à noyau: Parzen (1962).

On a $\hat{f}_{n,h}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x_i - x}{h}\right)$ où $\begin{cases} K \text{ est un noyau tel que } \int K = 1 \\ h > 0 \text{ fenêtre} \end{cases}$

Exemples de noyaux:

- 1) $K = K_0$ noyau rectangulaire
- 2) $K(u) = (1 - |u|) \cdot \mathbb{1}_{|u| \leq 1}$ noyau triangulaire
- 3) $K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}$ noyau gaussien

Objectif: Choisir h qui assure le MSE le plus petit $\rightarrow$ optimisateur de $\text{MSE}(\hat{f}_h)$ en h .

Calcul de Variance

Proposition: Supposons: $\begin{cases} f \text{ bornée: } \exists M > 0 \text{ tel que } |f(x)| < M, \forall x \in \mathbb{R} \\ K \text{ noyau tel que } \int K = 1 \text{ et } \int K^2 < \infty. \end{cases}$

Alors, $\forall x \in \mathbb{R}$ fixé, $\forall n \geq 1$, $\forall h > 0$, $\text{Var}_f(\hat{f}_{n,h}(x)) \leq \frac{C_1}{nh}$ où C_1 est une constante qui dépend de M et K (mais pas de n et h).

Preuve: $\text{Var}_f(\hat{f}_{n,h}(x)) = \mathbb{E}_f\left[\left(\hat{f}_{n,h}(x) - \mathbb{E}_f[\hat{f}_{n,h}(x)]\right)^2\right]$

$$\begin{aligned} &= \frac{1}{n^2 h^2} \mathbb{E}_f\left[\left(\sum_{i=1}^n K\left(\frac{x_i - x}{h}\right) - \mathbb{E}_f\left[K\left(\frac{x_i - x}{h}\right)\right]\right)^2\right] \\ &= \frac{1}{n^2 h^2} \mathbb{E}_f\left[\left(\sum_{i=1}^n Z_i\right)^2\right] \\ &= \frac{1}{n^2 h^2} \mathbb{E}_f\left[\sum_{i=1}^n Z_i^2 + 2 \sum_{i < j} Z_i Z_j\right] \quad \left. \begin{array}{l} \text{car } Z_i \text{ indépendants et identiquement} \\ \text{distribués, } \mathbb{E}[Z_i] = 0. \\ \text{et } \mathbb{E}[Z_i] \mathbb{E}[Z_j] = 0 \end{array} \right\} \\ &= \frac{1}{n^2 h^2} \sum_{i=1}^n \mathbb{E}_f[Z_i^2] + \frac{2}{n^2 h^2} \sum_{i < j} \mathbb{E}_f[Z_i Z_j] \\ &= \frac{1}{n^2 h^2} \sum_{i=1}^n \mathbb{E}_f[Z_i^2] \text{ car iid} \\ &= \frac{1}{nh^2} \text{Var}_f(Z_1) \quad (\text{Var}(Z_1) = \mathbb{E}[Z_1^2] - (\mathbb{E}[Z_1])^2 = \mathbb{E}[Z_1^2]) \\ &= \frac{1}{nh^2} \text{Var}_f\left(K\left(\frac{x_1 - x}{h}\right) - \mathbb{E}\left[K\left(\frac{x_1 - x}{h}\right)\right]\right) \end{aligned}$$

⑤

$$\begin{aligned}
 &= \frac{1}{nh^2} \text{Var}_f \left(K \left(\frac{X_i - x}{h} \right) \right) \\
 &\leq \frac{1}{nh^2} \mathbb{E}_f \left[K^2 \left(\frac{X_i - x}{h} \right) \right] \\
 &= \frac{1}{nh^2} \int_{\mathbb{R}} K^2 \left(\frac{z - x}{h} \right) f(z) dz \quad \left\{ \begin{array}{l} \text{Changement de variable:} \\ u = \frac{z - x}{h} \end{array} \right. \\
 &= \frac{1}{nh^2} \int_{\mathbb{R}} K^2(u) f(x + uh) h du \\
 &\leq \frac{1}{nh} \int_{\mathbb{R}} K^2(u) \underbrace{f(x + uh)}_{\leq M} du \\
 &\leq \frac{1}{nh} \cdot M \int_{\mathbb{R}} K^2
 \end{aligned}$$

Contrôle de Biais

Soit $\beta, L > 0$.

Hypothèse: $f \in \mathcal{F}(\beta, L) \Leftrightarrow f: f^{(l)}$ existe et $|f^{(l)}(x) - f^{(l)}(y)| \leq L|x - y|^{\beta - l}$ où $l = \lfloor \beta \rfloor$

Rappel: $\lfloor 1.5 \rfloor = 1$ et $\lfloor 4 \rfloor = 3$ avec $\lfloor \cdot \rfloor$: partie entière inférieure

Remarque: hypothèse implicite: f densité donc $\int f = 1, f \geq 0$

Hypothèse: K noyau d'ordre ℓ : $\int K = 1, \forall j \in \{1, \dots, \ell\}, \int u^j K(u) du = 0$.

Proposition: Supposons: $\left\{ \begin{array}{l} f \in \mathcal{F}(\beta, L) \\ K \text{ noyau d'ordre } \ell = \lfloor \beta \rfloor \text{ tel que } \int |u|^\beta |K(u)| du < \infty. \end{array} \right.$

Alors $\exists C_2 > 0$ (indépendante de u et h) tel que $|\beta(\hat{f}_{n,h}(x))| \leq C_2 h^\beta$.

Preuve:
$$\begin{aligned}
 \beta(\hat{f}_{n,h}(x)) &= \frac{1}{nh} \sum_{i=1}^n \mathbb{E} \left[K \left(\frac{X_i - x}{h} \right) \right] - f(x) \\
 &= \frac{1}{n} \mathbb{E} \left[K \left(\frac{X_1 - x}{h} \right) \right] - f(x).
 \end{aligned}$$

On a: 1) $\mathbb{E} \left[K \left(\frac{X_1 - x}{h} \right) \right] = \int_{\mathbb{R}} K \left(\frac{z - x}{h} \right) f(z) dz$ Changement de variable $u = \frac{z - x}{h}$

$$= h \int_{\mathbb{R}} K(u) f(x + uh) du$$

2) $f(x) \stackrel{\int K=1}{=} \int_{\mathbb{R}} K(u) f(x) du$

Donc $\beta(\hat{f}_{n,h}(x)) = \int_{\mathbb{R}} K(u) (f(x + uh) - f(x)) du$.

15/09/25

Développement limité à l'ordre ℓ en x :

$\exists \tau \in (0, 1)$ tel que $f(x + uh) = f(x) + \frac{f'(x)}{1!} uh + \dots + \frac{f^{(\ell-1)}(x)}{(\ell-1)!} (uh)^{\ell-1} + \frac{f^{(\ell)}(x + \tau uh)}{\ell!} (uh)^\ell$.

Donc:
$$\begin{aligned}
 \beta(\hat{f}_{n,h}(x)) &= \sum_{j=1}^{\ell-1} \int_{\mathbb{R}} K(u) \frac{f^{(j)}(x)}{j!} (uh)^j du + \int_{\mathbb{R}} K(u) \frac{f^{(\ell)}(x + \tau uh)}{\ell!} (uh)^\ell du \\
 &= \sum_{j=1}^{\ell-1} \frac{f^{(j)}(x)}{j!} h^j \underbrace{\int_{\mathbb{R}} K(u) u^j du}_{=0} + \frac{h^\ell}{\ell!} \int_{\mathbb{R}} K(u) u^\ell f^{(\ell)}(x + \tau uh) du
 \end{aligned}$$

①: $= 0$ car K noyau d'ordre ℓ et $j \in \{1, \dots, \ell-1\}$.

$$\begin{aligned}
 &= \frac{h^\ell}{\ell!} \int_{\mathbb{R}} K(u) u^\ell f^{(\ell)}(x + \tau uh) du - \frac{h^\ell}{\ell!} \int_{\mathbb{R}} K(u) u^\ell f^{(\ell)}(x) du \\
 &= \frac{h^\ell}{\ell!} \int_{\mathbb{R}} K(u) u^\ell (f^{(\ell)}(x + \tau uh) - f^{(\ell)}(x)) du
 \end{aligned}$$

Donc:
$$\begin{aligned}
 |\beta(\hat{f}_{n,h}(x))| &\leq \frac{h^\ell}{\ell!} \left| \int_{\mathbb{R}} K(u) u^\ell (f^{(\ell)}(x + \tau uh) - f^{(\ell)}(x)) du \right| \\
 &\leq \frac{h^\ell}{\ell!} \int_{\mathbb{R}} |K(u) u^\ell (f^{(\ell)}(x + \tau uh) - f^{(\ell)}(x))| du
 \end{aligned}$$

⑥

$$= \frac{h^e}{e!} \int |K(u)| |u|^e |f^{(e)}(x + \tau u h) - f^{(e)}(x)| du$$

$$\leq \frac{h^e}{e!} L \int |K(u)| |u|^\beta du$$

② $\leq L |\tau u h|^{\beta-e}$ par hypothèse

D'où le résultat en notant $c_2 = \frac{L}{e!} \int |K(u)| |u|^\beta du$.

Majoration du risque

Théorème: Majoration du MSE: Si $f \in \Sigma(\beta, L)$, $\beta, L > 0$.

Si K noyau d'ordre $\ell = \lfloor \beta \rfloor$ tel que: $\int K^2 < \infty$
 $\int |K(u)| |u|^\beta < \infty$.

Alors pour $h = \lambda n^{-\frac{1}{2\beta+1}}$ avec $\lambda > 0$, $MSE(\hat{f}_h(x)) \leq C n^{-\frac{2\beta}{2\beta+1}}$, où $C > 0$ est une constante qui ne dépend ni de n , ni de h .

Preuve: On a: $MSE(\hat{f}_h(x)) = B^2(\hat{f}_h(x)) + Var(\hat{f}_h(x))$
 $\leq C_2 h^{2\beta} + \frac{C_1}{nh} := G(h)$

Et $G(h) \rightarrow \min_h$

G convexe: Donc h^* qui assure le min $G(h)$ est tel que $G'(h^*) = 0$.

On a: $G'(h) = 2\beta C_2 h^{2\beta-1} - \frac{C_1}{nh^2}$.

Donc $G'(h^*) = 0 \Leftrightarrow (h^*)^{2\beta+1} = \frac{C_1}{2\beta C_2} \cdot \frac{1}{n}$

$\Leftrightarrow h^* = \left(\frac{C_1}{2\beta C_2} \right)^{\frac{1}{2\beta+1}} \cdot n^{-\frac{1}{2\beta+1}}$.

C'est-à-dire, $h^* = \lambda n^{-\frac{1}{2\beta+1}}$ avec $\lambda = \left(\frac{C_1}{2\beta C_2} \right)^{\frac{1}{2\beta+1}}$.


On injecte cette valeur dans $G(h)$ et on obtient: $G(h^*) = C_2 \lambda^{2\beta} n^{-\frac{2\beta}{2\beta+1}} + \frac{C_1}{n \lambda n^{-\frac{1}{2\beta+1}}}$.

Donc: $G(h^*) = C_2 \lambda^{2\beta} n^{-\frac{2\beta}{2\beta+1}} + \frac{C_1}{\lambda} \cdot \frac{1}{n^{\frac{1}{2\beta+1}}}$
 $= (C_2 \lambda^{2\beta} + \frac{C_1}{\lambda}) n^{-\frac{2\beta}{2\beta+1}}$.

Remarques:

1) Borne uniforme: $\sup_{f \in \Sigma(\beta, L)} MSE(\hat{f}_n(x)) \leq C n^{-\frac{2\beta}{2\beta+1}}, \forall x \in \mathbb{R}$.

2) Graphique:



3) $MSE(\hat{f}_n(x)) = E_f[(\hat{f}_n(x) - f(x))^2]$

$\sup_{f \in \Sigma(\beta, L)} (E_f[(\hat{f}_n(x) - f(x))^2])^{1/2} \leq C \cdot \psi_n$ avec $\psi_n = n^{-\frac{\beta}{2\beta+1}}$ (vitesse de convergence de $\hat{f}_n$ pour le risque L_2)

4) Attention: Cette vitesse est optimale.

En effet, on peut montrer que: $\exists c > 0$ tel que $\inf_{\tilde{f}} \sup_{f \in \Sigma(\beta, L)} MSE(\tilde{f}(x)) \geq c \cdot \psi_n^2$
 ①: inf sur tous les estimateurs

③

$$5) \psi_n = n^{-\frac{2\beta}{2\beta+4}} \text{ et } \underbrace{n^{-\frac{1}{2}}}_{\beta \rightarrow \infty} \leq \psi_n \leq \underbrace{\text{Constante}}_{\beta \rightarrow 0}$$

②: TCL (version paramétrique)

6) Majoration de la MISE:

En supposant plus de régularité ($f \in \mathcal{H}(\beta, L)$ qui est une version intégrée de $\Sigma(\beta, L)$), on peut montrer que: $\sup_{f \in \mathcal{H}(\beta, L)} \text{MISE}(\hat{f}_h) \leq C n^{-\frac{2\beta}{2\beta+4}}$ pour $h = \lambda n^{-\frac{1}{2\beta+4}}, K, X_1, \dots, X_n$.

④ Validation croisée

$$\text{On a: } \hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right).$$

h fourni par le théorème précédent ($h = \lambda n^{-\frac{1}{2\beta+4}}$) dépend de β et donc de f qui est inconnue.

On veut une approche qui détermine h de manière adaptative (dépend des données).

On va utiliser la validation croisée qui est basée ici sur l'estimation sans biais du risque (on va prendre la MISE): $h_{id} = \arg\min_h \text{MISE}(\hat{f}_h)$.

$$\begin{aligned} \text{On a } \text{MISE}(\hat{f}_h) &= \mathbb{E}[\sum (\hat{f}_h - f)^2] \\ &= \mathbb{E}[\sum \hat{f}_h^2] + \sum f^2 - 2\mathbb{E}[\sum \hat{f}_h f]. \end{aligned}$$

$$\text{On note: } \mathfrak{J}(h) = \mathbb{E}[\sum \hat{f}_h^2] - 2\mathbb{E}[\sum \hat{f}_h f].$$

Attention: $\text{MISE}(\hat{f}_{h_{id}}) \neq \mathfrak{J}(h_{id})$, mais: $\arg\min_{h>0} \text{MISE}(\hat{f}_h) = \arg\min_{h>0} \mathfrak{J}(h)$.

Il suffit donc de trouver un estimateur sans-biais (ESB) de $\mathfrak{J}(h)$.

On montre que $CV(h) = \sum \hat{f}_h^2 - \frac{2}{n} \sum_{i=1}^n \hat{f}_h^{-i}(X_i)$ avec $\hat{f}_h^{-i}(x) = \frac{1}{(n-1)h} \sum_{j=1, j \neq i}^n K\left(\frac{X_j - x}{h}\right)$ est un ESB de $\mathfrak{J}(h)$.

Exercice: Montrons que $CV(h)$ est un ESB de $\mathfrak{J}(h)$.

$$\hat{h}_{cv} = \arg\min_h cv(h)$$

$$\text{Par suite, on estime } f(x) \text{ par: } \hat{f}_{\hat{h}_{cv}}(x) = \frac{1}{n\hat{h}_{cv}} \sum_{i=1}^n K\left(\frac{X_i - x}{\hat{h}_{cv}}\right).$$

Attention: $\hat{h}_{cv}$ est une variable aléatoire

On peut montrer (Stone, 1984): $\text{MISE}(\hat{f}_{\hat{h}_{cv}}) - \text{MISE}(\hat{f}_{h_{id}}) \xrightarrow[n \rightarrow \infty]{p.s.} 0$.

