

## Chapitre 2: Régression non-paramétrique

$$(X_i, Y_i), i = 1, \dots, n \text{ tel que } Y_i = \underbrace{f(X_i)}_{\text{réponse}} + \underbrace{\xi_i}_{\substack{\text{variables} \\ \text{explicatives}}} \text{ avec } \xi_i \stackrel{\text{iid}}{\sim} \begin{cases} \mathbb{E}[\xi_i | X_i] = 0. \\ \text{Var}(\xi_i) = \sigma^2 < \infty. \end{cases}$$

$f$ : fonction de régression inconnue avec  $f \in \mathcal{F}$ ,  $f(x) = \mathbb{E}[Y_i | X_i = x]$ .

Si les  $X_i$  sont déterministe, on parle de effet fixe / desing déterministe.

Exemple:  $X_i = \frac{i}{n}$ .

### ① Estimation par projection

$$f \in L^2([0, 1]) (X_i \in [0, 1])$$

$n$ : taille de l'échantillon,  $N$ : ordre de l'échantillon

Base orthonormale de  $L_2([0, 1])$ :  $\{\varphi_j\}_{j \geq 1}$ .

Hypothèse.  $f(x) = \sum_{j \geq 1} \underbrace{\theta_j}_{\text{coefficient}} \varphi_j(x)$  où  $\theta_j = \underbrace{\langle f, \varphi_j \rangle}_{\text{inconnu}}_{L_2([0, 1])}$   
 $= \int_0^1 f(x) \varphi_j(x) dx$

On estime  $f(x)$  par  $\hat{f}_N(x) = \sum_{j=1}^N \hat{\theta}_j \varphi_j(x)$  où  $\hat{\theta}_j = \frac{1}{n} \sum_{i=1}^n Y_i \varphi_j(X_i)$ .

### Qualité de l'échantillon

Commençons par calculer l'espérance de  $\hat{\theta}_j$ .

Supposons  $X_i$  déterministe par rapport à la densité

On a donc:  $\mathbb{E}[\hat{\theta}_j] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[Y_i \varphi_j(X_i)]$   
 $= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\underbrace{\mathbb{E}[Y_i | X_i]}_{\text{①}} \varphi_j(X_i)]$ .

Et ① =  $\mathbb{E}[f(X_i) + \xi_i | X_i]$   
 $= f(X_i) + \mathbb{E}[\xi_i | X_i]$

Donc  $\mathbb{E}[\hat{\theta}_j] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[f(X_i) \varphi_j(X_i)]$ .

Cas 1:  $X_i \stackrel{\text{iid}}{\sim} \mathcal{U}([0, 1])$ ,  $\mathbb{E}[\hat{\theta}_j] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[f(X_i) \varphi_j(X_i)]$  car iid  
 $= \int_0^1 f(x) \varphi_j(x) dx := \theta_j$

↳  $\hat{\theta}_j$  ESB de  $\theta_j$

Cas 2:  $X_i = \frac{i}{n}$ ,  $\mathbb{E}[\hat{\theta}_j] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[f(X_i) \varphi_j(X_i)]$   
 $= \frac{1}{n} \sum_{i=1}^n f(\frac{i}{n}) \varphi_j(\frac{i}{n})$   
 $\xrightarrow{n \rightarrow \infty} \int f(x) \varphi_j(x) dx := \theta_j$

↳  $\hat{\theta}_j$  semble être un "bon" estimateur de  $\theta_j$ .

## Contrôle du biais et de la variance

Pour simplifier, on suppose  $X_i = \frac{i}{n}$ .

Notation:  $a_j = \mathbb{E}[\hat{\theta}_j] - \theta_j$  : biais

$$= \frac{1}{n} \sum_{i=1}^n f\left(\frac{i}{n}\right) \varphi_j\left(\frac{i}{n}\right) - \int f(x) \varphi_j(x) dx.$$

$$\text{MISE}(\hat{f}_N) = \mathbb{E}[\|\hat{f}_N - f\|_{L^2}^2]$$

$$= \mathbb{E}[\int_0^1 (\hat{f}_N(x) - f(x))^2 dx]$$

$$\begin{aligned} \hat{f}(x) - f(x) &= \sum_{j=1}^N \hat{\theta}_j \varphi_j(x) - \sum_{j=1}^N \theta_j \varphi_j(x) \\ &= \sum_{j=1}^N (\hat{\theta}_j - \theta_j) \varphi_j(x) - \sum_{j=N+1}^{\infty} \theta_j \varphi_j(x). \end{aligned}$$

$$\text{Donc } \int_0^1 (\hat{f}_N(x) - f(x))^2 dx = \int_0^1 \sum_{j=1}^N (\hat{\theta}_j - \theta_j)^2 \varphi_j^2(x) dx + \int \sum_{j=N+1}^{\infty} \theta_j^2 \varphi_j^2(x) dx \quad \Delta$$

$$\int \varphi_j^2 \rightarrow \sum_{j=1}^N (\hat{\theta}_j - \theta_j)^2 + \sum_{j=N+1}^{\infty} \theta_j^2.$$

$$\text{Ainsi: } \mathbb{E}[\|\hat{f}_N - f\|_{L^2}^2] = \sum_{j=1}^N \underbrace{\mathbb{E}[(\hat{\theta}_j - \theta_j)^2]}_{\text{bias}^2} + \sum_{j=N+1}^{\infty} \underbrace{\theta_j^2}_{\text{bias}^2}.$$

Attention: Tous les produits croisés sont égaux à 0 car la base  $\{\varphi_j\}_{j \geq 1}$  est orthogonale.

$$\text{Or, } \mathbb{E}[(\hat{\theta}_j - \theta_j)^2] = \text{Var}(\hat{\theta}_j^2) + \underbrace{\beta^2(\hat{\theta}_j)}_{\text{bias}^2 - 2}.$$

32/09/25

Rappel: Notation:  $\beta(\hat{\theta}_j) =: a_j$

$$= \frac{1}{n} \sum_{i=1}^n f\left(\frac{i}{n}\right) \varphi_j\left(\frac{i}{n}\right) - \int f(x) \varphi_j(x) dx$$

Base trigonométrique:

$$\begin{cases} \varphi_1 \equiv 1 \\ \varphi_{2k} = \sqrt{2} \cdot \cos(2\pi k x) \\ \varphi_{2k+1} = \sqrt{2} \cdot \sin(2\pi k x) \end{cases}$$

Lemme:  $\langle \varphi_j, \varphi_k \rangle = \delta_{jk}, \forall j, k$

$$\frac{1}{n} \sum_{i=1}^n \varphi_j\left(\frac{i}{n}\right) \varphi_k\left(\frac{i}{n}\right) = \delta_{jk}, \forall j, k \in \{1, \dots, n-1\}.$$

Preuve: Euler +  $\sum$  (somme).

Définition: Espaces de Sobolev: Soit  $m \in \mathbb{N}^*, L > 0$ .

On a  $W_{(0,1)}^{\text{per}}(m, L) = \{f: [0,1] \rightarrow \mathbb{R} : f \text{ est } m \text{ fois différentiable, } \|f^{(m)}\|_{L^2} \leq L \text{ et } f^{(j)}(0) = f^{(j)}(1), \\ \forall j \in \{0, \dots, m-1\}.$

Lemme: Soit  $m \in \mathbb{N}^*, L > 0$ .

On a  $f \in W_{(0,1)}^{\text{per}}(m, L)$  si et seulement si les coefficients de Fourier de  $f$  appartiennent à

$$W = \left\{ \theta_j \right\}_{j \geq 1} : \sum_{j \geq 1} \theta_j^2 < \infty, \sum_{j \geq 1} \theta_j^2 v_j^2 < \frac{L^2}{\pi^{2m}} \quad \text{avec } \begin{cases} v_j^m & \text{si } m \text{ est pair} \\ (j-1)^m & \text{si } m \text{ est impair} \end{cases}$$

Preuve: Exercice

Proposition:  $\{\varphi_j\}$  base trigonométrique,  $\theta_j = \langle f, \varphi_j \rangle$  tel que  $\sum_{j=1}^n |\theta_j| < \infty$ .

Alors :

1)  $E[\hat{\theta}_j] = a_j + \theta_j$

2)  $E[(\hat{\theta}_j - \theta_j)^2] = \frac{\sigma^2}{n} + a_j^2, \forall j \in \{1, \dots, n-1\}$

Preuve:

1) évident, c'est la définition de  $a_j = E[\hat{\theta}_j] - \theta_j$  (biais)

2) On a  $E[(\hat{\theta}_j - \theta_j)^2] = \text{Var}(\hat{\theta}_j) + \underbrace{\beta^2(\theta_j)}_{a_j^2}$  et  $\text{Var}(\hat{\theta}_j) = \text{Var}(\frac{1}{n} \sum_{i=1}^n Y_i \varphi_j(\frac{i}{n}))$   
 $= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i \varphi_j(\frac{i}{n}))$   
 $= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) \varphi_j^2(\frac{i}{n})$   
 $= \frac{\sigma^2}{n^2} \underbrace{(\frac{1}{n} \sum_{j=1}^n \varphi_j^2(\frac{i}{n}))}_{=1 \text{ (lemme)}} \times n = \frac{\sigma^2}{n}.$

Proposition:

1) Si  $\sum |\theta_j| < \infty$ , on a  $\max_{1 \leq j \leq n-1} |a_j| \leq 2 \sum_{k \geq n} |\theta_k|$

2) Si  $\{\theta_j\} \in W(m, L)$ , alors  $\max_{1 \leq j \leq n-1} |a_j| \leq C(m, L) n^{-m+1/2}$

Preuve:

1) Soit  $j \in \{1, \dots, m-1\}$ , on a  $a_j = E[\hat{\theta}_j] - \theta_j$

$$\begin{aligned} &= \frac{1}{n} \sum_{i=1}^n E[Y_i] \varphi_j(\frac{i}{n}) - \theta_j \\ &\stackrel{Y_i = f(\frac{i}{n}) \xi_i}{\Rightarrow} \frac{1}{n} \sum_{i=1}^n f(\frac{i}{n}) \varphi_j(\frac{i}{n}) - \theta_j \\ &\stackrel{f(\cdot) = \sum_{k \geq 1} \theta_k \varphi_k(\cdot)}{\Rightarrow} \frac{1}{n} \sum_{i=1}^n \sum_{k \geq 1} \theta_k \varphi_k(\frac{i}{n}) \varphi_j(\frac{i}{n}) - \theta_j \\ &= \sum_{k \geq 1} (\frac{1}{n} \sum_{i=1}^n \varphi_j(\frac{i}{n}) \varphi_k(\frac{i}{n})) \theta_k - \theta_j. \\ &\stackrel{\text{lemme pour } j \leq n-1}{=} \sum_{k=1}^{m-1} \delta_{jk} \theta_k + \sum_{k \geq n} (\frac{1}{n} \sum_{i=1}^n \varphi_j(\frac{i}{n}) \varphi_k(\frac{i}{n})) \theta_k - \theta_j \\ &\stackrel{j \text{ est fixé, le reste } \Rightarrow}{=} \theta_j + \sum_{k \geq n} (\frac{1}{n} \sum_{i=1}^n \varphi_j(\frac{i}{n}) \varphi_k(\frac{i}{n})) \theta_k - \theta_j = \sum_{k \geq n} (\frac{1}{n} \sum_{i=1}^n \varphi_j(\frac{i}{n}) \varphi_k(\frac{i}{n})) \theta_k \end{aligned}$$

Donc,  $\forall j \in \{1, \dots, m-1\}, |a_j| \leq \frac{1}{n} \sum_{i=1}^n \sum_{k \geq n} \underbrace{|\varphi_j(\frac{i}{n})|}_{\leq \sqrt{2}} \cdot \underbrace{|\varphi_k(\frac{i}{n})|}_{\leq \sqrt{2}} \cdot |\theta_k|$   
 $= 2 \cdot \frac{1}{n} \sum_{k \geq n} \sum_{i=1}^n |\theta_k| \leq 2 \sum_{k \geq n} |\theta_k|$

2) Il suffit de montrer que  $2 \sum_{k \geq n} |\theta_k| \leq C(m, L) n^{-m+1/2}$

On a :  $\sum_{k \geq n} |\theta_k| \leq \frac{1}{n} \leq (\sum_{k \geq m} v_k^2 \theta_k^2)^{1/2} \cdot (\sum_{k \geq m} \frac{1}{v_k^2})^{1/2}$

④ :  $\sum_{n \geq 1} v_k^2 \theta_k^2 \leq \frac{L^2}{\pi^2 n}$

On a :  $(\sum_{k \geq n} v_k^2 \theta_k^2)^{1/2} \leq \frac{L}{\pi n}$  et  $\sum_{k \geq n} \frac{1}{v_k^2} \leq \sum_{k \geq n} \frac{1}{(k-1)^{2m}}$   
 $\leq \frac{1}{(n-1)^{2m}} + \int_n^\infty \frac{1}{(x-1)^{2m}} dx$   
 $\leq \dots \leq C \cdot n^{-2m+1}$

Conclusion:  $\max_{1 \leq j \leq n-1} |a_j| \leq 2 \sum_{k \geq n} |\theta_k|$   
 $\leq \frac{2L}{\pi n} C^{1/2} n^{-n+1/2}.$

Théorème:  $\{\varphi_j\}$  trigonométrique,  $m \in \mathbb{N}^*, L > 0$  et  $N = \lfloor \alpha n^{1/2m+1} \rfloor$  (partie entière).

(12)

Alors:  $\sup_{j \in \mathcal{W}_{\text{Pois}}(m, L)} \mathbb{E}[\|\hat{f}_N - f\|_2^2] \leq C_2(m, L) n^{-\frac{2m}{2m+4}}.$

Preuve: D'après les propriétés précédentes, on a:  $\text{MISE}(\hat{f}_N) \leq \sum_{j=1}^N \left( \underbrace{\frac{\sigma^2}{n} + \alpha_j^2}_{\text{Var}(\hat{\theta}_j)} + \sum_{j \geq N} \underbrace{a_j^2 + \theta_j^2}_{\text{biais 1}} \right)$   
 $= \sum_{j=1}^N \frac{\sigma^2}{n} + 2 \sum_{j=1}^N \underbrace{a_j^2}_{\text{biais 2}} + \sum_{j \geq N} \theta_j^2$   
 $\leq \frac{N\sigma^2}{n} + 2 \sum_{j=1}^N C_1^2(m, L) n^{-2m+1} + \sum_{j \geq N} \theta_j^2$

Attention:  $N < n$  car  $N = \alpha \lfloor \frac{1}{n^{2m+4}} \rfloor$

Remarques:

1) On a  $n^{-2m+1} < n^{-1}$

Donc  $\exists \tilde{C} > 0, \frac{N\sigma^2}{n} + 2 \sum_{j=1}^N C_1^2(m, L) n^{-2m+1} \leq \tilde{C} \frac{N}{n}$

2)  $\sum_{j \geq N} \theta_j^2 \leq \frac{1}{N^2} \sum_{j \geq N} \theta_j^2 \leq \frac{1}{(N-1)^{2m}} \cdot \frac{L^2}{\pi^{2m}} \leq \bar{C} \cdot N^{-2m}.$

Ainsi,  $\text{MISE}(\hat{f}_N) \leq \tilde{C} \cdot \frac{N}{n} + \bar{C} \cdot N^{-2m}$

Et  $G(N) \rightarrow \min_N \text{MISE}(\hat{f}_N), N^* = \alpha \cdot N^{\frac{1}{2m+4}}$  et  $\text{MISE}(\hat{f}_N) \leq C \cdot n^{-\frac{2m}{2m+4}}.$

Remarques:

1)  $(\theta_1, \dots, \theta_N) \sim N^* \leq m.$

2) Variante de l'estimateur par projection:  $\hat{f}_N(x) = \sum_{j=1}^N \lambda_j \hat{\theta}_j \varphi_j(x).$

\*  $\lambda_j = \mathbb{1}_{\{j \leq N^*\}}$ : projection classique

\*  $\lambda_j = (1 - (\frac{j}{N})^m)_+$   $\rightarrow$  estimateur de Pinsker.

$j < N$ :  $\frac{j}{N} < 1, (\frac{j}{N})^m \xrightarrow{m \rightarrow \infty} 0$  et du coup  $(1 - (\frac{j}{N})^m)_+ \rightarrow 1$

$\hookrightarrow$  coefficients à prendre en compte

$j > N$ :  $\frac{j}{N} > 1, (\frac{j}{N})^m > 1$ , et donc  $(1 - (\frac{j}{N})^m)_+ = 0, \forall m.$

$\hookrightarrow$  On ne prend pas en compte les coefficients

3) Choix de  $\{\varphi_j\}$  est important

D'autres choix existent: 

- ondelettes (voir base de Haar)

- Legendre

### (13) Estimateur à noyau de la régression linéaire

On a  $Y_i = f(X_i) + \xi_i$  avec  $X_i \in [0, 1].$

$X_i$  admet une densité  $g, g: [0, 1] \rightarrow \mathbb{R}_+.$

Fonction de régression:  $f(x) = \mathbb{E}[Y|X=x].$

Donc:  $f(x) = \int y f_{Y|X}(y|x) dy$   
 $= \int y \frac{f_{(Y,X)}(x, y)}{g(x) = f_X(x)} dy.$

Soit  $K$  un noyau symétrique (ordre 1)

13) Alors, on estime  $g(x)$  par:  $\hat{g}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)$ .

On utilise le même noyau pour estimer la densité jointe  $f_{(x,y)}(x,y)$  par:

$$\hat{f}_n^{(x,y)}(x,y) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K\left(\frac{X_i - x}{h}\right) \frac{1}{h} K\left(\frac{Y_i - y}{h}\right)$$

On estime alors  $f(x)$  par plug-in et on obtient:  $\hat{f}_n(x) = \frac{\frac{1}{nh^2} \sum_{i=1}^n \int y K\left(\frac{X_i - x}{h}\right) K\left(\frac{Y_i - y}{h}\right) dy}{\frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}$

$$= \frac{1}{h} \cdot \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) \int y K\left(\frac{Y_i - y}{h}\right) dy}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}$$

Remarque:  $\int_{\mathbb{R}} y K\left(\frac{Y_i - y}{h}\right) dy \stackrel{④}{=} \int_{\mathbb{R}} (Y_i - uh) K(u) h du$

$$= \int Y_i K(u) h du - h^2 \int u K(u) du$$

④: Changement de variables:  $u = \frac{Y_i - y}{h} \Leftrightarrow Y_i - uh = y$

$$\Leftrightarrow h du = -dy$$

Donc  $\int y K\left(\frac{Y_i - y}{h}\right) dy = h Y_i \int K(u) du - h^2 \int u K(u) du$

$= h Y_i$   $= 0$ , noyau d'ordre 1

$$\Rightarrow \text{Donc } \hat{f}_n(x) = \frac{1}{h} \cdot \frac{\sum_{i=1}^n Y_i K\left(\frac{X_i - x}{h}\right)}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}$$

$$= \frac{\sum_{i=1}^n Y_i K\left(\frac{X_i - x}{h}\right)}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)}$$

Estimateur à noyau de  $f$  = Estimateur de Nadaraya-Watson

Remarque:  $\hat{f}_n(x) = \sum_{i=1}^n Y_i W_{i,n}^{N,W}(x)$  où  $W_{i,n}^{N,W}(x) = \frac{K\left(\frac{X_i - x}{h}\right)}{\sum_{j=1}^n K\left(\frac{X_j - x}{h}\right)}$  sont tel que:  $\sum_{i=1}^n W_{i,n}^{N,W}(x) = 1$ .

Définition: Estimateur linéaire:  $\hat{f}$  est un estimateur linéaire de  $f$  si  $\hat{f}_n(x) = \sum_{i=1}^n Y_i W_{i,n}(x)$  où les  $W_{i,n}(\cdot)$  sont des poids qui ne dépendent pas des  $Y_i$ .

En général,  $\sum_{i=1}^n W_{i,n}(x) = 1, \forall x$ .

⚠ Attention: L'estimateur de Nadaraya-Watson est un estimateur linéaire.

Remarques:

1) Si  $f \in \Sigma(\beta, L)$  (Hölder) ⊕ Autres hypothèses.

On a:  $\sup_{f \in \Sigma(\beta, L)} \sup_{x \in [0,1]} \text{MSE}(\hat{f}_n^{N,W}(x)) \leq C \cdot n^{-\frac{2\beta}{2\beta+1}}$  par  $h = \alpha \cdot n^{-\frac{1}{2\beta+1}}$ ,  $\alpha > 0$ .

⚠ Attention:  $n^{-\frac{2\beta}{2\beta+1}}$  vitesse de convergence optimale sur  $\Sigma(\beta, L)$ .

2) On a eu:

\* Estimateur par projection

\* Estimateur à noyau (NW).

Il existe d'autres estimateurs de la fonction de régression.

↳ \* Splines

\* polynômes locaux

## Estimateur des moindres carrés non-paramétrique

On a  $Y_i = f(X_i) + \xi$  avec  $f(\cdot) = [0, 1] \rightarrow \mathbb{R}$ ,  $f$  inconnue,  $i = 1, \dots, n$  et  $X_i \in [0, 1]$ .

Notation:  $f = \begin{pmatrix} f(X_1) \\ \vdots \\ f(X_n) \end{pmatrix} \in \mathbb{R}^n$ ,  $y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}$  et  $\xi = \begin{pmatrix} \xi_1 \\ \vdots \\ \xi_n \end{pmatrix}$ ,  $f(\cdot)$  fonction et  $f$  vecteur

On a alors  $y = f + \xi$ .

On considère  $\{\varphi_j\}_{j \geq 1}$  base orthonormée de  $L_2([0, 1])$ .

On suppose qu'il existe  $\theta^* \in \mathbb{R}^H$  tel que  $f(\cdot)$  est bien approximée par:  $f_{\theta^*}(\cdot) = \sum_{j=1}^H \theta_j^* \cdot \varphi_j(\cdot)$ , où  $\theta_j^* = \langle f, \varphi_j \rangle = \int_0^1 f(x) \varphi_j(x) dx$ .

Autre notation:  $f_{\theta} = \begin{pmatrix} f_{\theta}(X_1) \\ \vdots \\ f_{\theta}(X_n) \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^H \theta_j \varphi_j(X_1) \\ \vdots \\ \sum_{j=1}^H \theta_j \varphi_j(X_n) \end{pmatrix} = \begin{pmatrix} \varphi_1(X_1) & \dots & \varphi_H(X_1) \\ \vdots & \ddots & \vdots \\ \varphi_1(X_n) & \dots & \varphi_H(X_n) \end{pmatrix} \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_H \end{pmatrix} = X \cdot \theta$  avec  $X \in \mathbb{R}^{n \times H}$  et  $\theta \in \mathbb{R}^H$

On se ramène alors au modèle de regression linéaire:  $y = X\theta^* + \xi$ .

↳ EMC:  $\hat{\theta}^{MC} = \arg \min_{\theta \in \mathbb{R}^H} \|y - X\theta\|^2$ , avec:  $\|y - X\theta\|^2 = \sum_{i=1}^n (Y_i - \sum_{j=1}^H \theta_j \varphi_j(X_i))^2$ .

Si  $(X^T X)$  est inversible, alors  $\mathbb{E}[(X^T X)^{-1} X^T y]$  estimateur des MC.

On construit alors l'EMC non-paramétrique  $\hat{f}^{MC}(\cdot)$  de  $f$  donné par:  $\hat{f}^{MC}(x) = \hat{f}_{\hat{\theta}^{MC}}(x) = \sum_{j=1}^H \hat{\theta}_j^{MC} \varphi_j(x)$ .

### Remarques:

1)  $\hat{f}^{MC}(\cdot)$  est un estimateur linéaire.

En effet:  $\hat{f}^{MC}(x) = \varphi^T(x) \hat{\theta}^{MC}$  où  $\varphi(x) = \begin{pmatrix} \varphi_1(x) \\ \vdots \\ \varphi_H(x) \end{pmatrix} \in \mathbb{R}^H$

$$= \varphi^T(x) (X^T X)^{-1} X^T y$$

$$= \sum_{i=1}^n W_{n,i}^{MC}(x) Y_i \text{ où } W_{n,i}^{MC}(x) \text{ est la } i\text{-ème coordonnée du vecteur } (\varphi^T(x) (X^T X)^{-1} X)^T \in \mathbb{R}^n.$$

2) Si  $n < H$ ,  $\text{rang}(X^T X) = \text{rang}(X) \leq \min(n, H) = n$ .

Alors  $(X^T X)^{-1}$  n'existe pas!

Comment estimer  $f(\cdot)$  (car  $f_{\theta}$ ) dans ce cas?

On verra une solution au chapitre suivant (spécité).

⊙: taille d'échantillon

⊙: ordre de l'estimateur = nombre de paramètre

## Propriétés statistiques des estimateurs linéaires

$\hat{f}$  estimateur linéaire de  $f$ , c'est-à-dire  $\exists W_{n,1}(\cdot), \dots, W_{n,n}(\cdot)$  tel que:  $\hat{f}(\cdot) = \sum_{i=1}^n W_{n,i}(\cdot) Y_i$ .

Risque:  $R(\hat{f}) = \mathbb{E} \left[ \frac{1}{n} \sum_{i=1}^n (\hat{f}(X_i) - f(X_i))^2 \right]$ .

Remarque: Si  $X_i = \frac{i}{n}$ , alors  $R(\hat{f}) \sim \int (\hat{f}(x) - f(x))^2 dx = \text{MISE}(\hat{f})$

$\hat{f}(\cdot)$  estimateur linéaire.

Donc  $\hat{f} = \begin{pmatrix} \hat{f}(x_1) \\ \vdots \\ \hat{f}(x_n) \end{pmatrix} = \begin{pmatrix} w_{n,1}(x_1) & \dots & w_{n,n}(x_1) \\ \vdots & \ddots & \vdots \\ w_{n,1}(x_n) & \dots & w_{n,n}(x_n) \end{pmatrix} \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$

On a:  $\hat{f} = Sy$  avec  $S \in \mathbb{R}^{n \times n}$

$S$  s'appelle matrice de lissage

Théorème: Si les  $\xi_i$  sont indépendants et tel que  $\mathbb{E}[\xi_i] = 0$ ,  $\text{Var}(\xi_i) = \sigma^2 < \infty$  et  $\mathbb{E}[\xi_i \xi_j] = 0$  avec  $i \neq j$

Alors  $\hat{f} = Sy$  est tel que:  $R(\hat{f}) = \underbrace{\frac{1}{n} \|Sf - f\|^2}_{\text{biais}} + \underbrace{\frac{\sigma^2}{n} \text{Tr}(S^T S)}_{\text{variance}}$  où:  $B + V$

Preuve: On a  $R(\hat{f}) = \mathbb{E} \left[ \frac{1}{n} \|\hat{f} - f\|^2 \right]$

$$= \frac{1}{n} \mathbb{E} [\|Sy - f\|^2]$$

$y = f + \xi$   
 $\Rightarrow \frac{1}{n} \mathbb{E} [\|Sf - f + S\xi\|^2]$

$$= \frac{1}{n} \mathbb{E} [\|Sf - f\|^2] + \frac{2}{n} \mathbb{E} [(Sf - f)^T \xi] + \frac{1}{n} \mathbb{E} [\|S\xi\|^2]$$

$$= \frac{1}{n} \|Sf - f\|^2 + \frac{2}{n} (Sf - f)^T \underbrace{\mathbb{E}[\xi]}_{=0} + \frac{1}{n} \mathbb{E} [\|S\xi\|^2]$$

Or  $\mathbb{E} [\|S\xi\|^2] = \sigma^2$ , mais:

Méthode 1: On a  $\mathbb{E} [\|S\xi\|^2] = \mathbb{E} \left[ \sum_{i=1}^n \sum_{j=1}^n \xi_i \xi_j \right]$   
 $= \underbrace{\mathbb{E} \left[ \sum_{i=1}^n \xi_i^2 \right]}_{= \sigma^2} + \sum_{i=1}^n \sum_{j=1, j \neq i}^n \underbrace{\mathbb{E} [\xi_i \xi_j]}_{=0} = \sigma^2$

Méthode 2: On a  $\mathbb{E} [\|S\xi\|^2] = \mathbb{E} [\text{Tr}(\|S\xi\|^2)]$

$$= \mathbb{E} [\text{Tr}(\xi^T S^T S \xi)]$$

trace circulaire  
 $\text{Tr}(AB) = \text{Tr}(BA)$   
 $\Rightarrow \mathbb{E} [\text{Tr}(\xi \xi^T S^T S)] = \text{Tr}(\mathbb{E} [\xi \xi^T] S^T S)$

On a  $\mathbb{E}[\xi] = 0$  et  $\mathbb{E}[\xi_i \xi_j] = 0, i \neq j$ .

Donc  $\mathbb{E}[\xi \xi^T] = \text{Var}(\xi) = \sigma^2 I_n$ .

$$\Rightarrow \text{Donc } \mathbb{E} [\|S\xi\|^2] = \text{Tr}(\sigma^2 I_n S^T S)$$

$$= \sigma^2 \text{Tr}(S^T S)$$

Cas particulier:  $\hat{f}^{nc} = X \hat{\theta}^{nc}$   
 $= X (X^T X)^{-1} X^T y$

Et  $S = X (X^T X)^{-1} X^T = A$  s'appelle la matrice chapeau.

$A$  est un projecteur (sur l'espace vectoriel engendré par les colonnes de la matrice  $X$ , c'est-à-dire:

$$\text{vect}(X^1, \dots, X^n) \text{ où } M = \begin{pmatrix} \psi_1(x_1) \\ \vdots \\ \psi_1(x_n) \end{pmatrix}).$$

Proposition: Si  $\xi_i$  sont indépendants et identiquement distribués tel que  $\mathbb{E}[\xi_i] = 0$  et  $\text{Var}(\xi_i) = \sigma^2 < \infty$ .

Alors:  $\mathbb{E} \left[ \frac{1}{n} \|\hat{f}^{nc} - f\|^2 \right] \leq \min_{\theta \in \mathbb{R}^n} \frac{1}{n} \|f_\theta - f\|^2 + \frac{\sigma^2}{n} \cdot \min\{M, n\}.$

15) Preuve:

i) biais:  $\|Sf - f\|^2 = \|Af - f\|^2$

projection  $\rightarrow \triangleq \min_{g \in \mathbb{R}^n} \|f_0 - g\|^2$

ii)  $S^T S = A^T A = A A = A$

Donc  $Tr(S^T S) = Tr(A) = Tr(D)$

$= \text{rang}(A) \leq \min\{n, M\}$ .

Par aller plus loin et contrôler le biais, il faut des hypothèses.

Théorème: Si  $m \in \mathbb{N}^*$ ,  $L > 0$ ,  $n \geq 1$ .

On pose  $M = \lfloor \lambda n^{-\frac{1}{2m+2}} \rfloor$ ,  $\lambda > 0$ .

Si  $\{ \varphi_j \}_{j=1}^M$  base de Fourier, alors  $\sup_{f \in W^{m,2}(\lambda, L)} \mathbb{E}[\frac{1}{n} \|\hat{f}^{MC} - f\|^2] \leq C(n, L, \sigma^2) n^{-\frac{2m}{2m+2}}$

Remarque: Pour montrer ce résultat, il suffit de montrer que:  $\inf_{g \in \mathbb{R}^n} \|g - f\|^2 \leq C(m, L)(M^{-2m} + \frac{1}{n})$  et optimiser en  $M$ .

### III) Adaptation

Dans le théorème précédent, le choix optimal de  $M$  dépend de  $m$  (régularité de  $f$ ) qui est inconnu.

On se propose de déterminer une valeur de  $M$  qui dépend des données.


- 2 approches:
- Validation Croisée
  - Estimation sans biais du risque.

#### A) Validation Croisée (cas supervisé)

$\mathcal{D}_n = \{(X_i, Y_i), i = 1, \dots, n\}$  données

$g_1, \dots, g_K$  algorithmes (exemples: SVM, k-PPV, arbres, ...).

$\ell(y, y')$ : fonction de perte (exemple:  $\ell_2$ , perte 0/1)



Pour  $k \in [K]$ :

Pour  $v \in [V]$ :

i) On construit  $\hat{g}_k^{(-v)}$  l'estimateur en se basant sur les données  $\mathcal{D}_n \setminus B_v$  grâce à l'algo  $g_k$ .

$\hookrightarrow \hat{g}_k^{(-v)}: \mathcal{X} \rightarrow \mathcal{Y}$

ii) On calcule les performances de  $\hat{g}_k^{(-v)}$  sur les données  $B_v$ .

$\hookrightarrow \text{Err}(\hat{g}_k^{(-v)}) = \frac{1}{\#B_v} \sum_{(x, y) \in B_v} \ell(y, \hat{g}_k^{(-v)}(x))$

iii) On calcule l'erreur de Validation croisée de  $g_k$ .

$\hookrightarrow CV(g_k) = \sum_{v=1}^V \text{Err}(\hat{g}_k^{(-v)})$

$\hat{k}^{CV} = \arg\min CV(g_k)$ .

L'estimateur optimal pour VC est  $\hat{g}_{\hat{k}^{CV}}$  construit à partir de  $\mathcal{D}_n$  (toutes les données).



Remarque: Il y a des résultats théoriques par la validation croisée (mais pas le temps).

### B) ESB du risque (par les estimateurs linéaires)

Soit  $S$  tel que:  $\hat{f} = S y$  <sup>ne dépend pas de  $y$</sup>  estimateur linéaire

Soit  $\hat{f} = \begin{pmatrix} \hat{f}(x_1) \\ \vdots \\ \hat{f}(x_n) \end{pmatrix}$  et  $f = \begin{pmatrix} f(x_1) \\ \vdots \\ f(x_n) \end{pmatrix}$ , donc  $E[\|\hat{f} - f\|^2] = E[\|\hat{f}\|^2 + \|f\|^2 - 2\hat{f}^T f]$   
 $= E[\|\hat{f}\|^2] - 2 E[\hat{f}^T f] + \|f\|^2$

On pose  $\hat{J} = \|\hat{f}\|^2 - 2(y^T S y - \sigma^2 \text{Tr}(S))$

Exercice: Montrer que  $E[\hat{J}] = J(f)$ .

Remarque:  $\hat{f} = S y$

Donc  $\hat{J} = \hat{J}(S)$

$= \|S y\|^2 - 2 y^T S y + 2 \sigma^2 \text{Tr}(S) = \|S y - y\|^2 + 2 \sigma^2 \text{Tr}(S) - \|y\|^2$

⊙: En supposant  $S$  symétrique

⊙: ne dépend pas de  $S$

On se donne un ensemble de matrices  $\mathcal{M}$  et on choisit  $\hat{S} = \arg \min_{S \in \mathcal{M}} \frac{1}{n} \|S y - y\|^2 + \frac{2 \sigma^2}{n} \text{Tr}(S)$

⚠ Attention: Si  $S$  est un projecteur, ce critère est la Cp-Mallows (1975)

On pénalise donc les gros modèles (c'est-à-dire  $S$  tel que  $\text{rang}(S)$  est grand).

Théorème: Kneip, 1954: Si  $\mathcal{M}$  est un ensemble de matrices de  $\mathbb{R}^{n \times n}$  tel que :

- 1)  $\forall S \in \mathcal{M}$ ,  $S$  est symétrique et  $0 \leq v^T S v \leq v^T v, \forall v \in \mathbb{R}^n$
- 2)  $S_1 S_2 = S_2 S_1, \forall S_1, S_2 \in \mathcal{M}$
- 3)  $\forall S_1, S_2 \in \mathcal{M}$ , on a :
  - Soit  $S_2 - S_1 \geq 0$
  - ou  $S_2 - S_1 \leq 0$ .

Si de plus,  $\xi_i \stackrel{iid}{\sim} \mathcal{NP}(0, \sigma^2)$ .

Alors:  $\exists c \geq 0$  tel que  $\forall f, \forall \varepsilon > 0, E[\frac{1}{n} \|\hat{f} - f\|^2] \leq (1 + \varepsilon) \inf_{S \in \mathcal{M}} E[\frac{1}{n} \|S y - f\|^2] + \frac{c}{\varepsilon n}$  où  $\hat{f} = \hat{S} y$ .

Remarques:

1)  $\hat{f}$  a un risque de même ordre que le meilleur  $\hat{f} = S y$  avec  $S \in \mathcal{M}$  (inégalité Oracle)

2) Cas particulier: EMC: On a  $\hat{\theta}^{nc} = (X_M^T X_M)^{-1} X_M^T y$  où  $X_M = \begin{pmatrix} \varphi_1(x_1) & \dots & \varphi_n(x_1) \\ \vdots & \ddots & \vdots \\ \varphi_1(x_n) & \dots & \varphi_n(x_n) \end{pmatrix}$

$\hat{f}^{nc} = S_M y = X_M (X_M^T X_M)^{-1} X_M^T y = X_M \hat{\theta}^{nc}$

On a  $\mathcal{M} = \{S_M = X_M (X_M^T X_M)^{-1} X_M^T \in \mathbb{R}^{n \times n}, M = 1, \dots, n\}$ .

⚠ Attention:  $\mathcal{M}$  vérifie les hypothèses du théorème (À montrer!).

28

$$\hat{S} = \arg \min \left\{ \frac{1}{n} \|S_n y - y\|^2 + \frac{2\sigma^2}{n} \text{Tr}(S_n) \right\}.$$

On applique le théorème avec  $\varepsilon = 1$  et on obtient :

$$\begin{aligned} \mathbb{E} \left[ \frac{1}{n} \|\tilde{f} - f\|^2 \right] &\leq 2 \cdot \min_{M \in \mathcal{C}(n)} \left[ \mathbb{E} \left[ \frac{1}{n} \|S_n y - f\|^2 \right] + \frac{c}{2n} \right] \\ &\leq 2 \cdot \min_{M \in \mathcal{C}(n)} \left( \inf_{\theta \in \mathbb{R}^m} \frac{1}{n} \|\theta_0 - f\|^2 + \frac{\sigma^2}{n} \inf \{M, m\} \right) + \frac{c}{2n} \end{aligned}$$

En supposant  $f \in W^{\text{per}}(m, L)$  et  $\{\varphi_j\}$  Fourier.

$$\text{On obtient : } \mathbb{E} \left[ \frac{1}{n} \|\tilde{f} - f\|^2 \right] \leq C(m, L) n^{-\frac{2m}{2m+2}}$$

⚠ Attention :  $\tilde{f}$  adaptatif et atteint la bonne vitesse sans perte.