

⊕ Hypothèse de parcimonie (sparsité)

Modèle de régression: $Y_i = f(X_i) + \xi_i$ ^{ξ_i inconnue}

$X_i \in [0, 1]$ de signe déterministe et ξ_i indépendants et identiquement distribués avec: $\begin{cases} \mathbb{E}[\xi_i] = 0 \\ \text{Var}(\xi_i) = \sigma^2 < \infty \end{cases}$

On suppose $f \in L_2([0, 1])$.

$\{\varphi_j\}$ base orthonormée de $L_2([0, 1])$.

On suppose qu'il existe $M \in \mathbb{N}$ et $\theta^* \in \mathbb{R}^M$ tel que $f(\cdot) = \sum_{j=1}^M \theta_j^* \varphi_j(\cdot)$ (projection)

Estimation de f : $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n$, $\xi = \begin{pmatrix} \xi_1 \\ \vdots \\ \xi_n \end{pmatrix} \in \mathbb{R}^n$.

On a $y = X\theta^* + \xi$ où $X = \begin{pmatrix} \varphi_1(x_1) & \dots & \varphi_M(x_1) \\ \vdots & & \vdots \\ \varphi_1(x_n) & \dots & \varphi_M(x_n) \end{pmatrix}$.

D'après le chapitre précédent, $\{\varphi_j\}$ base orthonormée $\odot n \geq M \Rightarrow X^T X$ est inversible

Alors $\hat{\theta}^{nc} = \arg \min_{\theta \in \mathbb{R}^M} \|y - X\theta\|^2$
 $= (X^T X)^{-1} X^T y$.

De plus, on a $\mathbb{E}[\frac{1}{n} \|X\hat{\theta}^{nc} - X\theta^*\|_2^2] \leq \frac{\sigma^2}{n} \cdot \min\{n, M\}$
 $\stackrel{n \geq M}{=} \frac{\sigma^2}{n} \cdot M \xrightarrow{n \rightarrow \infty} 0$

Remarque: $\{\varphi_j\}$ base orthonormale $\Rightarrow \frac{1}{n} X^T X = \begin{pmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}$ (si $M \leq n-1$)

Si $n \ll N$ ou bien si: $\{\varphi_j\}_j$ n'est pas une base, il est possible que $X^T X$ ne soit plus inversible.

En particulier, si $n \ll M$, $X^T X$ n'est pas inversible.

Dans ce cas, l'ETC ci-dessus n'est plus défini de manière unique et la borne: $\frac{\sigma^2 \min\{n, M\}}{n} \stackrel{M \gg n}{=} \sigma^2 \frac{n}{n} \xrightarrow{n \rightarrow \infty} 0$

Dans ce cas, il faut trouver une alternative à l'ETC.

Il faut de plus supposer que le modèle est sparse

Hypothèse (S): $\exists S \subset [M]$ de cardinal $s \ll n$ tel que $\theta_j^* \neq 0 \Leftrightarrow j \in S$ ($s = o(n)$)

On a alors:

$$y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} \varphi_1(x_1) & \dots & \varphi_M(x_1) \\ \vdots & & \vdots \\ \varphi_1(x_n) & \dots & \varphi_M(x_n) \end{bmatrix} \cdot \begin{bmatrix} \theta_1^* \\ \vdots \\ \theta_M^* \end{bmatrix} + \begin{bmatrix} \xi_1 \\ \vdots \\ \xi_n \end{bmatrix}$$

①

$$\textcircled{1} = X_S = \begin{pmatrix} \varphi_j(x_1) \\ \vdots \\ \varphi_j(x_n) \end{pmatrix}_{j \in S}$$

Si S est connu, on estime $\theta_j^* \in \mathbb{R}^s$ par Moindres-carrés: $[\theta_S^* = (\theta_j^*)_{j \in S}]$, c'est-à-dire: $\hat{\theta}_S = \arg \min_{\theta \in \mathbb{R}^s} \|y - X_S \theta\|_2^2$
 $= (X_S^T X_S)^{-1} X_S^T y$.

Ⓜ Attention: On a $y = X\theta^* + \xi$
 $= X_S \theta_S^* + \xi$.

Pour suite, $\theta^* \in \mathbb{R}^n$ est estimée par: $\hat{\theta}^*$ défini par: $\hat{\theta}_j^* = \begin{cases} \hat{\theta}_j & \text{si } j \in S \\ 0 & \text{si } j \notin S \end{cases}$

En utilisant des calculs similaires au cas des PC, le risque de $\hat{\theta}^*$ est: $\mathbb{E}[\frac{1}{n} \|X\hat{\theta}^* - X\theta^*\|_2^2] \leq \sigma^2 \cdot \frac{\min\{n, s\}}{n}$
 $= \frac{\sigma^2 s}{n} \xrightarrow[n \rightarrow \infty]{} 0$ (s: sparsité)

Attention: $\hat{\theta}^*$ n'est pas un vrai estimateur.

Il dépend de S qui est inconnu!

Question: Peut-on construire un "vrai" estimateur qui atteint la même vitesse de convergence ($\frac{s\sigma^2}{n}$)?

la réponse est positive mais on va prendre un terme logarithmique.

II. Modèle de suites gaussiennes

On a $y = X\theta^* + \xi$ avec $\xi \sim \mathcal{P}(0_n, \sigma^2 I_n)$

Hypothèse (0): $\frac{X^T X}{n} = I_n$

Par exemple: $\{\varphi_j\}$ base trigonométrique et $n \gg \pi$.

On multiplie $\otimes$ par $\frac{X^T}{n}$ à gauche et on obtient: $\frac{X^T y}{n} = \underbrace{\frac{X^T X}{n}}_{I_n} \theta^* + \frac{X^T \xi}{n} \Leftrightarrow \frac{X^T y}{n} = \theta^* + \frac{X^T \xi}{n}$

le modèle devient $z = \theta^* + \bar{\eta} \in \mathbb{R}^n$.

Loi de $\bar{\eta}$: $\bar{\eta} = \frac{X^T \xi}{n}$.

On a: $\frac{X^T \xi}{n} \sim \mathcal{P}(0_n, \frac{X^T}{n} \cdot (\sigma^2 I_n) \cdot \frac{X}{n})$

$\sim \mathcal{P}(0_n, \frac{\sigma^2}{n} \cdot \frac{X^T X}{n})$, c'est-à-dire $\bar{\eta} \sim \mathcal{P}(0_n, \frac{\sigma^2}{n} I_n)$.

Ainsi, la j -ème coordonnée de z a pour loi: $z_j \sim \mathcal{P}(\theta_j^*, \frac{\sigma^2}{n})$.

On note $\varepsilon^2 = \frac{\sigma^2}{n}$.

On obtient alors le modèle de suites gaussiennes: $z_j = \theta_j^* + \varepsilon \eta_j$ avec $\eta_j \stackrel{iid}{\sim} \mathcal{P}(0, 1)$, $j = 1, \dots, n$.

Hypothèse: $\varepsilon = \frac{\sigma}{\sqrt{n}} \xrightarrow[n \rightarrow \infty]{} 0$

On a z_j : observation, θ_j^* : signal et η_j : bruit.

Hypothèse: $S(\theta^*) = \{j \in [n]: \theta_j^* \neq 0\}$, le support de θ^* est tel que: $|S(\theta^*)| = \|\theta^*\|_0$
 $= s(n)$

Exemple: $\theta^* = (0, 0, -3, 0, 7, 0, 0, 5, 3, 0, 0, 0)^T$, donc: $\|\theta^*\|_0 = 4$.

2.1 Lemme: Soit $\eta \sim \mathcal{N}(0, 1)$.

Alors, $\forall x > 0$:


- 1) $\mathbb{E}[|\eta|] = \sqrt{\frac{2}{\pi}}$.
- 2) $P(|\eta| > x) \leq \sqrt{\frac{2}{\pi}} \cdot \frac{e^{-x^2/2}}{x}$.
- 3) $P(|\eta| > x) \leq e^{-x^2/2}$ (Concentration gaussienne).
- 4) $\mathbb{E}[\eta^2 \mathbb{1}_{|\eta| \geq x}] \leq \sqrt{\frac{2}{\pi}} \left(x + \frac{1}{x}\right) e^{-x^2/2}$.

Preuve:

$$\begin{aligned} 1) \text{ On a : } \mathbb{E}[|\eta|] &= \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} \cdot \overbrace{|u|}^{\text{paire}} \cdot e^{-u^2/2} du \\ &= \frac{2}{\sqrt{2\pi}} \cdot \int_0^{\infty} u \cdot e^{-u^2/2} du \\ &= \sqrt{\frac{2}{\pi}} \cdot [-e^{-u^2/2}]_0^{\infty} = \sqrt{\frac{2}{\pi}} \end{aligned}$$

$$\begin{aligned} 2) \text{ On a : } P(|\eta| > x) &= \frac{2}{\sqrt{2\pi}} \int_{\mathbb{R}} \underbrace{\mathbb{1}_{|u| > x}}_{\text{paire}} \cdot e^{-u^2/2} du \\ &= \frac{2}{\sqrt{2\pi}} \int_0^{\infty} 1 \cdot e^{-u^2/2} du \\ &\stackrel{u \geq x}{\leq} \sqrt{\frac{2}{\pi}} \cdot \int_x^{\infty} \frac{1}{u} \cdot e^{-u^2/2} du \\ &= \sqrt{\frac{2}{\pi}} \cdot \frac{1}{x} \int_x^{\infty} u \cdot e^{-u^2/2} du \\ &= \sqrt{\frac{2}{\pi}} \cdot \frac{1}{x} \cdot [-e^{-u^2/2}]_x^{\infty} = \sqrt{\frac{2}{\pi}} \cdot \frac{1}{x} \cdot e^{-x^2/2} \end{aligned}$$

Remarque: $W \sim \mathcal{N}(\mu, \sigma^2)$:



$$\begin{aligned} 3) \text{ De même, } P(|\eta| > x) &= \sqrt{\frac{2}{\pi}} \cdot \int_x^{\infty} e^{-u^2/2} du \\ &\stackrel{\text{changement de variable } t = u-x}{=} \sqrt{\frac{2}{\pi}} \cdot \int_0^{\infty} e^{-(t+x)^2/2} dt \\ &\stackrel{④}{\leq} \sqrt{\frac{2}{\pi}} \cdot \int_0^{\infty} e^{-t^2+x^2/2} dt \\ &= \sqrt{2\pi} \cdot \sqrt{\frac{2}{\pi}} \cdot e^{-x^2/2} \cdot \underbrace{\int_0^{\infty} \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt}_{=1/2} \\ &= \sqrt{2\pi} \cdot \sqrt{\frac{2}{\pi}} \cdot e^{-x^2/2} \cdot \frac{1}{2} = e^{-x^2/2} \end{aligned}$$

④: car $x, t \geq 0, x^2 + t^2 \leq (x+t)^2 \leq 2(x^2 + t^2)$

$$\begin{aligned} 4) \text{ On a } \mathbb{E}[\eta^2 \mathbb{1}_{|\eta| \geq x}] &= \frac{2}{\sqrt{2\pi}} \cdot \int_0^{\infty} u^2 \mathbb{1}_{u \geq x} \cdot e^{-u^2/2} du \\ &= \frac{2}{\sqrt{2\pi}} \cdot \int_x^{\infty} 1 \cdot u^2 \cdot e^{-u^2/2} du \\ &\leq 2 \cdot \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{x} \int_x^{\infty} u \cdot u^2 \cdot e^{-u^2/2} du \\ &= 2 \cdot \frac{1}{x} \cdot \frac{1}{\sqrt{2\pi}} \cdot (-u^2 \cdot e^{-u^2/2}]_x^{\infty} - \int_x^{\infty} 2u \cdot e^{-u^2/2} du \\ &= \sqrt{\frac{2}{\pi}} \cdot \frac{1}{x} (x^2 \cdot e^{-x^2/2} - 2 \cdot \int_x^{\infty} u \cdot e^{-u^2/2} du) \\ &= \sqrt{\frac{2}{\pi}} \cdot \frac{1}{x} (x^2 \cdot e^{-x^2/2} - 2[e^{-u^2/2}]_x^{\infty}) \\ &= \sqrt{\frac{2}{\pi}} \cdot \frac{1}{x} (x^2 \cdot e^{-x^2/2} + 2 \cdot e^{-x^2/2}) = \sqrt{\frac{2}{\pi}} \left(x + \frac{1}{x}\right) e^{-x^2/2} \end{aligned}$$

Lemme: Soit $n \geq 2$ et $\eta_1, \dots, \eta_n$ variables aléatoires indépendantes et identiquement distribuées de loi $\mathcal{N}(0, 1)$.

(22)

Alors:

$$1) \forall t \geq \sqrt{2}, \mathbb{P}(\max_{j \in [M]} |\eta_j| \geq t \cdot \sqrt{\ln(M)}) \leq M^{1-t^2/2}$$

$$2) \forall u > 0, \mathbb{P}(\max_{j \in [M]} |\eta_j| > \sqrt{2 \cdot \ln(M)} + u) \leq \frac{1}{\sqrt{\pi \ln(M)}} e^{-u^2/2}.$$

Preuve:

$$1) \mathbb{P}(\max_{j \in [M]} |\eta_j| \geq t \cdot \sqrt{\ln(M)}) = \mathbb{P}(\exists j \in [M]: |\eta_j| \geq t \cdot \sqrt{\ln(M)})$$

$$= \mathbb{P}(\bigcup_{j \in [M]} \{|\eta_j| \geq t \cdot \sqrt{\ln(M)}\})$$

$$\leq \sum_{j \in [M]} \mathbb{P}(|\eta_j| \geq t \cdot \sqrt{\ln(M)})$$

$$\stackrel{\text{ind}}{\rightarrow} \stackrel{\text{②}}{=} M \cdot \mathbb{P}(|\eta_1| \geq t \cdot \sqrt{\ln(M)})$$

$$\stackrel{\text{④}}{\rightarrow} \leq M \cdot e^{-t^2 \ln(M)/2}$$

$$= M e^{\ln(M) - t^2/2}$$

$$= M M^{-t^2/2} = M^{1-t^2/2}$$

④: Par le 3) du lemme précédent, avec $x = t \sqrt{\ln(M)}$

$$2) \text{ De même, avec } \textcircled{*}, \text{ on a: } \mathbb{P}(\max_{j \in [M]} |\eta_j| > \sqrt{2 \cdot \ln(M)} + u) \leq M \cdot \mathbb{P}(|\eta_1| > \sqrt{2 \cdot \ln(M)} + u)$$

$$\stackrel{\text{②}}{\rightarrow} \leq M \cdot \sqrt{\frac{2}{\pi}} \cdot \frac{1}{\sqrt{2 \cdot \ln(M)} + u} \cdot e^{-(\sqrt{2 \cdot \ln(M)} + u)^2/2}$$

$$\stackrel{\text{③}}{\rightarrow} \leq \sqrt{\frac{2}{\pi}} \cdot M \cdot \frac{1}{\sqrt{2 \cdot \ln(M)}} e^{-2 \ln(M) + u^2/2}$$

$$= \sqrt{\frac{2}{\pi}} \cdot M \cdot \frac{1}{\sqrt{2 \cdot \ln(M)}} e^{-u^2/2} \underbrace{e^{-\ln(M)}}_{M^{-1}}$$

$$= \frac{1}{\sqrt{\pi \ln(M)}} e^{-u^2/2}$$

③: Avec le 2) du lemme précédent, avec $x = \sqrt{2 \cdot \ln(M)} + u$


$$\textcircled{3}: \left[\frac{1}{a+b} \leq \frac{1}{a} \right] + \left[u, v \geq 0, (u+v)^2 \geq u^2 + v^2 \right]$$

⚠ Attention: On a $\mathbb{P}(\max_{j \in [M]} |\eta_j| \leq t \sqrt{\ln(M)}) \geq 1 - M^{1-t^2/2}$, $t \geq \sqrt{2}$.

• Si $\Theta_j^* = 0$: On a $z_j = \varepsilon \eta_j$

$\Rightarrow |z_j| = \varepsilon |\eta_j| \leq \varepsilon t \sqrt{\ln(M)}$ avec grande probabilité

• Si $\Theta_j^* \neq 0$: $z_j = \Theta_j^* + \varepsilon \eta_j$ et on espère que $|z_j|$ soit grande.



(23)


Définition: Estimateur de seuillage dur (Hard - Thresholding): On a $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_n)^T$ défini par :

$$\hat{\theta}_j = \begin{cases} z_j & \text{si } |z_j| \geq c \varepsilon \sqrt{\ln(M)} \\ 0 & \text{sinon} \end{cases} \text{ est appelé estimateur de seuillage dur où } c > 0 \text{ est une constante.}$$

⚠ Attention: $\hat{\theta}_j = z_j \cdot \mathbb{1}_{|z_j| \geq c \varepsilon \sqrt{\ln(M)}}$.

Remarque: Fonction de seuillage dur: $z \mapsto z \mathbb{1}_{|z| \geq \tau}, \tau \geq 0$.

Dans la suite $\hat{\theta}_j = z_j \mathbb{1}_{|z_j| \geq \tau}, \tau > 0$.



Théorème:

1) Inégalité Oracle - en espérance: Si $\tau = \varepsilon \sqrt{2 \ln(M)}$

$$= \sigma \sqrt{\frac{2 \ln(M)}{n}}$$

$$\mathbb{E}[\|\hat{\theta} - \theta^*\|_2^2] \leq \frac{2\sigma^2}{n} \|\theta^*\|_0 \ln(M) \left(1 + \frac{4}{\sqrt{\ln(M)}}\right).$$

2) Inégalité Oracle - en probabilité: Si $\tau = A \varepsilon \sqrt{\ln(M)}$

$$= A \sigma \sqrt{\frac{\ln(M)}{n}} \text{ avec } A > 2\sqrt{2}$$

$$\text{Donc } \mathbb{P}(\|\hat{\theta} - \theta^*\|_2^2 \leq \frac{9}{4} A^2 \frac{\sigma^2}{n} \|\theta^*\|_0 \ln(M)) \geq 1 - M^{-1 - A^2/8}$$

3) Sélection de variables: Si $\tau = B \varepsilon \sqrt{\ln(M)}$, et si $\min_{j \in \mathcal{S}(\theta^*)} |\theta_j^*| > 2\tau$

$$= B \sigma \sqrt{\frac{\ln(M)}{n}} \text{ avec } B > \sqrt{2}$$

$$\text{Alors } \mathbb{P}(\mathcal{S}(\theta^*) = \hat{\mathcal{S}}) \geq 1 - M^{-1 - B^2/2} \text{ où : } \begin{cases} \mathcal{S}(\theta^*) = \{j : \theta_j^* \neq 0\} \\ \hat{\mathcal{S}} = \{j : \hat{\theta}_j \neq 0\} \end{cases}$$

Remarques:

1) $\hat{\theta}$ atteint la vitesse optimale ($\frac{\|\theta^*\|_0 \ln(M)}{n}$)

2) la sélection de variables est obtenue sous la condition "bêta-min", c'est-à-dire: $\min_{j \in \mathcal{S}(\theta^*)} |\theta_j^*| > 2\tau$.

Preuve:

2) Lemme: Soit $R > 0, z, \theta \in \mathbb{R}$ tel que $|z - \theta| \leq R$

$$\text{Alors } |z \mathbb{1}_{|z| > 2R} - \theta| \leq 3 \min\{|z|, R\}$$

Preuve du lemme:

Cas 1: $|z| > 2R$

$$\begin{aligned} \text{Déjà, on observe que } |\theta| &= |\theta - z + z| \\ &\geq |z| - \underbrace{|\theta - z|}_{\leq R \text{ (hypothèse)}} \\ &> 2R - R = R \end{aligned}$$

On a donc: $|\theta| > R$ $\textcircled{*}$

$$\begin{aligned} \text{Donc } |z \mathbb{1}_{|z| > 2R} - \theta| &= |z - \theta| \\ &\leq R = \min\{|z|, R\} \text{ (d'après } \textcircled{*}). \end{aligned}$$

(24)

$$\leq 3 \min\{|\theta|, R\}$$

Cas 2: $|z| \leq 2R$.

$$\text{On a alors: } |z \mathbb{1}_{|z| > 2R} - \theta| = |\theta|$$

$$\text{D'une part: } |\theta| \leq 3|\theta|$$

$$\text{D'autre part: } |\theta| = |\theta - z + z|$$

$$\leq |z| + |z - \theta|$$

$$\leq 2R + R = 3$$

$$\text{Conclusion: } |\theta| \leq \min\{3|\theta|, 3R\}$$

$$= 3 \min\{|\theta|, R\}.$$

Retour à la preuve du 2) du théorème.

↳ On prend $2R = \tau$

$$\text{Notons que } R = \frac{\tau}{2}$$

$$= \frac{A\varepsilon}{2} \sqrt{\ln(H)}$$

$$\text{Notation: } \mathcal{C} = \bigcap_{j \in [n]} \{|z_j - \theta_j^*| \leq R\}$$

$$\text{Montrons que: } P(\mathcal{C}) \geq 1 - H^{1-A^2/8}.$$

$$\text{On a alors: } P(\mathcal{C}^c) = P\left(\bigcup_{j \in [n]} \{|z_j - \theta_j^*| > R\}\right)$$

$$= P\left(\max_{j \in [n]} |z_j| > \frac{A\varepsilon}{2} \sqrt{\ln(H)}\right)$$

$$\stackrel{\text{Deuxième lemme avec } t = A/2}{\leq} H^{1-1/2 \cdot (A/2)^2} = H^{1-A^2/8}$$

On travaille donc sur $\mathcal{C}$ dans la suite.

$$\text{Sur } \mathcal{C}, \text{ et d'après la troisième lemme, on a: } \forall j \in [H], |z_j \mathbb{1}_{|z_j| > 2R} - \theta_j^*| \leq 3 \min\{|\theta_j^*|, R\}.$$

$$\begin{aligned} \text{Ainsi, sur } \mathcal{C}: \|\hat{\theta} - \theta^*\|_2^2 &= \sum_{j=1}^H |\hat{\theta}_j - \theta_j^*|^2 \\ &= \sum_{j=1}^H |z_j \mathbb{1}_{|z_j| > \tau} - \theta_j^*|^2 \\ &\leq 9 \sum_{j=1}^H \min\{|\theta_j^*|^2, R^2\} \\ &= 9 \left(\sum_{j \in \mathcal{S}(\theta^*)} \min\{|\theta_j^*|^2, R^2\} + \sum_{j \in \mathcal{S}(\theta^*)^c} \min\{\underbrace{|\theta_j^*|^2}_{=0}, R^2\} \right) \\ &\leq 9 \sum_{j \in \mathcal{S}(\theta^*)} R^2 \\ &= 9R^2 \#(\mathcal{S}(\theta^*)) \\ &= 9R^2 \|\theta^*\|_0 = \frac{9A^2}{4} \cdot \varepsilon^2 \cdot \ln(H) \cdot \|\theta^*\|_0. \end{aligned}$$

$$3) \text{ On introduit } \mathcal{B} = \bigcap_{j \in [n]} \{|z_j - \theta_j^*| \leq R'\} \text{ avec } R' = \tau$$

$$= B \sqrt{\ln(H)} \text{ avec } B > 0.$$

Il est évident que $P(\mathcal{B}) \geq 1 - H^{1-B^2/2}$ (même preuve que pour $\mathcal{C}$)

On travaille sur $\mathcal{B}$.

Montrons que $\hat{\mathcal{S}} = \mathcal{S}(\theta^*)$:

c) Soit $j \in \hat{\mathcal{S}}$, montrons que $j \in \mathcal{S}(\theta^*)$.

(25)

On a donc $\exists j \in \hat{S} \Leftrightarrow \hat{\theta}_j^* \neq 0$

$$\Leftrightarrow |z_j| > \tau$$

$$\text{Donc } |\theta_j^*| = |\theta_j^* - z_j + z_j|$$

$$\geq |z_j| - |\theta_j^* - z_j|$$

$$\text{Sur } \mathcal{B}, |z_j - \theta_j^*| \leq R' \Rightarrow \tau - \tau = 0$$

$$\text{Ainsi } |\theta_j^*| > 0$$

$$\text{Donc } |\theta_j^*| \neq 0 \Leftrightarrow j \in \mathcal{S}(\theta^*).$$

On a montré que: $\hat{S} \subset \mathcal{S}(\theta^*)$.

Remarkue: Sans aucune hypothèse: $\mathbb{P}(\hat{S} \subset \mathcal{S}(\theta^*)) \geq 1 - M^{1-p^2/2}$.

>: Soit $j \in \mathcal{S}(\theta^*)$, montrons que $j \in \hat{S}$.

On a $j \in \mathcal{S}(\theta^*)$, c'est-à-dire: $\theta_j^* \neq 0$.

En particulier, la condition "beta-min" assure que: $|\theta_j^*| > 2\tau$.

$$\text{On a donc } |z_j| = |z_j - \theta_j^* + \theta_j^*|$$

$$\geq |\theta_j^*| - |z_j - \theta_j^*|$$

$$\text{Sur } \mathcal{B}: |z_j - \theta_j^*| \leq R' = \tau \Rightarrow > 2\tau - \tau = \tau$$

On a donc $|z_j| > \tau$.


Donc $\hat{\theta}_j \neq 0$ et $j \in \hat{S}$.

On a donc $\mathcal{S}(\theta^*) \subset \hat{S}$.

Remarkue:

1) Il existe d'autres méthodes ayant les mêmes performances que l'estimateur par seuillage dur:

- seuillage doux (soft thresholding): $\hat{\theta}^S = (\hat{\theta}_1^S, \dots, \hat{\theta}_n^S)^T$ avec $\hat{\theta}_j^S = z_j (1 - \frac{\tau}{|z_j|})_+$
- fonction de seuillage doux: $z \mapsto z (1 - \frac{\tau}{|z|})_+$
- Inconvénient du seuillage dur: discontinu
- Inconvénient du seuillage doux: biais pour $|z| > \tau$.



On a donc: $\hat{\theta}_j^H = z_j \cdot \mathbb{1}_{|z_j| > \tau}$, $\hat{\theta}_j^S = z_j (1 - \frac{\tau}{|z_j|})_+$

En effet, si $|z_j| > \tau$:

- $\hat{\theta}_j^H = z_j$ et $\mathbb{E}[\hat{\theta}_j^H] = \mathbb{E}[z_j] = \theta_j^*$
- $\hat{\theta}_j^S = z_j \pm \tau$, donc $\mathbb{E}[\hat{\theta}_j^S] = \mathbb{E}[z_j] \pm \tau$
biaisé!

$$= \theta_j^* \pm \tau$$

2) Ecriture variationnelle (TD2): Pour $z = \begin{pmatrix} z_1 \\ \vdots \\ z_n \end{pmatrix} \in \mathbb{R}^n$, on a: $\hat{\theta}^H = \arg \min_{\theta \in \mathbb{R}^n} \{ \|z - \theta\|_2^2 + \tau^2 \|\theta\|_0 \}$ et

$$\hat{\theta}^S = \arg \min_{\theta \in \mathbb{R}^n} \{ \|z - \theta\|_2^2 + 2\tau \|\theta\|_1 \}$$

(26)

III Retour à la régression linéaire

On a $y = X\theta^* + \xi$ avec $y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n$, $X = (X_{i,j}) \in \mathbb{R}^{n \times n}$, $\xi \sim \mathcal{N}(0, \sigma^2 I_n)$ avec $\xi = \begin{pmatrix} \xi_1 \\ \vdots \\ \xi_n \end{pmatrix} \in \mathbb{R}^n$, $\theta^* \in \mathbb{R}^n$

avec $\|\theta^*\|_0 = S \ll \sigma(n)$ et X déterministe

Sous l'hypothèse (0): $\frac{X^T X}{n} = I_n$, on observe que $\forall \tilde{\theta} \in \mathbb{R}^n$, $\theta \in \mathbb{R}^n$, $\frac{1}{n} \|X(\tilde{\theta} - \theta)\|_2^2 = \frac{1}{n} (\tilde{\theta} - \theta)^T X^T X (\tilde{\theta} - \theta)$
 $= (\tilde{\theta} - \theta)^T \underbrace{\frac{X^T X}{n}}_{=I} (\tilde{\theta} - \theta)$
 $= (\tilde{\theta} - \theta)^T (\tilde{\theta} - \theta) = \|\tilde{\theta} - \theta\|_2^2$

Ainsi, sous l'hypothèse (0), on a montré qu'avec grande probabilité, on a $\frac{1}{n} \|X(\hat{\theta}^n - \theta^*)\|_2^2 \leq C \sigma^2 \|\theta_0\| \frac{\ln(n)}{n}$ où $C > 0$, et on a un résultat analogue par $\hat{\theta}^S$.

Conséquence: $\hat{\theta}^S$ et $\hat{\theta}^n$ atteignent la vitesse optimale de convergence (à un log près).

Remarque: Sous l'hypothèse (0), on note que: $\|z - \theta\|_2^2 = \|\frac{1}{n} X^T y - \theta\|_2^2$

$$\begin{aligned} &= (\frac{1}{n} X^T y - \theta)^T (\frac{1}{n} X^T y - \theta) \\ &= \frac{1}{n^2} y^T X X^T y - \frac{2}{n} y^T X \theta + \theta^T \theta \\ &= \frac{1}{n^2} y^T X^T X y - \frac{2}{n} y^T X \theta + \theta^T I \theta \\ &\stackrel{\frac{X^T X}{n} = I}{\Rightarrow} \frac{1}{n^2} y^T X^T X y - \frac{2}{n} y^T X \theta + \frac{\theta^T X^T X \theta}{n} \\ &= \frac{1}{n^2} y^T X^T X y + \|\frac{y}{n} - \frac{X\theta}{n}\|_2^2 - \frac{y^T y}{n} \\ &= \frac{1}{n} \|y - X\theta\|_2^2 + \underbrace{\frac{1}{n^2} y^T X^T X y - \frac{y^T y}{n}}_{(1)} \end{aligned}$$

②: $C(X, y)$: ne dépend pas de θ .

Conclusion: Sous l'hypothèse (0): $\begin{cases} \hat{\theta}^n = \arg\min_{\theta \in \mathbb{R}^n} \{ \frac{1}{n} \|y - X\theta\|_2^2 + \tau^2 \|\theta\|_0 \} \end{cases}$, et les garanties théoriques sont toujours valables

Si l'hypothèse (0) n'est pas vérifiée, on peut toujours définir les estimateurs (sans forme variationnelles):

$$\begin{cases} \hat{\theta}_0 \in \arg\min_{\theta \in \mathbb{R}^n} \{ \frac{1}{n} \|y - X\theta\|_2^2 + \tau^2 \|\theta\|_0 \} \\ \hat{\theta}^1 \in \arg\min_{\theta \in \mathbb{R}^n} \{ \frac{1}{n} \|y - X\theta\|_2^2 + 2\tau \|\theta\|_1 \} \end{cases}$$

La question est donc de savoir si les garanties théoriques précédentes sont toujours valables pour ces estimateurs même sans l'hypothèse (0).

10/11/25

IV Discussions

A) Autour de l'estimateur de type ℓ_0

On a: $y_i = x_i^T \theta^* + \xi_i$ avec: $\xi_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$.

On a $\hat{\theta}_0 \in \arg\min_{\theta \in \mathbb{R}^n} \{ \frac{1}{n} \|y - X\theta\|_2^2 + \tau^2 \|\theta\|_0 \}$

De plus, on a: $\hat{\theta}_0 \in \arg\min_{\theta \in \mathbb{R}^n} \{ \frac{1}{2\sigma^2} \|y - X\theta\|_2^2 + \frac{\tau^2 n}{2\sigma^2} \|\theta\|_0 \}$.

(23) Dans un modèle gaussien, on a : $\hat{\theta}_{\ell_0} \in \arg \min_{\theta} \{-\log\text{-vrais}(\theta) + \text{pen}(\theta)\}$ avec $\text{pen}(\theta) = \frac{\tau^2}{2\sigma^2} \|\theta\|_0$.

Si $\tau^2 = \frac{2\sigma^2}{n}$, on obtient le critère AIC (Akaike Information Criterion, 1973) $\sim \hat{\theta}^{\text{AIC}}$.

En général, cette valeur de τ^2 est faible et n'induit pas assez de parcimonie dans $\hat{\theta}^{\text{AIC}}$.

Par $c > 0$, on introduit alors $\hat{\theta}^{\text{BIC}} \in \arg \min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 + c \frac{\sigma^2 \ln(n)}{n} \|\theta\|_0 \right\}$ qui est l'estimateur BIC (Bayésien IC - 1978).

Critère BIC : $-\log\text{-vrais}(\theta) + \frac{1}{2} \|\theta\|_0 \ln(n)$.

Remarque : $\tau^2 = \frac{\sigma^2 \ln(n)}{n}$ est le seul dans l'estimateur de seuillage dur.

Théorème : $\exists c > 0$ tel que (+ hypothèse faible). $\mathbb{E} \left[\frac{1}{n} \|X\hat{\theta}^{\text{BIC}} - X\theta^*\|_2^2 \right] \leq c \underbrace{\frac{\sigma^2}{n} \|\theta^*\|_0}_{\text{vitesse optimale}} \cdot \ln(n)$

Attention. Sans l'hypothèse sur la matrice X , l'estimateur BIC atteint la vitesse optimale (au log-près).

En revanche, l'inconvénient principale de l'estimateur BIC est qu'il est difficilement calculable.

En effet, $\min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 + \tau^2 \|\theta\|_0 \right\} = \min_{k=0, \dots, n} \min_{\theta: \|\theta\|_0 = k} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 + \tau^2 k \right\}$.

Par chaque valeur de k , on résout $\binom{n}{k}$ problèmes d'optimisation (dont la complexité est équivalente à l'EMC).

Au total, il y a donc $\sum_{k=0}^n \binom{n}{k} 1^k 1^{n-k} = 2^n$ problèmes d'optimisation à résoudre.

Si $n \geq 30$, ce nombre est beaucoup trop grand.

On ne résout pas ce problème en un temps polynomial.

On dit que le problème est NP-Hard.

B) Autour de la pénalité

Notation : $\hat{\theta}^{\text{nc}} \in \arg \min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 \right\}$.

$$\begin{aligned} \text{On a : } \|y - X\theta\|_2^2 &= \|(y - X\hat{\theta}^{\text{nc}}) + (X\hat{\theta}^{\text{nc}} - X\theta)\|_2^2 \\ &= \|y - X\hat{\theta}^{\text{nc}}\|_2^2 + \|X\hat{\theta}^{\text{nc}} - X\theta\|_2^2 + 2(\hat{\theta}^{\text{nc}} - \theta)^T X^T (y - X\hat{\theta}^{\text{nc}}) \end{aligned}$$

$$\begin{aligned} \text{Par le graphe, on a : } P_{\mathcal{D}}(y) &= X(X^T X)^{-1} X^T y \\ &= X\hat{\theta}^{\text{nc}} \end{aligned}$$

$$\text{On a } y - P_{\mathcal{D}}(y) \perp \mathcal{D}.$$

$$\text{Donc } X^T (y - P_{\mathcal{D}}(y)) = 0 \Leftrightarrow X^T (y - X\hat{\theta}^{\text{nc}}) = 0.$$


$$\text{Ainsi : } \|y - X\theta\|_2^2 = \|y - X\hat{\theta}^{\text{nc}}\|_2^2 + \|X\theta - X\hat{\theta}^{\text{nc}}\|_2^2, \text{ et donc } \hat{\theta}_{\ell_0} \in \arg \min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|X\theta - X\hat{\theta}^{\text{nc}}\|_2^2 + \tau^2 \|\theta\|_0 \right\}.$$

Ce problème est également à résoudre.

$$\text{On a : } \min_{\theta \in \mathbb{R}^n} \|X\hat{\theta}^{\text{nc}} - X\theta\|_2^2 \text{ et sous la contrainte : } \|\theta\|_0 \leq t \text{ pour un } t > 0 \text{ bien choisi.}$$

On a le graphique avec $M = 2$ et $t = 1$:

$$\begin{cases} \textcircled{1} : \hat{\theta}_{\ell_0} = \begin{pmatrix} 0 \\ (\hat{\theta}_{\ell_0})_2 \end{pmatrix} \\ \textcircled{2} : d_x(\theta, \hat{\theta}^{\text{nc}}) = \|X\hat{\theta}^{\text{nc}} - X\theta\|_2^2 = a \end{cases}$$



↳ Spécificité / Non convexe

Trouver $\hat{\theta}_{\text{LS}}$ par M grand est un problème difficile (voir A) car l'ensemble $\{\theta : \|\theta\|_0 \leq t\}$ n'est pas convexe.


Par résoudre ce problème, on a recours à la convexification.

On a le graphique suivant:

On a $\hat{\theta}^{\text{LS}} \in \arg\min \left\{ \frac{1}{n} \|y - X\theta\|_2^2 \right\}$ sous la contrainte: $\|\theta\|_2^2 \leq t$.

③: boule ℓ_1 : convexe + induit de la spécificité

④: ℓ_q avec $0 < q < 1$: non convexe!



↳ Non sparse / convexe

Dans le cas $\{\|\theta\|_1 \leq t\}$, on s'obtient par un $t > 0$ bien choisi une solution sparse.

De plus, $\{\|\theta\|_1 \leq t\}$ est convexe.

On a donc tous les avantages que nous souhaitons.

Cette boule ℓ_1 donne l'estimateur Lasso: $\hat{\theta}^{\text{L}} \in \arg\min_{\theta \in \mathbb{R}^M} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 + \lambda \|\theta\|_1 \right\}$ que nous étudierons au chapitre suivant.