

On note $y = X\theta^* + \xi$ et $X = (X_{i,j})_{1 \leq i \leq n, 1 \leq j \leq p} \in \mathbb{R}^{n \times p}$, $y \in \mathbb{R}^n$, $\xi \sim \mathcal{N}(0, \sigma^2 I_n)$.

$\theta^* \in \mathbb{R}^p$ paramètre inconnu (et donc à estimer).

LASSO: Least Absolute Shrinkage Solution operator (Tibshirani, 1996):

$$\theta^* \in \arg\min_{\theta \in \mathbb{R}^p} \left\{ \frac{1}{2} \|y - X\theta\|_2^2 + 2\tau \|\theta\|_1, \tau \geq 0 \text{ et } X\theta = \sum_{j=1}^p \theta_j X_j \right\}$$

τ : paramètre de régularisation qui contrôle la sparsité (dans $\hat{\theta}$).

Plus τ est grand, plus on impose une forte pénalité sur $\|\theta\|_1$ qui devient petite $\Rightarrow$ sparsité dans θ .

Calcul pratique du LASSO

A) LARS

Notation: $X = (X^1 | \dots | X^p)$.

$$\text{On a } \frac{\partial}{\partial \theta_j} L(\theta) \Big|_{\theta=\hat{\theta}} = -\frac{2}{n} X_j^T (y - X\hat{\theta}) + 2\tau \text{sg}(\hat{\theta}_j) = 0 \text{ où } \text{sg}(u) = \begin{cases} 1 & \text{si } u > 0 \\ -1 & \text{si } u < 0 \\ [-1, 1] & \text{si } u = 0 \end{cases}$$

$$\text{Aussi: } \frac{\partial}{\partial \theta_j} L(\theta) \Big|_{\theta=\hat{\theta}} = 0 \Leftrightarrow \frac{1}{n} X_j^T (y - X\hat{\theta}) = \tau \text{sg}(\hat{\theta}_j).$$

$$\text{Alors: } \left| \frac{1}{n} X_j^T (y - X\hat{\theta}) \right| \leq \tau.$$

$$\text{En particulier par } j \in [M] \text{ tel que } \hat{\theta}_j \neq 0, \text{ on a: } \left| \frac{1}{n} X_j^T (y - X\hat{\theta}) \right| = \tau.$$


Ceci est vrai: $\forall \tau \in \mathbb{R}$.

Note: $\exists \tau_{\max} > 0$ tel que $\forall \tau > \tau_{\max}$, on a: $\hat{\theta} = 0_{\mathbb{R}^p}$.


$$\text{Soit } \tau \in [0, \tau_{\max}], \text{ on a: } \|X^T (y - X\hat{\theta})\|_{\infty} = \max_{j \in [M]} |X_j^T (y - X\hat{\theta})| = \tau$$

①: corrélation entre X^j et le résidu.

M=2: On note $X = (X^1 | X^2)$.



Cette idée donne l'intuition du LARS dont le chemin de régularisation peut être visualisée de la façon suivante:



②: Dans un cas idéal, on obtient à la fin l'EHC (Estimateur des Moindres Carrés).

$$\hat{\theta}(\tau): \tau \in [0, +\infty[.$$

Il existe de nombreux algorithmes pour tracer une solution approchée de $\hat{\theta}$:

- * Pathwise Coordinate Optimisation: Descente de gradient coordonnée par coordonnée.
 - ↳ lien avec le seuillage dax .
Chaque mise à jour est un calcul de seuillage dax
- * Fast Iterative Shrinkage Thresholding Algo (FISTA)

Remarque: Souvent τ est calibré par Validation Croisée.

B) Astuces pratiques

Tout comme le seuillage dax , le LASSO induit un biais.

On peut éliminer ce biais grâce à une procédure en 2 étapes:

- On fait un LASSO: $\tau > 0$, $\hat{\theta} \in \arg\min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 + 2\tau \|\theta\|_1 \right\}$.
De cette solution, on ne garde que l'ensemble actif $\hat{S} = \{j \in [M]: \hat{\theta}_j \neq 0\}$.
- On fait un moindre carré sur l'ensemble des variables sélectionnées à l'étape i).
On a: $\hat{\theta}^{\text{GL}} \in \arg\min_{\theta_j \in \mathbb{R}^{|\hat{S}|}} \left\{ \frac{1}{n} \|y - X_{\hat{S}} \theta_{\hat{S}}\|_2^2 \right\}$, et donc: $\hat{\theta}^{\text{GL}} = (X_{\hat{S}}^T X_{\hat{S}})^{-1} X_{\hat{S}}^T y$.

Attention: Si $j \in \hat{S} \rightarrow$ on met un 0.

Cet estimateur s'appelle: $\begin{cases} \text{Gauss Lasso} \\ \text{Least Squares LASSO} \end{cases}$

En présence de fortes corrélations entre les variables, le LASSO peut mal sélectionner les variables.

- ↳ Solution: Elastic-Net: $\hat{\theta}^{\text{EN}} \in \arg\min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|y - X\theta\|_2^2 + 2\tau \|\theta\|_1 + \mu \|\theta\|_2^2 \right\}$.

Remarque: Pour $\tau = 0$, $\hat{\theta}^{\text{EN}}(\tau, \mu)$ devient l'estimateur de Ridge $\rightarrow \hat{\theta}^{\text{R}} = \hat{\theta}^{\text{EN}}(0, \mu)$

$$= \left(\frac{X^T X}{n} + \mu I \right)^{-1} \frac{X^T y}{n}$$

III Théorie du LASSO

A) Hypothèses

$$H_{yp}(D): \left(\frac{X^T X}{n} \right)_{jj} = \begin{pmatrix} 1 & x \\ & \ddots \\ x & 1 \end{pmatrix} = 1, \forall j \in [M].$$

Dans la suite: "OK" veut dire "vitesse optimale" = $\sigma^2 \frac{\|\theta^*\|_0}{n} (\times \log)$

Cas 1: Modèle de Suites Gaussiennes (MSG): Si $\frac{X^T X}{n} = I_M$, LASSO = seuillage.

$\Rightarrow$ Donc "OK"

Attention: $M < n$.

Cas 2: Cohérence Mutuelle: Si $\left\| \frac{X^T X}{n} - I \right\|_{\infty} < \text{constante}$ (corrélations faibles entre variables), alors "OK"

3.4 Cas 3: Condition d'irreprésentabilité:

$\| (X_{\mathcal{S}^c}^T X_{\mathcal{S}^c}) (X_{\mathcal{S}^*}^T X_{\mathcal{S}^*})^{-1} \theta_{\mathcal{S}^*}^* \|_{\infty} < \text{constante}$, avec $\mathcal{S}^* = \{j \in [M] : \theta_j^* \neq 0\}$.
(Variables dans $\mathcal{S}^*$ faiblement corrélées aux variables dans $(\mathcal{S}^*)^c$).
 $\Rightarrow$ "OK"

Cas 4: Restricted Eigenvalues (valeurs propres restreintes): Si $\mathcal{S} \in [M]$, alors:

$$RE(\mathcal{S}) := \min_{\substack{\mathcal{S}: |\mathcal{S}| \leq s \\ \Delta \in \mathcal{C}(\mathcal{S})}} \frac{\frac{1}{n} \|\Delta\|_2^2}{\|\Delta_{\mathcal{S}}\|_2^2} := K^2 > 0 \text{ où } \mathcal{C}(\mathcal{S}) = \{\Delta \in \mathbb{R}^M : \|\Delta_{\mathcal{S}^c}\|_1 \leq 3 \|\Delta_{\mathcal{S}}\|_1\}.$$

De plus, $\min_{\Delta \in \mathbb{R}^n} \frac{\Delta^T (X^T X / n) \Delta}{\Delta^T \Delta} = \lambda_{\min} \left(\frac{X^T X}{n} \right) = 0$ si $M > n$.

Lemme: Sous l'hypothèse $RE(\mathcal{S})$, on a: $\|\Delta_{\mathcal{S}}\|_1 \leq \frac{s}{K^2} \cdot \sqrt{\frac{s}{n} \|X_{\mathcal{S}}\|_2^2}$, $\forall \Delta \in \mathcal{C}(\mathcal{S})$ où $|\mathcal{S}| \leq s$.

Preuve: $\|\Delta_{\mathcal{S}}\|_1 = \langle (\Delta_{\mathcal{S}})_1, \dots, (\Delta_{\mathcal{S}})_{|\mathcal{S}|} \rangle_{\mathcal{S}} = \langle s_1, \dots, s_{|\mathcal{S}|} \rangle_{\mathcal{S}} \leq \|\Delta_{\mathcal{S}}\|_2 \cdot \sqrt{|\mathcal{S}|}$ où $s_j = \text{sign}((\Delta_{\mathcal{S}})_j)$, $\forall j$.

$$\begin{aligned} \text{Donc } \|\Delta_{\mathcal{S}}\|_1 &\leq \|\Delta_{\mathcal{S}}\|_2 \cdot \sqrt{|\mathcal{S}|} \\ &\leq \sqrt{s} \|\Delta_{\mathcal{S}}\|_2 \leq \sqrt{s} \sqrt{\frac{(1/n) \|\Delta\|_2^2}{K^2}}. \end{aligned}$$

$\uparrow$ spécificité $\uparrow$ $RE(\mathcal{S})$

B) Borne pour l'erreur de prédiction

Théorème: Sous les hypothèses: $\begin{cases} (D) \\ RE(\mathcal{S}^*) \end{cases}$, et pour $\tau = A \sigma \sqrt{\frac{\ln(M)}{n}}$ avec $A > 2\sqrt{2}$.

On a avec probabilité $\geq 1 - M^{-1-A^2/8}$, on a: $\frac{1}{n} \|X\hat{\theta} - X\theta^*\|_2^2 \leq 9 \cdot \frac{A^2}{K^2} \sigma^2 \frac{|\mathcal{S}^*| \ln(M)}{n}$, et avec la même probabilité, on a: $\|\hat{\theta} - \theta^*\|_1 \leq 12 \frac{A \sigma^2}{K^2} |\mathcal{S}^*| \sqrt{\frac{\ln(M)}{n}}$.

Preuve: Par définition du LASSO, on a $\forall \theta \in \mathbb{R}^M$, (en particulier pour $\theta = \theta^*$),

$$\begin{aligned} \frac{1}{n} \|y - X\hat{\theta}\|_2^2 + 2\tau \|\hat{\theta}\|_1 &\leq \frac{1}{n} \|y - X\theta^*\|_2^2 + 2\tau \|\theta^*\|_1 \\ \Leftrightarrow \frac{1}{n} \|X\theta^* - X\hat{\theta}\|_2^2 + \frac{2}{n} \|\hat{\theta}\|_1^2 + \frac{2}{n} (\theta^* - \hat{\theta})^T X^T \xi + 2\tau \|\hat{\theta}\|_1 &\leq \frac{1}{n} \|\xi\|_2^2 + 2\tau \|\theta^*\|_1 \\ \Leftrightarrow \frac{1}{n} \|X\hat{\theta} - X\theta^*\|_2^2 &\leq \frac{2}{n} (\hat{\theta} - \theta^*)^T X^T \xi + 2\tau (\|\theta^*\|_1 - \|\hat{\theta}\|_1) \end{aligned}$$

Donc: $\frac{1}{n} \|X\hat{\theta} - X\theta^*\|_2^2 \leq \|\hat{\theta} - \theta^*\|_1 \cdot \left\| \frac{2X^T \xi}{n} \right\|_{\infty} + 2\tau (\|\theta^*\|_1 - \|\hat{\theta}\|_1).$

Montrons que: $\mathbb{P} \left(\left\| \frac{2X^T \xi}{n} \right\|_{\infty} \leq \tau \right) \geq 1 - M^{-1-A^2/8}$.

①: $\left\| \frac{2X^T \xi}{n} \right\|_{\infty} = \max_{j \in [M]} \left| \frac{2(X^j)^T \xi}{n} \right|$ avec $\xi \sim \mathcal{D}(0, \sigma^2 I)$.

Donc: $\frac{2(X^j)^T \xi}{n} \sim \mathcal{D}(0, \frac{4\sigma^2}{n} \cdot \frac{(X^j)^T I X^j}{n})$.

Or, on a: $\frac{(X^j)^T I X^j}{n} = \frac{(X^j)^T X^j}{n}$
 $= \left(\frac{X^T X}{n} \right) = 1$ par hypothèse (a)

Donc: $\frac{2(X^j)^T \xi}{n} \sim \mathcal{D}(0, \frac{4\sigma^2}{n})$.

Ainsi: $\mathbb{P} \left(\left\| \frac{2X^T \xi}{n} \right\|_{\infty} > \tau \right) = \mathbb{P} \left(\left\| \frac{2X^T \xi}{n} \right\|_{\infty} > A \sigma \sqrt{\frac{\ln(M)}{n}} \right)$

$= \mathbb{P} \left(\max_{j \in [M]} \frac{2\sigma}{\sqrt{n}} |\eta_j| > A \sigma \sqrt{\frac{\ln(M)}{n}} \right)$ où $\eta_j \sim \mathcal{D}(0, 1)$, $\forall j \in [M]$

$= \mathbb{P} \left(\max_{j \in [M]} |\eta_j| > \frac{A}{2} \sqrt{\ln(M)} \right)$

$\leq M^{-1-A^2/8}$ par la deuxième lemme du chapitre 3 avec $t = A/2$

33

4) le théorème précédent nécessite que τ soit une fonction de σ [$\tau \propto \sigma$].

Souvent σ est inconnu.

On ne peut donc pas utiliser la valeur théorique en pratique (du coup, on fait une validation croisée).

Pour résoudre ce problème, on peut utiliser le square root LASSO, noté $\sqrt{\text{LASSO}}$:

$$\hat{\theta}^{\sqrt{\text{LASSO}}} \in \underset{\theta \in \mathbb{R}^n}{\text{argmin}} \left\{ \sqrt{\frac{1}{n}} \|y - X\theta\|_2 + 2\tau \|\theta\|_1 \right\}.$$

Justification: On a pour LASSO:
$$\begin{cases} \frac{1}{n} \|y - X\theta\|_2^2 \sim \sigma^2 \\ \|\theta\|_1 \sim \sigma \end{cases}$$

Par que le critère LASSO reste homogène en σ , il faut que $\tau \propto \sigma$.

On a alors: $\sqrt{\text{LASSO}}: \begin{cases} \sqrt{\frac{1}{n}} \|y - X\theta\|_2 \sim \sigma \\ \|\theta\|_1 \sim \sigma \end{cases}$

le problème est déjà homogène en $\sigma \Rightarrow \tau \propto \sigma$.

Sous les mêmes hypothèses que le LASSO, et pour $\tau = A \sqrt{\frac{\ln(A)}{n}}$, $A > 2\sqrt{2}$, on a:

$$P\left(\frac{1}{n} \|X\hat{\theta}^{\sqrt{\text{LASSO}}} - X\theta^*\|_2^2 \leq C \frac{\sigma^2 \ln(M)}{n} \|\theta^*\|_0\right) \geq 1 - M^{-1-A^2/8}.$$

04/12/25

IV Fléau de la dimension

1) Données Massives

De plus en plus de données de toutes sortes (médicales, sciences sociales, ...):

→ En statistique traditionnelle, on a beaucoup d'observations et peu de variables (que l'on choisit soigneusement)

↳ il y a donc peu de paramètres à estimer ($n \gg M$)

→ Aujourd'hui, on a en core plus d'observation, mais aussi énormément de variables (M de l'ordre de n ou même $M \gg n$)

↳ $\begin{cases} \text{Que faire de cette masse de données} \\ \text{Est-ce que c'est un avantage.} \end{cases}$

Exemples:

i) biotechnologie: Par mesure le niveau d'expression de milliers de gènes simultanément.

ii) images et vidéos: $\leadsto 10^6$ pixels par image

iii) recommandations clients: Informations recueillies sur des sites webs.

↳ sujet de recommandation.

iv) planète et climat: données météorologiques, climatiques et écologiques.

2) Grandes Dimensions (Mathématiques)

a) Volume d'une boule

34) Soit $\mathbb{R}^M$ avec M grand, on a: $B_n(r) = \{v \in \mathbb{R}^M : \|v\|_2 \leq r\}$

Volume de cette boule ?

i	1	2	3	...	M
$V(B_i(r))$	$2r$	πr^2	$\frac{4}{3} \pi r^3$	...	$\frac{\pi^{M/2} r^M}{\Gamma(\frac{M}{2} + 1)}$



$$\text{à } \Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt.$$

$$\text{On a : } V(B_n(r)) \sim \left(\frac{2\pi e r}{n}\right)^{n/2} (M\pi)^{-n/2} \xrightarrow{n \rightarrow \infty} 0.$$

En particulier, le volume de la boule est concentré dans sa coque:

$$C_n(r) = B_n(r) \setminus B_n(0, 99r)$$

$$\text{On a : } \frac{V(C_n(r))}{V(B_n(r))} = \frac{V(B_n(r))}{V(B_n(r))} - \frac{V(B_n(0, 99r))}{V(B_n(r))} \\ = 1 - (0,99)^n \xrightarrow{n \rightarrow \infty} 1 \text{ (exponentiellement vite).}$$



b) Distance entre points/vecteurs

Soit $X_i \stackrel{i.i.d}{\sim} \mathcal{U}([0,1])$, on a: $X = (X_1, \dots, X_n)^T \in [0,1]^n$.

Soit $x = (\frac{1}{2}, \dots, \frac{1}{2})^T \in [0,1]^n$, point au centre du cube.

On note $D = \|x - X\|_1$, on a:

$$\begin{aligned} \bullet \mathbb{E}[D] &= \mathbb{E}\left[\sum_{i=1}^n |X_i - \frac{1}{2}|\right] \\ &= \sum_{i=1}^n \mathbb{E}[|X_i - \frac{1}{2}|] \\ &= n \cdot \mathbb{E}[|X_1 - \frac{1}{2}|] = n \cdot \frac{1}{4} \\ \bullet \text{Var}(D) &= \text{Var}\left(\sum_{i=1}^n |X_i - \frac{1}{2}|\right) \\ &= \sum_{i=1}^n \text{Var}(|X_i - \frac{1}{2}|) \\ &= n \cdot \underbrace{\text{Var}(|X_1 - \frac{1}{2}|)}_{=c} = n \cdot c \end{aligned}$$

$$\text{Donc } D \approx \frac{n}{4} \pm \sqrt{c} \sqrt{n}$$

↳ la distance au centre est de plus en plus grande et tous les points sont à distance scalaire (vrai pour ℓ_2, ℓ_∞).

A priori, les méthodes basées sur les distances s'effondrent.

c) D'autres phénomènes

la diagonale de l'hypercube $[0,1]^n$ est presque orthogonal à ses côtés: $\cos(\alpha) = \frac{\langle u, v \rangle}{\|u\|_2 \|v\|_2} \\ = \frac{\langle (1, 1, \dots, 1), (1, 0, \dots, 0) \rangle}{\|(1, 1, \dots, 1)\|_2 \|(1, 0, \dots, 0)\|_2} \\ = \frac{1}{\sqrt{n}} \xrightarrow{n \rightarrow \infty} 0.$

Densité gaussienne se concentre dans ses queues: $\sup_{x \in \mathbb{R}^n} \varphi(x) = \frac{1}{(2\pi)^{n/2}} \xrightarrow{n \rightarrow \infty} 0.$

3) la solution de la parcimonie

⚠ Attention: les données ne sont pas réparties uniformément en général!

35

Exemples:

- i) 30000 gènes: $\rightarrow$ tous ne sont pas impliqués dans le processus conduisant à une maladie
- ii) recommandation: En général, la connaissance des goûts d'un client sur ~ 30 films, suffit pour faire de bonnes recommandations.
- iii) images: les images sont structurées.

2

En général, les données sont concentrées autour de structures de faible dimension

Beaucoup de variables ont un très faible impact.

$\Rightarrow$ Hypothèse de parcimonie (structure de faible dimension).

La question principale est alors de retrouver cette structure.

⑤ Sparsité dans des modèles généraux

Une solution par contre le fléau de la grande dimension est d'exploiter la parcimonie.

Par des problèmes classiques, on peut utiliser des variantes du LASSO.

En particulier, on peut souvent avoir recours à l'estimateur de maximum pénalisé par une norme proche de la norme ℓ_1 : $\hat{\theta} \in \arg \min_{\theta} \{-\ln(V(y, X; \theta)) + \text{pen}(\theta)\}$.
 $\propto \|\theta\|_1$

Voici quelques exemples:

1) Modèle de régression linéaire

$Y_i = X_i^T \theta^* + \xi_i$ avec $\xi_i \sim \mathcal{N}(0, \sigma^2)$ et $\theta^* \in \mathbb{R}^n$.

On a $\mathbb{E}[Y_i | X_i] = X_i^T \theta^*$ linéaire.

Déjà vu dans ce chapitre: $y = X \theta^* + \xi$ et $X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbb{R}^n$.

$$\leadsto \hat{\theta}^L \in \arg \min_{\theta \in \mathbb{R}^n} \left\{ \frac{1}{n} \|y - X \theta\|_2^2 + 2\tau \|\theta\|_1 \right\}$$

2) Modèle de régression logistique

On a $Y_i \in \{-1, 1\}$.

$$\begin{aligned} \mathbb{E}[Y_i | X_i] &= \mathbb{P}(Y_i = 1 | X_i) - \mathbb{P}(Y_i = -1 | X_i) \\ &= 2\mathbb{P}(Y_i = 1 | X_i) - 1 \end{aligned}$$

On note $\eta(x) = \mathbb{P}(Y_i = 1 | X_i = x)$

Classifieur optimal: $h^*(x) = \text{sgn}(\eta(x) - \frac{1}{2})$, $\forall x \in \mathcal{X}$.

$$\begin{aligned} \text{Vraisemblance: } \mathbb{V}(y, X; \eta) &= \prod_{i=1}^n (\eta(X_i))^{y_i} (1 - \eta(X_i))^{1-y_i} = -\ln(\mathbb{V}(y, X; \eta)) \\ &= -\left(\sum_{i=1}^n Y_i \ln(\eta(X_i)) + (1 - Y_i) \ln(1 - \eta(X_i)) \right) \end{aligned}$$

Comment modéliser η ?

36

$$\eta_{\theta^*}(x) = \frac{\exp(x^T \theta^*)}{1 + \exp(x^T \theta^*)} \text{ avec } \theta^* \in \mathbb{R}^H.$$

fonction sigmoïde $\rightarrow$ $\sigma(x^T \theta^*) \in [0, 1]$ proba.

EMV: $\hat{\theta}^{EMV} \in \arg \min_{\theta \in \mathbb{R}^H} \frac{1}{n} \sum_{i=1}^n (Y_i \ln(\sigma(X_i^T \theta)) + (1 - Y_i) \ln(1 - \sigma(X_i^T \theta)))$

$\underbrace{\qquad\qquad\qquad}_{\hat{R}_n(\theta)}$

On note $R(\theta) = \mathbb{E}_p[Y \ln(\sigma(X^T \theta)) + (1 - Y) \ln(1 - \sigma(X^T \theta))]$ pour $(X, Y) \sim P$

$$\mathbb{E}_p(\theta) = R_p(\theta) - R_p(\theta^*) \text{ où } \theta^* \in \arg \min_{\theta \in \mathbb{R}^H} R_p(\theta).$$

Résultat: Si $\|X\| < L$ presque sûrement, on a: $\mathbb{E}_p(\hat{\theta}^{EMV}) \leq C \cdot \frac{H}{n}$

$\leftarrow$ Constante

EMV + LASSO: $\hat{\theta}^{\log + L_1} \in \arg \min_{\theta \in \mathbb{R}^H} \{ \hat{R}_n(\theta) + \tau \|\theta\|_1 \}$

Si $\|X\| < L$ presque sûrement + $\|\theta^*\|_0 = s \ll n$ + Hypothèse "RE"

Si $\tau = L \cdot \sqrt{\frac{\ln(H)}{n}}$, alors: $\mathbb{E}_p(\hat{\theta}^{\log + L_1}) \leq \text{constante} \cdot \frac{s \cdot \ln(H)}{n}$.


Remarque: Ce type de résultats se généralisent (de la même façon) à la famille exponentielle.

(Modèle linéaire généralisé) $\leadsto$ Poisson, ...

3) Estimation de graphes

On a: $cl(a) = ne(a) \cup \{a\}$ où $ne(a) = \{b \neq a : a \stackrel{?}{\sim} b\}$

$\odot$: lie dans le graphe (il y a une arête)



Modèle Graphique Gaussien (MGG): On a $X \sim \mathcal{P}(0, \Sigma)$ avec Σ inversible et inconnue!

On veut estimer le graphe g^* .

On note $K = \Sigma^{-1}$, matrice de précision

Attention: $a \stackrel{?}{\sim} b \Leftrightarrow K_{ab} \neq 0$, revient à dire: Estimer $g^* \Leftrightarrow$ estimer K .

Plus précisément, on a:

Lemme: Soit $X = (X^1, \dots, X^H) \sim \mathcal{P}(0, \Sigma)$

$$\forall a \in [H], X^a = - \sum_{b \neq a} \frac{K_{ab}}{K_{aa}} X^b + \varepsilon^a$$

$$\text{Pour } \varepsilon^a \sim \mathcal{P}(0, K_{aa}^{-1}), \varepsilon^a \perp\!\!\!\perp ne(X^a)$$

$$\text{On a donc } X^a = \sum_{b \neq a} \theta_b^a X^b + \varepsilon^a \text{ avec } \theta_b^a = - \frac{K_{ab}}{K_{aa}}.$$

En autres termes, trouver $\{b : K_{ab} \neq 0\}$ pour $a \in [H]$ revient à trouver le support de θ^a (c'est-à-dire $\{b : \theta_b^a \neq 0\}$)

$\odot$: $\theta^a = (\theta_1^a, \dots, \theta_H^a)^T$

On peut répondre à cette question en régressant X^a sur $\{X^b : b \neq a\}$.

$$\text{On note : } \odot^* \in \arg \min_{\odot \in \odot} \mathbb{E} \left[\sum_{a=1}^H (X^a - \sum_{b: b \neq a} \odot_b^a X^b)^2 \right]$$

$\odot$: $\odot = (\theta_b^a)_{a, b \in [H]}$

$\odot$: $\sum_{a=1}^H \|X^a - X^T \odot^a\|^2$

33

↳ Estimateur de type LASSO: $X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbb{R}^{n \times p}$ où $x_i \stackrel{iid}{\sim} \mathcal{P}(0, \Sigma)$

$$\hat{\theta}_\tau \in \underset{\theta \in \mathbb{R}^p}{\text{argmin}} \frac{1}{n} \sum_{i=1}^n \left\{ (X_i)^a - \sum_{b: b \neq a} \theta_b (X_i)^b \right\}^2 + \tau \sum_{a=1}^p |\theta_a|.$$

Théorème: Si $\sum_{a=1}^p \Sigma_{aa} = 1, \forall a \in [p], \exists c, c', c_1, c_2, c_3 > 0$ tel que dès que $1 \leq d(\Sigma) \leq \frac{n}{\phi_n \ln(p)} \wedge \frac{1}{\max_{b \neq a} |\Sigma_{ab}|}$, où:

$$\begin{cases} d(\Sigma) = \max_a \|\theta^a\|_0 \text{ (degré de } g^*) \\ \phi_n = \max \|\Sigma_{\mathcal{J}\mathcal{J}}\|_{op} : \mathcal{J} \in [p], |\mathcal{J}| \leq \frac{n}{3 \ln(p)} \end{cases}$$

et pour $\tau = c' \phi_n \sqrt{\ln(p)}$, on a probabilité $\geq 1 - c_1 (M^{-c_2})$: $\|X \hat{\theta}_\tau - X \theta^*\|_F^2 \leq c_3 \frac{\phi_n^2 \ln(p)}{n} \|\theta^*\|_0$.

Et bien d'autres méthodes!