
Projet 1 : Estimation de densité

Les notations utilisées sont celles du cours.

Exercice 1. Données simulées

1. On construit les données simulées de la manière suivante:
 - (a) Générer un échantillon de taille 50 constitué de réalisations d'une gaussienne $\mathcal{N}(-1, 5; 2)$.
 - (b) Générer un échantillon de taille 50 constitué de réalisations d'une uniforme sur $[0, 1]$.
 - (c) Définir $\mathbf{X}$ comme la concaténation de ces deux vecteurs.
2. On suppose alors que le vecteur $\mathbf{X}$ est constitué de réalisations i.i.d. d'une variable aléatoire X dont la loi nous est inconnue. On se propose alors d'estimer la densité f de X .
 - (a) Construire un histogramme pour les données $\mathbf{X}$.
 - (b) Construire l'estimateur à noyau de f en utilisant deux noyaux de votre choix vus en cours. Le choix de la fenêtre est optimisé à la main afin de garantir un aspect visuelle acceptable.
 - (c) Construire l'estimateur optimal en utilisant la technique de validation croisée.

Exercice 2. Données réelles

Appliquer la méthodologie proposée ci-dessus sur un jeu de données de votre choix adapté à l'estimation de densité (provenant par exemple de la base de données UCI - machine learning).

Projet 2 : Estimateur par projection

Les notations utilisées sont celles du cours.

Exercice 1. Fourier

Le but de ce TP est d'étudier de façon numérique l'estimateur par projection introduit en cours et d'observer l'influence du paramètre de troncature N sur cet estimateur.

1. Simuler $n = 100$ couples de variables aléatoires indépendantes (X_i, Y_i) , $i = 1, \dots, n$ de la manière suivante:

(a) Les X_i sont i.i.d. et uniformément distribués sur $[0, 1]$.

(b) Les Y_i sont tels que :

$$Y_i = f(X_i) + \sigma \xi_i,$$

où les ξ_i sont des variables aléatoires normales i.i.d. et f est une fonction de $[0, 1] \rightarrow \mathbb{R}$ définie par $f(x) = (x^2 2^{x-1} - (x - 0,5)^3) \sin(10x)$. De plus, on fixe $\sigma = 0,2$.

2. Représenter sur un même graphique le nuage de points obtenu ainsi que la vraie fonction f .
3. On se propose d'estimer la fonction de régression f par un estimateur défini par projection sur la base de Fourier.
 - (a) Tracer sur un même graphique les 5 premières fonctions de cette base.
 - (b) Construire l'estimateur par projection de f pour $N \in \{5, 10, 15, 20, 30, 50, 70\}$.
 - (c) Choisir la valeur de N optimale par validation croisée et tracer l'estimateur correspondant.
4. La valeur optimale du paramètre N , obtenue ci-dessus, dépend de l'échantillon $(X_1, Y_1), \dots, (X_n, Y_n)$ construit à la question 1. Réitérer la procédure ci-dessus 200 fois et tracer un histogramme des valeurs optimales de N obtenues.
5. Conclure.

Exercice 2. Données réelles

Appliquer la méthodologie proposée ci-dessus sur un jeu de données de votre choix adapté à l'estimation de fonction de régression (provenant par exemple de la base de données UCI - machine learning).

Projet 3 : Sparsité, estimation et sélection de variables

Les notations utilisées sont celles du cours.

Exercice 1. Différentes méthodes de seuillage

Supposons que l'on observe $y_1, \dots, y_d$ vérifiant le modèle de suite gaussienne

$$y_j = a\eta_j + \xi_j; \quad j = 1, \dots, d;$$

avec $a \in \mathbb{R}$ et $\eta_j \in \{0, 1\}$ qui sont des paramètres inconnus tels que

$$\sum_{j=1}^d \eta_j = [d^{1-\beta}], \text{ pour un } \beta \in (0, 1) \text{ fixé,}$$

où les variables aléatoires ξ_j sont i.i.d. de loi $\mathcal{N}(0, 1)$.

Application numérique: $d = 50$, $\beta = 0.3$ et a varie de 1 à 10. On pose le seuil $\tau = \sqrt{2 \log d}$.

On note $\theta^* = a \cdot (\eta_1, \dots, \eta_d)^\top$. Pour estimer θ^* on considère l'estimateur par seuillage fort $\hat{\theta}^H$, l'estimateur par seuillage faible $\hat{\theta}^S$ et l'estimateur dit 'non-negative garrotte' $\hat{\theta}^{NG}$ définis respectivement par :

$$\hat{\theta}_j^H = y_j I(|y_j| > \tau), \quad \hat{\theta}_j^S = y_j \cdot \left(1 - \frac{\tau}{|y_j|}\right)_+, \quad \hat{\theta}_j^{NG} = y_j \cdot \left(1 - \frac{\tau^2}{y_j^2}\right)_+,$$

pour tout $j \in \{1, \dots, d\}$, où $(a)_+ = \max\{0, a\}$ pour tout $a \in \mathbb{R}$.

1. Tracer sur le même graphique les fonctions $\hat{\theta}_j^H(y_j)$, $\hat{\theta}_j^S(y_j)$ et $\hat{\theta}_j^{NG}(y_j)$ (comme fonction de y_j).
2. On note $R(\hat{\theta}, a) = \|\hat{\theta} - \theta^*\|_2^2$ le risque quadratique de l'estimateur $\hat{\theta}$.
Représenter graphiquement, pour chacun des estimateurs ci-dessus, les quantités $R(\hat{\theta}, a)$ pour a qui varie de 1 à 10.
3. Sélectionner les coordonnées non nulles de θ^* (par seuillage dur, c'est-à-dire, $\hat{\eta}_j = I(|y_j| \geq \tau)$), et étudier le risque de sélection de variables $R^{MS}(\hat{\theta}, a) = \sum_{j=1}^M |\eta_j - \hat{\eta}_j|$ pour $a \in [1, 10]$.

Important : Pour avoir une idée des vrais risques, utiliser pour les illustrations des questions 2 et 3 des moyennes (et écarts-types) sur plusieurs répétitions.

Exercice 2. Détection de ruptures

Supposons que l'on observe $y_1, \dots, y_d$ vérifiant le modèle de suite gaussienne

$$y_j = \theta_j^* + \varepsilon \cdot \xi_j; \quad j = 1, \dots, d,$$

avec $\varepsilon = 1/\sqrt{d}$, $\theta^* = (\theta_1^*, \dots, \theta_d^*)^\top$ est tel que

$$\begin{cases} \theta_j^* = 3, & \text{pour } j \in \{1, \dots, 10\}, \\ \theta_j^* = 7, & \text{pour } j \in \{11, \dots, 30\}, \\ \theta_j^* = 1.5, & \text{pour } j \in \{31, \dots, 40\}, \\ \theta_j^* = 2, & \text{pour } j \in \{41, \dots, d\}, \end{cases}$$

et les variables aléatoires ξ_j sont i.i.d. de loi $\mathcal{N}(0, 1)$. On fixe $d = 50$ pour la suite.

Proposer une méthode permettant de détecter les instants de ruptures dans le vecteur θ^* , c'est-à-dire, une méthode permettant d'estimer l'ensemble $J^* = \{j \in \{2, \dots, d\} : \theta_j^* \neq \theta_{j-1}^*\}$.

Idée : Considérer le vecteur, **sparse**, des différences $\Delta^* = (\Delta_1^*, \dots, \Delta_{d-1}^*)^\top$, dont la j -ième composante Δ_j^* est donnée par : $\Delta_j^* = \theta_{j+1}^* - \theta_j^*$.

Exercice 3. Données réelles pour la détection de ruptures

Appliquer la méthodologie proposée dans l'exercice 2 sur un jeu de données de votre choix adapté à la détection de ruptures (provenant par exemple de la base de données UCI - machine learning).

Projet 4 : Régression en grande dimension et sparsité

Les notations utilisées sont celles du cours.

Exercice 1. Régularisation

1. Supposons que l'on observe le modèle linéaire $Y = X\beta + \eta$, avec η un vecteur gaussien standard de dimension $n = 1000$, β un vecteur de dimension $p = 5000$ tel que

$$\beta_1 = \dots = \beta_{15} = 1$$

et les autres coordonnées sont nulles (paramètre de sparsité $s = 15$). On suppose que les colonnes $X_{\cdot,j}$ de X sont i.i.d. gaussiens standards (pas corrélées).

On sépare l'échantillon en deux: deux tiers des données (environ 660) pour l'estimation du modèle et un tiers des données (environ 340) pour tester le modèle retenu.

Nous voulons comparer les estimateurs suivants en utilisant par exemple la fonction ElasticNet de `sklearn.linear_model`:

- LASSO

$$\hat{\beta}^L = \arg \min_{\beta} L_{\lambda}(\beta) \text{ où } L_{\lambda}(\beta) = \frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i\cdot} \beta)^2 + \lambda \|\beta\|_1,$$

pour $\lambda > 0$.

- Ridge

$$\hat{\beta}^R = \arg \min_{\beta} R_{\mu}(\beta) \text{ où } R_{\mu}(\beta) = \frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i\cdot} \beta)^2 + \frac{\mu}{2} \|\beta\|_2^2,$$

pour $\mu > 0$.

- Elastic net

$$\hat{\beta}^{EN} = \arg \min_{\beta} F_{\lambda}(\beta) \text{ où } F_{\lambda}(\beta) = \frac{1}{2n} \sum_{i=1}^n (Y_i - X_{i\cdot} \beta)^2 + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right),$$

pour $\lambda > 0$ et $\alpha \in [0, 1]$. Remarquer que $\alpha = 0$ donne l'estimateur Ridge et $\alpha = 1$ le Lasso.

- Estimer le vecteur de regression par la méthode Elastic-Net pour toutes les valeurs de α dans $\{0, 0.1, 0.2, \dots, 0.9, 1\}$.
 - Tracer le chemin de régularisation du Lasso.
 - En utilisant seulement l'échantillon d'apprentissage, déterminer la valeur optimale du paramètre de régularisation pour les trois méthodes ci-dessus (attention: pour l'Elastic-Net, la recherche se fera sur une grille en dimension deux).
 - Quel estimateur fournit la meilleure prédiction sur l'échantillon test?
2. Mêmes questions si on remplace β par $\beta_1 = \dots = \beta_{1500} = 1$ et les autres coordonnées sont nulles.
3. Mêmes questions pour $n = 100$, $p = 50$, $\beta_1 = \beta_2 = 10$, $\beta_3 = \beta_4 = 5$, $\beta_5 = \dots = \beta_{14} = 1$ et les autres coordonnées sont nulles. On suppose aussi que les prédicteurs sont corrélés: $\text{cov}(X_{k,i}, X_{k,j}) = 0.7^{|i-j|}$.

Exercice 2. Données réelles

Appliquer les méthodes proposées ci-dessus sur un jeu de données de votre choix adapté à la régression en grande dimension (provenant par exemple de la base de données UCI - machine learning).